

情報論

第10回：AIを用いたデータ分析

Titanic例題からBank Marketing課題へ：前処理・可視化・AI出力の検証

2026年度 | 日本大学大学院 理工学研究科 | 松野 裕

今日の位置づけ

これまで情報論で扱ってきたAI活用を、実データ分析の流れの中で使う。

今日扱うこと

項目	今日の扱い
データ確認	行数、列、欠損値、外れ値を確認する
可視化	グループ別生存率や分布を読む
前処理	欠損値とカテゴリ変数を扱う
モデリング	ロジスティック回帰の評価結果を読む
データ探索	自分で分析対象データを探す

今日は精度を競うのではなく、分析結果を自分の言葉で説明し、AIの出力を確かめながら使うことを目標にする。

例題で調べたいこと

まずTitanicデータを例題として、乗客の属性と生存・死亡の関係を調べる。

主な問い

- 生存者は、死亡者と比べてどのような傾向があったか
- 客室クラス、性別、年齢、運賃は生存率と関係しているか
- 欠損値やカテゴリ変数をどう処理すれば、分析に使える形になるか
- モデルはどの程度、生存・死亡を予測できるか

この授業では「なぜ生存したか」を断定するのではなく、データ上で見える傾向を確認する。

これまでの内容との対応

これまで扱ったAI活用を、統計の基礎と実データ分析につなげる。

これまでの内容	今日使う場面
平均・分散・標準偏差	Age , Fare の分布や外れ値を確認する
ヒストグラム・相対度数	生存者と非生存者の分布を比較する
相関・回帰	変数と Survived の関係を調べる
確率変数・期待値	0/1変数 Survived の平均を生存率として読む
多重共線性	説明変数同士の重なりに注意する
AI出力の検証	コード、数値、解釈を自分で確認する

AIの出力を検証しながら実データ分析を進めることを重視する。

今日の学習目標

授業後に、次の流れを説明できることを目標にする。

1. Pandasでデータを読み込み、欠損値と列の意味を確認する
2. 可視化により、データの傾向を読み取る
3. 性別・客室クラスなどのグループ別生存率を比較する
4. 最小限の前処理を行い、正解率と混同行列を確認する
5. 結果を自分の言葉で説明し、AIの説明を検証する
6. 同じ手順で分析できる公開データを探す

授業の進め方

時間	内容	到達ライン
0-10分	目的、データ、AI使用ルール	作業の全体像を把握
10-25分	Colab起動、データ読み込み	<code>df.head()</code> まで
25-40分	欠損値と列の意味の確認	処理方針をメモ
40-60分	グループ別生存率の可視化	傾向を説明
60-75分	最小限の前処理	モデルに入る形にする
75-90分	分類モデルの評価	正解率・混同行列
90-100分	Bank Marketingとデータ探索課題	課題の方針を決める

今日の提出物

Google Classroomに、実行済みColabノートブックの共有リンクを提出する。

提出先

Google Classroomの第10回課題

Colabノートブックに残すもの

1. すべてのコードセルの実行結果
2. 結果を見て分かったこと・考えたこと
3. AI使用記録
4. 振り返りコメント
5. 自分で探したデータ候補の出典URLと選定理由

AI使用記録には、使用したAIツール、入力したプロンプト、採用・修正した回答、検証した内容を残す。

今日の構成：例題と課題

今日の授業では、次の3つを区別して進める。

位置づけ	データ	目的
例題	Titanicデータ	分析の流れを全員で確認する
共通課題	Bank Marketingデータ	別データへ同じ手順を移す
個人課題	学生が探す公開データ	自分で問いと分析対象を設定する

Titanicのスライドは、前処理・可視化・モデル評価・AI出力の検証の型を確認するための例として使う。

データと環境

まず動く状態を作る

使用するデータ（例題）

Titanicデータセット

1912年に沈没したタイタニック号の乗客データ。
乗客の属性から、生存したかどうかを予測する分類問題として扱う。

列	意味
Survived	生存したか（0=死亡、1=生存）
Pclass	客室クラス（1, 2, 3）
Sex , Age	性別、年齢
SibSp , Parch	同乗家族数
Fare	運賃
Cabin , Embarked	客室番号、乗船港

※ `train.csv` はGoogle Classroomで配布する。授業ではGoogle Driveの指定フォルダに置いてColabから読み込む。

AIの使い方

AIは使ってよい。ただし、分析を丸投げしない。

よい使い方

- 「このエラーの原因は何か」
- 「Age の欠損値を中央値で補完するコードを書いて」
- 「混同行列の各セルの意味を説明して」

避ける使い方

- 「Titanicデータを分析して」
- AIが出したコードを読まずに実行する
- AIの説明を検証せずにレポートへ貼る

Colabで作業を始める

1. Google Classroomから `train.csv` と `titanic_colab_code.ipynb` をダウンロードする
2. Google Driveの `マイドライブ/information_theory2026/` に `train.csv` を置く
3. Google Colabで `titanic_colab_code.ipynb` を開く
4. 必要ならノートブック名を `studentid_titanic.ipynb` のように変更する
5. ランタイムはCPUのままでよい

左側のファイル欄に直接アップロードする方法でも読めるが、セッションが切れると消える。授業ではGoogle Driveに置いてから読み込む方法を推奨する。

Colabリンクの提出方法

1. Colabの「共有」ボタンを押す
2. 教員が開ける共有設定にする
3. 「リンクをコピー」してGoogle Classroomに貼る
4. Classroom提出前に、リンクを開いてノートブックが見えるか確認する

共有設定が自分だけになっていると、提出されても教員が確認できない。大学アカウント内で閲覧できる設定、または教員に閲覧権限を付ける。

環境確認

Colabの最初のセルで実行する。

```
import os

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from IPython.display import display
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report

print("環境確認完了")
```

通常のColab環境では、今日使うライブラリを追加インストールなしで読み込める。
エラーが出た場合は、まずエラーメッセージに出ているライブラリ名を確認する。

実行結果：環境確認

環境確認完了

通常のColab環境では、今日使うライブラリは追加インストールなしで読み込める。

Google Driveをマウントする

次のセルを実行し、Google Driveへのアクセスを許可する。

```
from google.colab import drive
drive.mount("/content/drive")
```

初回はGoogleアカウントの確認画面が出る。

マウント後、Drive内のファイルは `/content/drive/MyDrive/` 以下から読める。

データの読み込み

Driveに置いた `train.csv` を読み込む。

```
import os

DATA_PATH = "/content/drive/MyDrive/information_theory2026/train.csv"

if not os.path.exists(DATA_PATH):
    raise FileNotFoundError(DATA_PATH)

df = pd.read_csv(DATA_PATH)

print(df.shape)
display(df.head())
df.info()
display(df.describe())
```

`FileNotFoundError` が出たら、Drive内の保存場所と `DATA_PATH` が一致しているか確認する。

実行結果：読み込みの概要

`df.shape` は `(891, 12)`。

確認すること

- 891人分の乗客データである
- `Survived` を目的変数として扱う
- 数値列と文字列列が混在している

実行結果：先頭5行

df.head(): first 5 rows

PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked
1	0	3	male	22.0	1	0	7.25	NaN	S
2	1	1	female	38.0	1	0	71.2833	C85	C
3	1	3	female	26.0	0	0	7.925	NaN	S
4	1	1	female	35.0	1	0	53.1	C123	S
5	0	3	male	35.0	0	0	8.05	NaN	S

実行結果：列と欠損の概要

Column overview and missing values

Column	Non-null	Missing	Type
PassengerId	891	0	int64
Survived	891	0	int64
Pclass	891	0	int64
Name	891	0	object
Sex	891	0	object
Age	714	177	float64
SibSp	891	0	int64
Parch	891	0	int64
Ticket	891	0	object
Fare	891	0	float64
Cabin	204	687	object
Embarked	889	2	object

実行結果：数値列の要約統計量

df.describe().T: numeric summary

Column	count	mean	std	min	25%	50%	75%	max
PassengerId	891.00	446.00	257.35	1.00	223.50	446.00	668.50	891.00
Survived	891.00	0.38	0.49	0.00	0.00	0.00	1.00	1.00
Pclass	891.00	2.31	0.84	1.00	2.00	3.00	3.00	3.00
Age	714.00	29.70	14.53	0.42	20.12	28.00	38.00	80.00
SibSp	891.00	0.52	1.10	0.00	0.00	0.00	1.00	8.00
Parch	891.00	0.38	0.81	0.00	0.00	0.00	0.00	6.00
Fare	891.00	32.20	49.69	0.00	7.91	14.45	31.00	512.33

読み込み結果で記録すること

- 行数と列数
- 数値列とカテゴリ列
- 欠損値がありそうな列

確認の観点

- `df.shape` でデータの大きさを見る
- `df.info()` で列ごとの型と欠損の有無を見る
- `df.describe()` で数値列の範囲と外れ値の候補を見る

演習1

データの概要と欠損値を確認する

列の意味を確認する

まず、各列が何を表しているかを自分の言葉でメモする。

列	確認する観点
Survived	目的変数。何を予測したいのか
Pclass	数値だが、客室クラスというカテゴリに近い
Sex , Embarked	文字列なので数値化が必要
Age , Fare	数値だが欠損値・外れ値に注意
Name , Ticket , Cabin	そのまま特徴量に使うか検討が必要

AIに列の意味を聞いてよいが、データの表示結果と照合する。

欠損値を確認する

```
missing_count = df.isnull().sum()
missing_rate = (df.isnull().sum() / len(df) * 100).round(1)

pd.DataFrame({
    "欠損数": missing_count,
    "欠損率(%)": missing_rate
})
```


判断の例

- Age : 欠損はあるが、削除するとデータが減るため中央値補完を検討
- Cabin : 欠損が多すぎるため、今回は列ごと除外
- Embarked : 欠損が少ないため、最頻値補完を検討

実行結果：欠損値

Columns with missing values

Column	Missing count	Missing rate (%)
Age	177	19.9
Cabin	687	77.1
Embarked	2	0.2



確認すること

- Age は欠損があるが、列ごと削除するほどではない
- Cabin は欠損が多く、今回は列ごと除外する
- Embarked は欠損が少ないため、最頻値で補う

欠損値処理の方針をメモする

ノートブックのテキストセルに、以下の形式で書く。

列	処理	理由
Age	中央値で補完	欠損は多いが、年齢は重要そう
Cabin	削除	欠損が非常に多い
Embarked	最頻値で補完	欠損が少ない

コードだけではなく、なぜその処理を選んだかを書く。ここが提出ノートブックで重要になる。

演習2

可視化して傾向を読む

生存者数の分布


```
df["Survived"].value_counts().sort_index().plot(
    kind="bar",
    color=["#D32F2F", "#02BD35"]
)
plt.title("Survived Distribution")
plt.xlabel("Survived (0=No, 1=Yes)")
plt.ylabel("Count")
plt.show()

print(df["Survived"].mean())
```

読み取ること

- `Survived` は0/1なので、平均は生存率になる
- 生存率は何%か
- 正解率だけで評価してよいか

実行結果：生存者数の分布



Target variable summary

Class	Value
0: Not survived	549
1: Survived	342
Survival rate	38.4%

読み取りポイント

- 生存率は38.4%
- 死亡者の方が多い
- 全員を死亡と予測しても一定の正解率が出るため、正解率だけでは不十分

カテゴリ変数と生存率

```
fig, axes = plt.subplots(1, 3, figsize=(15, 4))




for ax, col in zip(axes, ["Pclass", "Sex", "Embarked"]):
    df.groupby(col)["Survived"].mean().plot(kind="bar", ax=ax)
    ax.set_title(f"Survival Rate by {col}")
    ax.set_ylabel("Survival Rate")

plt.tight_layout()
plt.show()
```

読み取ること

- `groupby` 後の平均は、グループ別生存率として読む
- 客室クラス・性別で生存率はどう違うか
- 乗船港は、他の変数と関係していそうか

実行結果：カテゴリ変数と生存率



実行結果：生存率の数値表

Survival rates by categorical variables

Variable	Level	Survival rate
Pclass	1	63.0%
Pclass	2	47.3%
Pclass	3	24.2%
Sex	female	74.2%
Sex	male	18.9%
Embarked	C	55.4%
Embarked	Q	39.0%
Embarked	S	33.7%

読み取りポイント

- Pclass は1等ほど生存率が高い
- Sex は女性の生存率が大きく高い
- Embarked は単独で因果を断定しない
- Embarked=C の高さは Pclass と関係している可能性がある

「生存率が高い」から「原因である」とは言わない。相関・交絡の可能性を確認する。

数値変数の分布

Age と Fare の分布を、生存者と非生存者で比較する。


```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

for ax, col in zip(axes, ["Age", "Fare"]):
    df[df["Survived"] == 0][col].hist(
        ax=ax, alpha=0.5, label="Not Survived", bins=30
    )
    df[df["Survived"] == 1][col].hist(
        ax=ax, alpha=0.5, label="Survived", bins=30
    )
    ax.set_title(f"{col} by Survival")
    ax.legend()

plt.tight_layout()
plt.show()
```

箱ひげ図や相関行列は、発展確認とする。

実行結果：数値変数の分布



読み取りポイント

- Age は欠損補完前なので、欠損の扱いにも注意
- Fare は右に長い分布で、外れ値がある
- 前処理やモデル評価に進む前に、数値変数の形を確認する

AI演習1 可視化の読み取り

AIに次のように聞いてよい。

Titanicデータで、Pclass, Sex, Embarkedごとの生存率を棒グラフで確認しました。それぞれのグラフから読み取るべき統計的な観点を、レポート用に箇条書きで説明してください。ただし、因果関係だと断定しない表現にしてください。

検証すること

- グラフとAIの説明が一致しているか
- 「相関」と「因果」を混同していないか
- 数値を勝手に作っていないか

演習3

前処理してモデルに入れられる形にする

最小限の前処理

今日は時間を優先し、次の処理に絞る。

```
df_work = df.copy()

# 欠損値処理
df_work["Age"] = df_work["Age"].fillna(df_work["Age"].median())
df_work["Embarked"] = df_work["Embarked"].fillna(df_work["Embarked"].mode()[0])

# 今回は使わない列を削除
df_work = df_work.drop(columns=["PassengerId", "Name", "Ticket", "Cabin"])

# カテゴリ変数の数値化
df_work["Sex"] = df_work["Sex"].map({"male": 0, "female": 1})

# EmbarkedはCを基準に、Q/Sの0/1列を作る
df_work = pd.get_dummies(df_work, columns=["Embarked"], drop_first=True, dtype=int)

df_work.head()
```

実行結果：前処理後のデータ

`df_work.head(): after preprocessing`

Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked_Q	Embarked_S
0	3	0	22.0	1	0	7.25	0	1
1	1	1	38.0	1	0	71.2833	0	0
1	3	1	26.0	0	0	7.925	0	1
1	1	1	35.0	1	0	53.1	0	1
0	3	0	35.0	0	0	8.05	0	1

確認すること

- 文字列のままでは `LogisticRegression` に入れない
- `Embarked_Q`, `Embarked_S` は0/1のダミー変数
- `drop_first=True` なので `c` は基準カテゴリとして列を作らない

数値化の考え方

Sex

2値なので、`male=0`, `female=1` のようにしてよい。

Embarked

`c`, `q`, `s` は文字列なので、そのままではモデルに入れない。
今回は `c` を基準にして、`Embarked_Q`, `Embarked_S` という0/1列を作る。

Pclass

1等、2等、3等には順序がある。
ただし「3等が1等の3倍」という意味ではない点に注意する。

説明変数が8列になる理由

元データは12列だが、すべてを説明変数に使うわけではない。

扱い	列
目的変数	Survived
今回使わない	PassengerId , Name , Ticket , Cabin
そのまま使う	Pclass , Sex , Age , SibSp , Parch , Fare
0/1列に変換	Embarked → Embarked_Q , Embarked_S

そのまま使う6列と、Embarked から作る2列を合わせて、モデルに入れる説明変数は $6 + 2 = 8$ 列になる。

演習4

分類モデルを作り、評価する

説明変数と目的変数

```
X = df_work.drop("Survived", axis=1)
y = df_work["Survived"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

print(X_train.shape, X_test.shape)
```

今日は授業時間内で分析の流れを確認するため、訓練データとテストデータの2分割にする。

`test_size=0.2` なので、およそ8割で係数を推定し、残り2割で評価する。

実行結果：訓練データとテストデータ

(712, 8) (179, 8)

確認すること

- 712件を学習に使う
- 179件を評価に使う
- 説明変数は8列になっている（前のスライドの内訳を確認）

ロジスティック回帰の考え方

今回の目的変数 `Survived` は、 `0=死亡` , `1=生存` の0/1変数である。

最小二乗法の回帰	ロジスティック回帰
連続値を予測する	<code>1</code> になる確率を予測する
実測値との差が小さくなるように係数を決める	実際の0/1を説明しやすい確率になるように係数を決める
予測値は任意の数値	予測値は0から1の確率

ロジスティック回帰では、生存確率が0.5以上なら `1=生存` と判定する。

ロジスティック回帰

ここでは理論の詳細には踏み込まず、X_trainで係数を推定し、X_testで予測結果を確認する。

```
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)

pred = model.predict(X_test)

print("正解率:", accuracy_score(y_test, pred))
print("混同行列:")
print(confusion_matrix(y_test, pred))
print("分類レポート:")
print(classification_report(y_test, pred))
```

確認すること

- 正解率はどれくらいか
- 生存者と非生存者のどちらを間違えやすいか
- 正解率だけで十分か

実行結果：モデル評価の要約


Logistic regression result

Metric	Value
Train rows	712
Test rows	179
Accuracy	0.8045
TN	98
FP	12
FN	23
TP	46

Classification report

Class	Precision	Recall	F1-score	Support
0	0.81	0.89	0.85	110
1	0.79	0.67	0.72	69
accuracy			0.80	179
macro avg	0.80	0.78	0.79	179
weighted avg	0.80	0.80	0.80	179

実行結果：混同行列



読み取りポイント

- 正解率は0.804
- 生存者の再現率は $46 / (46+23) = 0.67$
- 死亡者は比較的よく拾えている
- 正解率だけでなく、どちらの誤りが多いかを見る

混同行列の読み方

Titanicでは、1=生存 を陽性とみなす。

	予測0：死亡	予測1：生存
実際0：死亡	TN	FP
実際1：生存	FN	TP

重要な問い

- 生存と予測した人は、どれくらい実際に生存していたか
- 実際に生存した人を、どれくらい拾えているか
- どちらの誤りが問題になる場面か

係数を見て解釈する

モデルがどの特徴量を生存確率と結びつけているかを確認する。

```
coef_df = pd.DataFrame({  
    "Feature": X.columns,  
    "Coefficient": model.coef_[0]  
}).sort_values("Coefficient", ascending=False)
```

coef_df

解釈の例

- 係数が正：生存確率を上げる方向
- 係数が負：生存確率を下げる方向
- 係数の大小は、特徴量のスケールにも影響される


「なぜその特徴量が効いているのか」を、データの背景と結びつけて説明する。

実行結果：係数表

Logistic regression coefficients

Feature	Coefficient
Sex	2.560
Embarked_Q	0.278
Fare	0.002
Age	-0.039
Parch	-0.072
SibSp	-0.244
Embarked_S	-0.382
Pclass	-1.092

実行結果：係数の可視化



読み取りポイント

- Sex が大きく正：女性を1にしたため、生存と予測されやすい方向
- Pclass が負：値が大きい3等ほど、生存と予測されにくい方向
- Fare は正だが係数は小さい。スケールの影響に注意
- 係数は因果を示すものではない

AI演習2 評価結果の説明を確認する

AIに次の材料を渡す。

Titanicデータでロジスティック回帰を実行しました。 正解率、混同行列、分類レポートを下に貼ります。 レポート用に、結果の要点と注意点を説明してください。 ただし、数値を勝手に補わないでください。

検証すること

- 貼っていない数値をAIが作っていないか
- 「予測に効いた」と「原因である」を混同していないか

授業課題

Titanicの分析の型を、別データへ移す

共通課題：Bank Marketing

UCI Machine Learning Repository の Bank Marketing データを使う。

データの概要

項目	内容
出典	UCI Machine Learning Repository
対象	ポルトガルの銀行の電話マーケティング
行数	45,211件
入力変数	16列（数値・カテゴリ）
目的変数	y：定期預金を契約したか（yes/no）

出典：<https://archive.ics.uci.edu/dataset/222/bank%2Bmarketing>

Bank Marketingで考えること

Titanicで確認した流れを、Bank Marketingに移して考える。

主な問い

- 契約した顧客と契約しなかった顧客には、どのような違いがあるか
- `job`, `marital`, `education`, `housing`, `loan` は契約率と関係しているか
- 数値変数 `age`, `balance`, `duration`, `campaign` の分布はどう違うか
- ロジスティック回帰で `y=yes` をどの程度見つけられるか

マーケティング結果の予測では、どの誤りが問題になるかを考える。契約見込み客を見逃すことと、契約しない人に連絡することは、同じ意味ではない。

Bank Marketingで注意すること

Titanicと同じ手順で進められるが、注意すべき点は少し違う。

観点	注意点
目的変数	y=yes は少数派なので、正解率だけでは評価しない
欠損値	欠損値はない扱いだが、 unknown というカテゴリがある
カテゴリ変数	job , education , month などはダミー変数化する
duration	通話後に分かる値なので、予測目的によっては使わない方がよい
解釈	係数は因果ではなく、モデル上の関連として読む

AIに前処理案を出させても、どの列を使うべきかは分析目的から判断する。

学生が探すデータの条件

授業課題では、Bank Marketingに加えて、自分でも分析対象データを探す。

条件

- 公開データである
- CSV、Excel、Google Sheetsなどで読み込める
- 200行以上、5列以上を目安にする
- 目的変数にできる列がある
- 出典URLと利用条件を示せる
- 個人を特定できる情報や非公開情報を含まない

自分の研究データを使ってもよいが、個人情報・未公開情報・共同研究先の機密情報を含むものは使わない。

データ候補メモに書くこと

Google Classroomには、Colabリンクに加えて、データ候補メモを書く。

項目	書く内容
データ名	例：Bank Marketing
出典URL	取得元ページ
行数・列数	<code>df.shape</code> で確認
目的変数	何を予測・説明したいか
主な説明変数	使えそうな列
注意点	欠損、偏り、個人情報、解釈の限界
AI使用記録	何をAIに聞き、何を自分で検証したか

AI演習3 データ候補を評価する

AIに次のように聞いてよい。

この公開データを授業課題で使いたいです。 列名、行数、目的変数候補、出典URLを下に示します。 このデータが、前処理・可視化・ロジスティック回帰の練習に向いているかを確認してください。 ただし、個人情報・バイアス・因果解釈の注意点も挙げてください。

検証すること

- AIが実際には存在しない列や値を作っていないか
- 「予測できる」と「説明できる」を混同していないか
- データの利用条件や個人情報の扱いを見落としていないか

例題の発展課題

次のどれか1つを試す。

1. 決定木 `DecisionTreeClassifier` を使い、ロジスティック回帰と比較する
2. `SibSp + Parch + 1` で `FamilySize` を作る
3. `Age` の欠損値処理を変えて、結果が変わるか試す
4. `Fare` を標準化して、係数の解釈がどう変わるか確認する

記録すること

- なぜそれを試したか
- 結果はどう変わったか
- その原因をどう考えるか

振り返り

AIを使った分析を、自分で説明できる形にする

最後に書くこと

コードセルの実行結果を残した上で、ノートブックの最後に次の5点を書く。

1. 今日の分析で分かったこと
2. 前処理で迷ったこと
3. AIが役に立った場面
4. AIの出力を検証した場面
5. 次に分析したい公開データの候補

提出前チェック

- すべてのコードセルを上から順に実行した
- グラフや表がノートブック内に表示されている
- 結果の分析をテキストセルに書いた
- データ候補の出典URLと選定理由を書いた
- Colabの共有リンクをGoogle Classroomに提出した

振り返りコメントの例

「AIは欠損値補完の候補を挙げるのに役立った。ただし、Cabin列を補完すべきと提案したため、欠損率を自分で確認し、今回は削除する判断に修正した。」

「次の分析対象としてBank Marketingデータを選んだ。目的変数が yes/no の二値で、Titanicと同じように分類問題として扱えるためである。ただし、duration は通話後に分かる値なので、予測の目的によっては使わない判断が必要だと考えた。」

今日の確認ポイント

今日の授業では、次を確認する。

- データ読み込みから評価までの流れを追えるか
- Pythonのエラー原因を切り分けられるか
- AIへの質問が具体的に書けるか
- 可視化結果を自分の言葉で読めるか
- 正解率・混同行列を説明できるか
- 公開データを分析しやすさの観点から選べるか

提出ノートブックでは、コードの実行結果だけでなく、判断理由、AI出力を確かめた過程、次に分析したいデータ候補を書く。

まとめ

今日の要点：

1. データ分析は、前処理、可視化、モデリング、評価、解釈の流れで進む
2. Titanicデータは、分析手順を確認するための例題として使える
3. AIはコード作成や説明に役立つが、数値・定義・解釈は自分で検証する
4. モデルの評価では、正解率だけでなく混同行列も見る
5. Bank Marketingや自分で探した公開データにも、同じ分析の型を使ってみる

次回

AIを用いた分析結果の説明・レポート化を扱う

実行結果まとめ：Titanic例題の基準値

項目	値
行数・列数	891行・12列
生存率	38.4%
Age 欠損	177件 (19.9%)
Cabin 欠損	687件 (77.1%)
Embarked 欠損	2件 (0.2%)
テストデータ正解率	0.804
混同行列	[[98, 12], [23, 46]]