

データ分析と可視化

情報論 2025 第9回 — AI活用(7)

情報科学専攻 | 松野 裕

2025年6月17日 (対面授業・100分)

本日のアジェンダ

時間	内容
10分	研究におけるデータ分析
25分	AIを使ったデータ分析
20分	AIを使ったデータ可視化
50分	演習

研究におけるデータ分析の重要性

データ分析が必要な場面

- **実験結果の解釈** — 得られた数値に意味はあるか
- **仮説の検証** — 統計的に有意な差があるか
- **論文の説得力** — 適切な図表で結果を示す

大学院生が直面する課題

- 統計手法の選択が分からない
- Pythonでの実装に時間がかかる
- 論文品質のグラフ作成が難しい

AIはこれらの課題を解決する **強力なパートナー** になる

AIがデータ分析をどう変えるか

従来のやり方

- 統計の教科書を調べる
- コードを一から書く
- グラフの体裁を手動で調整
- 結果の解釈に自信がない

AI活用のやり方

- AIに適切な手法を相談
- AIがコードを生成
- AIが論文品質のグラフを生成
- AIに結果の解釈を支援してもらう

AIを使ったデータ分析

各ステップでのAI活用法

データ分析ワークフロー

1. データ準備（読み込み・前処理）



2. 探索的データ分析（EDA）



3. 統計処理（検定・回帰等）



4. 可視化（グラフ作成）



5. 解釈（結果の意味を考える）

各ステップでAIを活用できる。順番に見ていきましょう

Step 1: データの理解と前処理

プロンプト例

以下のCSVデータの各列の概要を分析するPythonコードを書いてください。

- データ型
- 欠損値の数と割合
- 基本統計量（平均、中央値、標準偏差、最小値、最大値）
- ユニークな値の数

pandasを使用してください。

前処理で確認すべきこと

- 欠損値の処理方法（削除 or 補完）
- 外れ値の検出
- データ型の確認と変換

Step 2: 探索的データ分析 (EDA)

プロンプト例

このデータセットの相関関係を分析し、重要な知見を抽出するPythonコードを書いてください。

- 相関行列の計算とヒートマップ
- 各変数間の散布図マトリクス
- 分布の確認（ヒストグラム）

seabornとmatplotlibを使用してください。

EDAで分かること

- 変数間の関係性
- データの分布の特徴
- 分析方針のヒント

Step 3: 統計的検定

プロンプト例

2群のデータに有意差があるか検定するPythonコードを書いてください。正規性確認（Shapiro-Wilk）→ t検定 or Mann-Whitney U検定、有意水準0.05、効果量（Cohen's d）も計算。scipyを使用。

ポイント

- 検定手法の選択理由をAIに説明させる
- 多重検定の補正（Bonferroni等）を忘れない

AIを使ったデータ可視化

効果的なグラフ作成と論文品質

効果的なグラフ作成のポイント

目的に合ったグラフの選択

目的	適切なグラフ
値の比較	棒グラフ
時系列変化	折れ線グラフ
分布の確認	ヒストグラム、箱ひげ図
相関関係	散布図
多変量	ヒートマップ、ペアプロット

グラフデザインの原則

- **色使い**: カラーユニバーサルデザインを意識
- **ラベル**: 何を示しているか一目で分かる
- **シンプルさ**: 不要な装飾を排除

matplotlib/seabornでの可視化

プロンプト例

論文掲載品質の棒グラフをmatplotlibで作成してください。ハッチング使用（白黒対応）、フォント：タイトル14pt/軸12pt/目盛り10pt、サイズ：8x6cm、300dpi、エラーバー付き、PDF保存

AIに具体的な要件を伝えることで、論文にそのまま使えるグラフが得られる

論文品質のグラフに必要な要素

チェックリスト

- **軸ラベル**（単位を含む） / **凡例**（位置は適切か）
- **フォントサイズ**（印刷時に読めるサイズ）
- **解像度**（300dpi以上） / **適切なアスペクト比**
- **白黒対応**（ハッチング、マーカー形状で識別）
- **エラーバー**（標準偏差 or 標準誤差 or 信頼区間）
- **タイトル**（図番号とキャプション）

出力形式

- 論文投稿: **PDF** or **EPS**（ベクター形式）
- プレゼン: **PNG**（300dpi以上）

インタラクティブ可視化

データ探索にはインタラクティブツールが有効

Plotly — Webブラウザで動くインタラクティブなグラフ

以下のデータでPlotlyを使ったインタラクティブな散布図を作成してください。

- ホバーで各点の詳細情報を表示
- ズーム・パン機能
- 色でカテゴリを区別

Bokeh — 大規模データの可視化に適している

使い分け

- **探索段階**: Plotly、Bokeh（インタラクティブ）
- **論文掲載**: matplotlib、seaborn（静的・高品質）

演習

計50分

AI演習 演習1: データをAIで分析 (20分)

サンプルデータ or 自分の研究データを分析

1. データを読み込み、基本統計量を確認
2. 探索的データ分析 (EDA) を実施
3. 必要に応じて統計的検定を実行

Gemini Proへの依頼手順

- Step 1: 「このCSVデータの概要を教えてください」
- Step 2: 「相関関係を分析するコードを書いてください」
- Step 3: 「〇〇と△△に有意差があるか検定してください」

自分の研究データがある人はぜひそれを使いましょう

AI演習 演習2: 論文品質のグラフを3種類作成 (20分)

以下のグラフを作成

1. **棒グラフ** (エラーバー付き、白黒対応)
2. **散布図** (回帰直線付き、相関係数表示)
3. **箱ひげ図** (群間比較、有意差マーク付き)

要件

- 論文掲載品質 (300dpi、適切なフォントサイズ)、白黒印刷でも識別可能

AI演習 演習2: ヒント

グラフ作成のコツ

AIに「論文に掲載できる品質で」と明示的に指示する

- 軸ラベル・凡例・タイトルを必ず含める
- 白黒対応にはハッチングやマーカー形状の変更を指示

AI演習 演習3: AIにグラフの解釈を説明させる (10分)

手順

1. 作成したグラフと数値結果をAIに渡す
2. 「このグラフから読み取れることを説明してください」と依頼
3. AIの解釈を読み、**自分の言葉で修正**する

重要

- AIの解釈は**あくまで参考**。研究の文脈を踏まえた解釈は**自分で行う**
- 論文では自分の言葉で結果を記述する

AIを使ったデータ分析の落とし穴

注意すべき3つのポイント

1. 統計的な誤解

- 相関と因果の混同 / 有意水準の誤った解釈

2. 過学習

- データに合いすぎるモデルは汎化しない。検証データで評価する

3. p値ハッキング

- 有意差が出るまで分析条件を変えるのは不正。事前に分析計画を立てる

AIは道具。正しく使うかどうかは研究者の倫理観にかかっている

課題

提出物

1. **データ分析レポート**（使用データの説明・分析手法と結果・考察）
2. **論文品質のグラフ3つ**（白黒対応、300dpi以上）
3. **使用したプロンプトの記録**

データ

- 自分の研究データを推奨。なければ配布サンプルデータを使用

提出期限: 次回授業（6/24）まで

次回予告

第10回: 研究の新規性分析とポートフォリオ (6/24)

- AIを使って **自分の研究の新規性** を分析・言語化する
- これまでの授業の成果物を統合した **研究ポートフォリオ** を作成
- GitHubリポジトリで **ポートフォリオを公開**

準備

- 自分の研究に関連する **先行研究を2-3本** リストアップ
- 今回作成したグラフを持参