


ニューラルネットワークの基礎

ニューラルネットワークは人間の脳の神経細胞（ニューロン）を模倣した機械学習モデルです。入力層、隠れ層、出力層の3層構造を基本とし、重みとバイアスによって情報を伝達・変換します。この仕組みにより、コンピュータが複雑なパターンを学習できるようになります。




ニューロンの計算モデル

ニューラルネットワークの基本単位であるニューロンは、以下の要素で構成されます：

- 入力ベクトル $\mathbf{x} = (x_1, \dots, x_d)$
- 重みベクトル $\mathbf{w} = (w_1, \dots, w_d)$
- バイアス b

総入力は次の式で計算されます：

$$z = \mathbf{w}^T \mathbf{x} + b = \sum_{j=1}^d w_j x_j + b$$



NETRORON



活性化関数

活性化関数の役割

総入力 z に非線形変換を適用することで、ネットワークが複雑な関数を学習できるようにします。

シグモイド関数

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

出力値は $a = \sigma(z)$ となり、0 から1の範囲の値をとります。

その他の活性化関数

- ReLU: $f(z) = \max(0, z)$
- tanh: $f(z) = \tanh(z)$

多層パーセプトロン (MLP)

多層パーセプトロンは複数の隠れ層を持つニューラルネットワークです。各層のニューロンは前の層の全ニューロンと接続しています。情報は入力層から隠れ層を通じて出力層へと伝播し、複雑なパターンを学習できます。




順伝播の数式

情報が入力層から出力層へと伝わる「順伝播」のプロセスは以下の数式で表されます：

$$a_i^{(l)} = \sigma \left(\sum_j w_{ij}^{(l)} a_j^{(l-1)} + b_i^{(l)} \right)$$

ここで：

- $a_i^{(l)}$ は層 (l) のニューロン (i) の出力
- $w_{ij}^{(l)}$ は層 $(l-1)$ のニューロン (j) から層 (l) のニューロン (i) への重み
- $b_i^{(l)}$ は層 (l) のニューロン (i) のバイアス
- $a_j^{(0)} = x_j$ (入力層)



学習の目的と誤差関数

目標と予測

目標値 $\{t_n\}$ と予測値 $\{y_n\}$ の差を最小化することが学習の目的です。

平均二乗誤差 (MSE)

$$L = \frac{1}{N} \sum_{n=1}^N (t_n - y_n)^2$$

データ点 $\{N\}$ 個についての予測誤差の平均を計算します。

パラメータ最適化

誤差関数 $\{L\}$ を最小化する重みとバイアスを見つけることが目標です。



誤差逆伝播法（バックプロパゲーション）

誤差逆伝播法は、ニューラルネットワークの学習アルゴリズムの核心部分です。出力層での誤差を計算し、それを入力層に向かって「逆方向」に伝播させながら各パラメータの勾配を計算します。

出力層の誤差計算

予測値と目標値の差から誤差を計算

勾配の逆伝播

誤差を各層に逆向きに伝え、各重みの誤差への寄与を計算

パラメータ更新

$$w_{\text{new}} = w_{\text{old}} - \alpha \frac{\partial L}{\partial w}$$

(α)は学習率

まとめ

非線形関数の近似器

ニューラルネットワークは複雑な非線形関数を近似できる強力なモデルです。

学習による性能向上

重みとバイアスを調整することで、様々なタスクに対する性能を向上できます。

複雑な問題解決

多層構造により、画像認識や自然言語処理など複雑な問題も解決できます。

今後の発展も目覚ましく、さらに高度なアーキテクチャやアルゴリズムが研究されています。実践的な応用に向けてさらなる探求が期待されます。

