

DAD-3DHeads

単一画像からの高密度・高精度・多様な
3Dヘッドアライメントのための大規模データセット

情報科学専攻 5015 本郷羽琉

背景と課題

3D 顔分析の社会的ニーズの高まり

顔認識・検出、VR/ ゲーム向け3D アバター、吹き替え用の顔再演出、仮想試着、医療用セグメンテーションなど、様々な分野での応用が急速に拡大している

データ収集の限界

従来の3D モーフィングモデル(3DMM)は、高価な3D スキャン装置による限られたサンプルサイズでしか構築できず、多様性に乏しい

実環境での一般化の課題

3D 取得デバイスは任意の条件下で動作できないため、実世界の多様な環境（ポーズ、照明、表情、オクルージョン）に対応できるなデータセットが不足している

※オクルージョン：ある物体が別の物体を隠す状態

目的と貢献

高品質データセット

DAD-3DHeads : 3,500 点以上の検証済み高精度ランドマークを持つ高密度・高精度・多様な3D 頭部データセット。様々な顔の向き、表情、オクルージョン、照明条件を含む実環境データ

新しい損失関数

形状再構成と姿勢推定を同時に学習する新しいアプローチ。Shape+Expression Loss と Reprojection Loss の2つの損失成分を最適化し、豊富なアノテーションを活用

高性能モデル

DAD-3DNet : 入力画像からFLAME トポロジーに一貫した3Dメッシュ表現へのマッピングを行うモデル。3DMM パラメータを回帰し、微分可能なFLAME デコーダで3D 頭部形状を復元

新しい評価基準

3D 密な頭部フィッティングの定量的評価のための新しいベンチマーク。Reprojection NME と Z_r Accuracy という2つの新しい評価指標を導入

既存研究の限界

高精度な教師データの不足

- 実際の写真に近い画像に対して、正確な3Dの顔データがほとんどない
- 既存のデータは管理された環境（スタジオなど）で撮られたものが多く、ラベルも粗い
- 表情・角度・顔の特徴の多様性が足りず現実の状況にうまく対応できない

統計的3D形状モデルへの過度な依存

- 多くの方法が、少ないデータから「平均的な顔の形」を統計的に学ぶ手法（3DMM）を使っている
- その結果、変わった形の顔や複雑なポーズに弱くなってしまう
- 現実世界のようなバラバラな条件には対応しきれない

複雑な状況への対応の弱さ

- 頭を大きく傾けたり、笑ったり怒ったり
- といった動きにうまく対応できない
- 目や鼻が髪やマスクで隠れると、正しく顔の形を推定できない

データセットの特徴

DAD-3DHeads は、実環境における高密度・高精度・多様な3D 頭部アライメントのための大規模データセット

3,500 点以上の高精度な3D ランドマークを含み、頭部の姿勢、表情、オクルージョンなど多様な属性情報を網羅している

高密度

3,500 点以上の高精度な3D ランドマークを含みます。頭部の表面を詳細に捕捉し、高密度な教師データを提供します。

高精度

アノテーション精度を検証した結果、Median Error が1.109mm と高く精度が保証されています。既存のSOTA 手法よりもGround Truth に近い精度を達成。

多様

頭部の姿勢、表情、オクルージョン、性別、年齢層、照明条件など、実環境での汎化性能評価に適した多様な属性情報を網羅しています。

総画像数

44,898 枚

学習	37,840 枚
検証	4,312 枚
テスト	2,746 枚

3D メッシュ


5,023 頂点

うち、3,669 点 が高精度ランドマーク

属性

- 頭部の姿勢
- 表情
- オクルージョン
- 性別
- 年齢層

画像の分布



データセットの特性

- 画像は、様々なパターンで撮影されたもの
- 多様な姿勢と表情を網羅
- 顔や頭の一部が髪・手・マスク・帽子などで隠れている画像も含まれている




Figure 3. **Dataset Properties:** DAD-3DHeads is well balanced over a wide range of poses, face expressions, and occlusions. The attribute labels are a valuable signal for subgroup analysis and for generalization to in-the-wild deployment conditions.

アノテーション手法

ステップ1：ピン留め

アノテーターは 3Dメッシュ表面の特定のポイントを画像上の対応するピクセルに「ピン留め」し、位置を固定する。これにより、3Dモデルと 2D画像の間の空間的対応関係が確立される


ステップ2：最適化

ピン留めされたポイントの再投影誤差を最小化するように 3DMMパラメータが最適化される。これにより、顔の形状や表情、ポーズが調整され2D画像に合致するようになる

ステップ3：テクスチャ確認

ラベルは 3Dメッシュ上にレンダリングされたテクスチャを確認し、結果の視覚的な妥当性を検証する。顔の特徴や頭蓋の境界が正確であることを確認し、相対的な深さ情報が画像と一致するかを確認する

3.1. Data acquisition




アノテーションの特徴

- 3D ランドマーク (3,669 点)
- 首や眼球を除いた頭部ランドマーク
- 多様な画像を対応

アノテーション精度の検証


3D スキャナデータと比較して、DAD-3DHeads のアノテーション精度を検証

NoW データセット




16% の改善

Stirling データセット



2.4% の改善

BIWI 姿勢推定



35% の改善

精度検証の結論

NoW データセット: DAD-3DHeads の中央値誤差は 1.109mm で、既存手法よりも16% 改善

Stirling データセット: 3DRMSE が2.488mm で、既存手法よりも 2.4% 改善

BIWI 姿勢推定: 角度誤差が6.037° で、既存手法よりも35% 改善

DAD-3DNet : モデルアーキテクチャ




Figure 6. **DAD-3DNet architecture design** and model training benefit from the rich annotations in a multi-branch setup. The Gaussian heatmap estimator predicts coarse locations of the head landmarks. The fusion block combines the coarse heatmap, BiFPN feature map, and CNN encoder output to regress a set of 3D head model parameters and finer locations of head landmarks.

CNN エンコーダ
画像から特徴を抽出



ヒートマップ推定
BiFPN による2D ランドマ
ーク位置の粗い予測



融合モジュール
ヒートマップとエンコーダ
特徴を融合



回帰モジュール
詳細なランドマークと
3DMM パラメータを予測



FLAME レイヤー
3DMM ベクトルを3D メッ
シュ頂点にマッピング

損失関数

L_3^D : 形状・表情損失

$$L_{3D} = \frac{1}{N} \sum_{i=1}^N \|\hat{v}_i - v_i\|_2^2$$

3D 頭部形状の適合度を測定する損失関数。正規化された3D 頂点を使用して、形状と表情の情報をポーズ情報から分離し、正確な頭部形状を学習させる

L_{proj} : 再投影損失

$$L_{proj} = \frac{1}{K} \sum_{i=1}^K \|\Pi(R \cdot v_i + t) - p_i\|_1$$

3D メッシュを2D 画像平面に再投影する際の誤差を最小化。高密度な2D ランドマークに基づき、頭部ポーズの精度を評価し、2D-3D 整合性を確保する

L_1 : L1 正則化損失

$$L_1 = \|\hat{p} - p\|_1$$

予測されたモデルパラメータと真のパラメータ間の絶対誤差を最小化。過学習を防ぎ、安定したパラメータ推定を実現するための正則化として機能する

L_{AWing} : 適応型Wing 損失

$$L_{AWing} = \begin{cases} w \ln(1 + |\frac{y-\gamma}{\epsilon}|^{\alpha-\gamma}) & \text{if } |y-\gamma| < \vartheta \\ A|y-\gamma| - C & \text{otherwise} \end{cases}$$

ランドマーク予測のための特殊な損失関数。小さな誤差と大きな誤差を異なる重みで扱い、特に顔の輪郭や細部の精度向上に効果的

実験設定

評価タスク

3D顔ランドマークの精密な位置合わせ

DAD-3DHeadsデータを使って、どこまで正確に顔の形を再現できるかを検証

頭の向きの推定

既存のデータセット（AFLW2000-3D、BIWI）を使って、顔の向きの認識力を比べる

3D顔の形を再現できるか

NoWなどのベンチマークで、3Dメッシュの正確さを評価

評価指標

Reprojection NME

画像上で予測した顔の点が、正しい位置からどれくらいズれているか

Zn Accuracy

顔の奥行き（Z軸）の関係が、正しいかどうか

Chamfer Distance

予測した3D形状と、本物の形がどれだけ違うか

Pose Error

顔の向き（回転角度）が、どれくらいズれているか

比較対象

RingNet

顔の形を3Dで再現する代表的な方法

3DDFA-V2

高精度な3D顔認識の有名モデル

Img2Pose

顔の向き（姿勢）を専門に推定する手法


SynergyNet

姿勢推定に強い手法

実験結果：3D 頭部アライメント性能

DAD-3DHeads テストセットを用いて、DAD-3DNet と既存のSOTA 手法の性能を比較した

各手法の性能比較



Reprojection NME

値が低いほど良い

2.302

従来比 36% 改善

Zn Accuracy

値が高いほど良い

0.954

従来比 8% 改善

Chamfer Distance

値が低いほど良い

3.178

従来比 38% 改善

Pose Error

値が低いほど良い

0.138


従来比 68% 改善

解釈

DAD-3DNet は、全ての評価指標において既存手法を大幅に上回る性能を達成。特に姿勢の正確さを示すPose Error が著しく改善されている。これは、高密度な教師データによる学習の有効性を示している

実験結果：汎化性能評価

DAD-3DNet が未知のデータセットに対しての汎化性能を評価した 各ベンチマークでの性能を以下に示す



未知データセットでの性能

- BIWI 姿勢推定: **MAE 3.98°**
- AFLW2000-3D 姿勢推定: **MAE 3.66°**
- NoW 形状復元: 平均誤差 **1.541mm**
- Feng et al. 形状復元: **3DRMSE 2.749**

結果の意義

DAD-3DNet は、学習に用いていない複数の標準的なベンチマークにおいても、各タスクのSOTA 手法に匹敵する、あるいはそれを上回る高い性能を達成した。これは、DAD-3DHeads データセットの多様性と品質が、モデルに高い汎化能力を与えたことを意味する。

要因分析

DAD-3DNet の性能向上に貢献した要素を分析 損失関数の各コンポーネントを追加した時の性能改善を示す

頭部全体のランドマーク

頭部全体のランドマークを再投影損失に用いることで、姿勢(Pose) と奥行き(Zn Acc.) の精度を大幅に向上させた

Ablation Study 行3: + 頭部全体の再投影損失 → Zn Acc. が 0.943 に改善

形状+ 表情損失


正規化された3D 頂点を用いる形状+ 表情損失が、姿勢推定精度をさらに改善した

Ablation Study 行4: + 形状+ 表情損失 → Pose が 0.139 に改善

マルチタスク学習

ランドマーク予測を同時に行うマルチタスク学習が、全ての指標を改善し汎化性能向上に貢献した

Ablation Study 行5: + ランドマーク予測ヘッド → 全ての指標が最良値に達成



結論と今後の展望

結論

- 高密度な3D ランドマークによる直接的な教師あり学習の有効性を実証
- DAD-3DHeads データセットと DAD-3DNet モデルにより、3D 頭部復元の精度と頑健性を大幅に向上
- 実環境における多様な頭部（姿勢、表情、オクルージョン）への対応能力を向上

今後の展望

- 本研究が提供するデータセットとベンチマークが、この分野の今後の研究を加速させることが期待
- 高密度な3D ランドマークと教師あり学習を活用した、さらに精密な3D 頭部復元モデルの開発
- 実環境での3D 頭部トラッキングやアニメーションへの応用研究の推進