

chatgpt-o4(deep research)で prompt「Non-contrast から contrast-enhanced に変換する深層生成モデルについて調査してください(医用画像)」、「MRI CT モデルは問わない」と入力。

了解しました。モダリティ (MRI、CT など) は問わず、Non-contrast (非造影) から contrast-enhanced (造影) 画像への変換を行う深層生成モデルに関する最新の研究や技術を調査します。

調査結果がまとまり次第、ご報告いたします。

Non-contrast 画像から造影画像への変換：深層生成モデルの現状

背景と目的

医療画像診断では、**造影剤**の使用により臓器や病変のコントラストが向上し、診断精度が高まります。しかし、造影剤の投与には**アレルギー反応**や**腎機能悪化**などのリスクが伴い、高齢者や腎機能低下患者では造影剤使用を避けざるを得ないケースもあります。このため、**非造影画像から造影画像に相当する情報を得ることができれば**、患者の負担軽減や検査効率の向上につながります。近年、ディープラーニングを用いた**画像生成モデル**によって「仮想的な造影画像」を合成する研究が盛んに行われています。本稿では、非造影 MRI・CT 画像から造影効果を持つ画像を生成する深層生成モデルの技術と応用について、主要なアプローチとモダリティ別の研究例、臨床的な有用性、最新の論文動向、および公開データやコードの情報を整理して解説します。

深層生成モデルのアプローチ

深層生成モデルには様々なアーキテクチャがありますが、医用画像の合成では特に **GAN (Generative Adversarial Network)** 系のモデルが広く使われています。例えば、条件付き GAN である **pix2pix** は入力画像からターゲット画像へのマッピングを学習する代表的手法で、エンコーダ・デコーダ型の U-Net ジェネレータと PatchGAN 識別器を備えています。実際、非造影 CT→造影 CT 生成では **3 次元版 pix2pix** のようなモデル構造が用いられ、ジェネレータに 3D U-Net、識別器に 3D PatchGAN を組み込んだ実装例があります。一方、**CycleGAN** のような未対応データ (非ペアデータ) 同士でのドメイン変換手法も、ペア画像取得が難しい場合に利用されています。CycleGAN では**サイクル一貫性損失**を用いて非造影↔造影の双方向に変換モデルを学習し、実際に**造影 CT→非造影 CT**の変換によるデータ標準化などに応用された報告があります。

また、VAE (Variational Autoencoder) は潜在空間から画像を生成するオートエンコーダですが、単独では生成画像がぼやける傾向があり、医用画像の鮮鋭な造影効果再現には不向きとされています。ただし、VAE を GAN と組み合わせた VAE-GAN や CVAE (条件付き VAE) を用いることで、安定した学習と高解像度化を両立する試みもあります。近年急速に注目されている****拡散モデル (Diffusion Models)****も医用画像合成へ応用が進んでいます。拡散モデルはノイズ付加と除去の逐次過程を通じて高品質な画像を生成でき、GAN より安定して学習できる利点があります。実際、****DDPM (Denoising Diffusion Probabilistic Model)**

やスコアマッチングモデルを用いたマルチモダリティ画像変換では、従来の CNN や GAN を上回る精度が報告されており、医用画像においても GAN の代替として拡散モデルを採用する研究が登場し始めています。さらに、2020 年代半ばには、Stable Diffusion** のような事前学習モデルを医用画像領域に微調整し、高解像度な合成造影画像を得る取り組みも現れています。

以上のように、GAN 系 (pix2pix や CycleGAN など) の**敵対的学習**による手法が現在の主流ですが、ネットワーク構造には U-Net や DenseNet、残差ブロック、注意機構など様々な工夫が凝らされています。また、より高品質な合成のため**損失関数**にも工夫がみられ、画素ごとの L1 損失に加えて**知覚的損失**や **SSIM 損失**を組み合わせる例もあります。次節以降では、MRI と CT それぞれのモダリティで代表的な研究例と成果を紹介します。

MRI における非造影 MRI から造影 MRI の生成

MRI では**ガドリニウム造影剤**を用いた T1 強調造影画像が腫瘍の検出・評価に重要ですが、ガドリニウムは脳内への残留や腎機能障害のリスクから使用制限が議論されています。この問題に対し、深層学習で**非造影 MRI から造影後 MRI を再現**する研究が進んでいます。特に脳腫瘍領域では、**多パラメータ MRI** (例: T1 非造影、T2、FLAIR など) から**造影 T1 画像**を合成し、造影剤無しで腫瘍増強効果を得ようという試みが数多く報告されています。代表的な例として、2021 年に Lancet Digital Health で報告された Preetha らの研究があります。彼らは**条件付 GAN (pix2pix) に基づくモデルを開発し、**非造影 T1・T2・FLAIR を入力に造影 T1 の差分画像 (造影前後の差分) **を出力するよう学習しました。損失関数には GAN の識別損失に加え、平均絶対誤差 (MAE) と SSIM (構造的類似指標) を組み合わせ、より造影画像らしい出力を得る工夫がされています。このモデルは glioma (神経膠腫) 患者 2000 例以上 (200 施設超) もの大規模データで検証され、合成画像と実際の造影画像との類似度は約 82%に達し、通常の U-Net による回帰モデル (約 81%) を僅かに上回りました。また、合成画像から算出した腫瘍体積は実測より中央値で 7%程度小さめになる傾向がありましたが、経時的な腫瘍増大の検出 (無増悪生存期間の推定) では実際の造影画像とほぼ同等の結果を示しました。この研究はマルチセンター試験データでモデルを評価し、異なる装置や施設でも適用可能な汎用性を示した点で画期的です。一方で、症例の 28%では合成 vs 実画像で増悪判定が食い違うなど課題も残り、さらなる精度向上が必要と指摘されています。**

こうした腫瘍領域以外にも、脳卒中や認知症研究で**脳血流や血液量マップ**を推定する目的の研究もあります。たとえば Liu ら (2022) は**単一の非造影 MRI から脳血液量 (CBV) のマップ**を予測するモデルを提案し、アルツハイマー病患者の機能異常検出に応用しています。このモデルはマウスとヒトの定常状態造影データで学習後、人間の非造影データに転移学習され、**造影剤なしで高解像度の CBV マップを得る**ことに成功しました。結果として、高齢正常脳や AD 患者の脳で従来造影しなければ見えなかった微細な血流変化の検出に寄与しています。

MRI 領域では他にも、多様なネットワークと工夫が試みられています。Murugesan ら (2024) は **Residual Inception DenseNet** という新しいネットワークを開発し、**脳腫瘍の造影 T1 画像の合成と腫瘍セグメンテーションを同時に行うマルチタスク学習モデル**を報告しました。彼らは Brain Tumor Segmentation Challenge (BraTS 2019) の公開データセット (**多施設 MRI データ**) から 335 例を訓練、125 例を検証に用い、造影 T1 (T1c) 合成と腫瘍輪郭抽出を一段で実現しています。専門医による評価では、88.8%の症例で合成造影画像が「良好～優秀」と判定され、低用量造影の代替や造影剤投与削減に道を開く結果となりました。さらに 2025 年には、肝細胞癌 (HCC) 診断のため**多相ダイナミック造影 MRI**を合成する**安定拡散モデル**が報告されています。図はその研究 (Zhang ら 2025) の模式図で、上段(A)は通常のフルプロトコル MRI (cMRI: T2、拡散強調 DWI、事前 T1、動脈相 AP、門脈相 VP、肝実質相 TP、平衡相 HBP)と、下段は深層学習による短縮プロトコル MRI (DL-aMRI: 造影相は全て**合成**: AP-Syn, VP-Syn, TP-Syn, HBP-Syn)を比較しています。また下段(B)には**安定拡散モデル**の構造が示され、事前 T1 を条件入力とした**潜在空間での拡散モデル** (VQVAE によるエンコード/デコードを含む) で 4 つの造影位相をそれぞれ生成しています。大規模 (3 施設、被験者 1769 名) な検証の結果、**造影無しでも HCC 検出能が従来造影 MRI と同等**であり、検査時間を 28 分から 4 分へ大幅短縮できることが示されました。このように、MRI 分野では**神経領域から腹部領域まで**深層生成モデルの応用が広がり、造影剤リスク低減や検査効率化への貢献が期待されています。

CT における非造影 CT から造影 CT の生成

CT では**ヨード造影剤**が血管や病変の描出に不可欠ですが、腎障害やアレルギーの懸念から造影 CT を実施できない場合があります。特に救急診療や慢性腎不全患者のフォローアップでは**非造影 CT (NCCT)**のみで**診断せざるを得ない**ことも多く、こうした状況で**造影情報を付加するディープラーニング技術**への期待が高まっています。CT 領域でも近年、多くの研究が**非造影 CT から造影効果を合成**することに取り組んでいます。

2018～2020 年頃から初期研究が散見され、例えば Sharma ら (2020)や Dai ら (2020) は GAN に基づくネットワークで脳や腹部の**仮想造影 CT**生成を試みています。2021 年以降、この分野は一層活発化しました。代表例の一つに、Choi ら (2021) の**胸部 CT**に関する研究があります。彼らは非造影胸部 CT から**縦隔リンパ節の描出を改善**する目的で GAN モデル (3D pix2pix に類似)を開発し、**デュアルエナジーCT 由来の仮想非造影画像 (VNC)**と**実際の造影 CT**のペアデータでモデルを訓練しました。その結果、****合成造影 CT (sCECT)**は非造影 CT に比べ画質指標で有意な改善を示し (例: MAE 減少、PSNR 向上、SSIM 向上、LPIPS 減少)、特に**縦隔リンパ節のコントラスト対ノイズ比 (CNR)****が飛躍的に増大しました (6.15 vs 0.74 と約 8 倍)。実際、同じ患者の非造影 CT に合成造影を重ねることで、リンパ節が周囲構造から明瞭に区別できるようになっています。Radiologist による読影実験でも、**合成造影画像を併用**することで**リンパ節検出数が増加**し、**病変の視認性評価が有意に向上**しました。これは特に造影 CT が行えない肺癌患者のリンパ節転移評価に有用

と考えられます。

また、腹部領域では Kim ら（2021）が**救急外来の急性腹症患者** 353 例を対象に、非造影 CT から生成した****合成造影腹部 CT (DL-SCE-CT)****の有用性を検証しています。この研究では paired データで学習したモデルを用い、救急現場で撮影された非造影 CT に造影効果を付加して診断するシミュレーションを行いました。その結果、**熟練医・研修医の双方で診断精度が向上し（Accuracy 最大 50%→62%程度）、特に若手医師において有意な改善が認められました**。診断信頼度も全体の 83%の読影者で向上し、**陰性所見症例や基礎疾患（悪性腫瘍等）を有する症例で恩恵が大きかった**と報告されています。このように、腹部救急でも合成造影 CT が医師の判断を助ける可能性が示唆されています。

2024 年には、Han らが**腹部 CT での大規模弱教師あり学習**の報告を行いました。彼らはデュアルエナジーCT が出力する VNC（仮想非造影像）と造影 CT の完全に位置一致したペア 2,202 例を使いモデルを学習し、別施設の 398 例の非造影 CT に対して合成造影を生成しています。この DL-SynCCT モデルは腹部全般で造影効果を付加するもので、外部検証では**病変検出感度が 72.0%から 76.4%へ有意に上昇し、診断信頼度スコアも 3.0 から 3.6 へ向上しました**。特に**消化管病変の検出感度**が有意に改善しており、造影できない患者の診断補助として有益であることが示されています。一方で注意点も指摘されており、造影血管の一部が合成で十分強調されない「偽非造影化」や、存在しない構造が造影されたように映る「偽造影」などの**アーティファクト**が一部で見られました。これらはデータ上の限界やモデルの過学習によるものと考えられ、特に腎臓や血管周囲での偽造影は課題として残っています。

CT 領域の最新動向としては、**血管造影**への応用も注目されます。Zhang ら（2023）は**非造影 CT から血管構造を強調した CTA 画像を生成する深層学習を試み、「造影剤なしで隠れた血管情報を可視化できる」可能性を報告しました**（Radiology 誌）。これは主に大動脈や動脈系の描出を改善するもので、詳細な結果は今後の発表に委ねられますが、将来的に**脳卒中や心血管救急での迅速な血管評価**に寄与するかもしれません。また、Solak ら（2024）は**大動脈および頸動脈領域**での非造影→造影 CT 変換 GAN を研究し、内部テストで 94%、外部テストで 86%の診断精度を報告しています。このように**血管領域**でも合成造影の有用性が模索されています。

図は胸部 CT における実例で、左(A)が非造影 CT、中央(B)が GAN モデルで生成した合成造影 CT、右(C)が実際の造影 CT です。大動脈や肺動脈の造影効果が合成(B)でもそれなりに再現されており、非造影(A)では判別しにくかった縦隔構造が強調されています。定量的にも、非造影に比べ合成造影の方が実際の造影 CT に近い画質指標を示すことが確認されています。

以上のように、CT 領域では胸部から腹部・血管まで幅広い応用で**深層生成モデルによる合成造影**が研究されています。臨床的には、造影剤使用が難しい患者で診断の質を高めたり、不必要な造影検査を回避したりするツールとして期待されています。実際、上記のような研

究で放射線科医の読影パフォーマンス向上が示されたことは大きな前進と言えます。もっとも、造影情報の完全な再現は容易ではなく、GAN 特有のハルシネーション（幻影）のリスクや、疾患によっては微妙な強調パターンが再現困難なケースもあります。そのため、合成画像の診断への活用には安全性と限界の理解が不可欠であり、今後さらなる改良と検証が求められます。

臨床応用と今後の展望

深層生成モデルによる非造影→造影画像変換は、**診断支援**や**造影剤使用低減**の観点から非常に有望です。特に MRI では、蓄積リスクのあるガドリニウム造影剤を省略できる可能性が示唆されており、脳腫瘍診療のプロトコル見直しや、将来的な**造影剤フリーMRI 検査**の実現につながるかもしれません。CT でも、腎不全患者への造影剤非使用で重要病変を見落とすリスクを低減できるほか、緊急時に造影剤が使えない場面で代替情報を提供することで迅速な治療判断に寄与するでしょう。実際、現在までに**読影者スタディ (observer study) **で有効性が示された例も複数あり（前述の胸部・腹部 CT 研究など）、臨床実装への第一歩が踏み出されています。

しかし、課題も残ります。モデルが出力する**合成造影画像の信頼性**や**再現性**を高めるため、より多様なデータでの学習と外部検証が必要です。また、GAN 系モデルには稀に現実には存在しない構造を「幻影」として描いてしまうリスク（**hallucination**）が知られており、医療応用ではこうした誤情報の検出と制御が重要です。最近のレビューでも、**評価指標の最適化**や**専門医による厳密な検証**を通じて、安全に臨床へ展開するためのガイドライン策定が議論されています。さらに、合成画像を医療判断に用いる際の**責任の所在**や、規制当局の承認プロセスも解決すべき問題です。

技術的には、**拡散モデルの導入**や**マルチタスク学習**による精度向上が今後のトレンドとなるでしょう。拡散モデルは既に一部研究で成果を上げており、GAN の欠点である不安定さを克服しつつ高画質化が期待できます。また、合成と同時に病変検出やセグメンテーションも行う**統合モデル**（例：前述の Murugesan らの RID ネット、Huang ら（2024）の CSS-Net など）により、合成画像が直接診断アウトカムの改善に結びつくアプローチも登場しています。これらは単に「画像を似せる」だけでなく、その先の**臨床意思決定を支援**するところまで AI が踏み込む動きと言えます。

最後に、研究開発を加速するための**データセットとコードの公開**も進みつつあります。MRI 分野では前述の **BraTS** データセット（多施設脳腫瘍 MRI、造影 T1 含む）が広く利用され、また **ADNI** など公開コホートの非造影 MRI を用いた検証報告もあります。CT 分野では十分な公開ペアデータが限られていますが、デュアルエナジーCT が得られる施設では **VNC** と**造影 CT のデータ蓄積**が進んでおり、研究目的で共有される可能性があります。実装面では、Choi らの pix2pix3D-CT モデルのコードが GitHub で公開されており、3 次元医用画像に特化した条件付き GAN の参考実装として活用できます。また、Stable Diffusion など一般画像向け事前学習モデルも公開されており、医学領域への fine-tuning に応用する試みが

誰でも実施可能です。このようなオープンな環境は、新たな研究者が参入し技術を磨く助けとなっています。

結論として、深層生成モデルを用いた非造影から造影画像への変換技術は、ここ数年で急速に発展しつつあり、MRI・CT 双方で有望な成果が蓄積されています。患者の負担軽減と診断精度向上の両立という観点から、その臨床応用価値は非常に高いものがあります。今後は、さらなるモデル改良と包括的な検証によって信頼性を高め、実際の診療ワークフローに組み込まれていくことが期待されます。その際には、医療者と AI の協調による**安全で効果的な活用方法**を確立し、患者にとって最適な医療提供に寄与していくことが重要です。

参考文献：

- Choi JW, et al. *Sci Rep*. 2021 Oct;11:20403
- Kim SW, et al. *Sci Rep*. 2021 Oct;11:20390
- Han S, et al. *Sci Rep*. 2024 Jul;14:17635
- Zhang Y, et al. *JHEP Rep*. 2025 May;7(5):101392
- Preetha CJ, et al. *Lancet Digit Health*. 2021 Dec;3(12):e784-e794
- Murugesan G, et al. *AJNR Am J Neuroradiol*. 2024 Mar;45(3):312-319
- Liu C, et al. *Front Aging Neurosci*. 2022 Aug;14:923673
- Ferles A, et al. *Lancet Digit Health*. 2021 Dec;3(12):e754-e755 (Comment)
- Solak M, et al. *Eur J Radiol*. 2024 Dec (in press)
- Huang X, et al. *Med Image Anal*. 2024 Dec (in press) (CSS-Net)

結果の妥当性

GAN をはじめとする拡散モデルまでの深層生成モデルを使用した研究が紹介されていた。また、定量評価指標についても記述があり、自身の研究との類似点が明らかになった。また、nature などの信頼性の高い学会からの引用がされていた。