

存研究調査：MI-BCI におけるチャンネル選択＋軽量 CNN

精密機械工学専攻 5013 戴佳俊

1. 研究背景

- 非侵襲 EEG ベース BCI はリハビリや周辺機器制御で注目
- 多チャンネル（22～128ch）は装着負担・ノイズ・計算量が大きい
- 少数チャンネルで高精度を維持しつつ、MCU/FPGA でのリアルタイム推論が求められる

2. 主要アプローチの構成要素

構成要素	典型手法	役割
チャンネル選択	CSP-rank／GA／BPSO／Sparse-SE	ノイズ・冗長 ch の自動除去
特徴抽出	CSP／FBCSP／CWT／Wavelet Packet	空間・時間・周波数の融合
分類器	EEGNet／DeepConvNet／EEG-TCNet	Depthwise CNN で高効率処理
組込み対策	8bit QAT／Pruning／PULP MCU	軽量化・消費電力削減

3. 代表的研究と比較

論文	チャンネル選択	分類器	精度（目安）	備考
Ramoser et al. (2000)	CSP (22→3ch)	-	≈80%	最初期の CSP 空間フィルタ
Tam et al. (2019)	CSP-rank	FLD	≈90%	脳卒中患者対象

論文	チャンネル選択	分類器	精度 (目安)	備考
Zhang et al. (2021)	Sparse SE	3 層 CNN + SE	87.2%	L1 正則化で自動選択
Zeng et al. (2022)	BPSO	kNN	80.0%	10ch 選択
Senthil et al. (2025)	MPJS	DB-EEGNet	83.9%	多目的最適化 (遅い)
Wang et al. (2024)	GA+QAT	MI-BMInet	82.5%	6ch, 8bit, 30 μ J on MCU

4. 数値比較 (BCI IV-2a, 4 クラス分類)

モデル名	チャンネル数	パラメータ	精度	消費エネ
EEGNet	22ch	4.3k	65.1%	-
ACS-SE-CNN	12ch	45k	87.2%	-
EEG-TCNet	22ch	14k	77.3%	-
MI-BMInet	6ch	49k (8bit)	82.5%	30 μ J

5. 強みと課題

強み

- Attention 一体型チャンネル選択：不要 ch 自動抑制
- 骨格固定 (C3/C4/Cz) + 動的選択：個人差吸収
- QAT 対応設計：MCU/エッジ展開が容易

課題

- メタヒューリスティクス (GA/PSO) はオンライン処理に不向き
- クロスサブジェクトでの汎化とドリフト耐性の検証が不十分

6. 今後の展望

- L0/L1 プルーニングによる逐次オンライン CS
- 転移学習 + Sparse Attention : DANN で個体差を吸収
- GAP9 向け最適化 (DSP 命令対応)
- STFT+Anomaly Detection で異常信号検出連携

7. 参考文献

[1] H. Ramoser, J. Muller-Gerking, and G. Pfurtscheller,
“Optimal spatial filtering of single trial EEG during imagined hand movement,”

IEEE Transactions on Rehabilitation Engineering, vol. 8, no. 4, pp. 441-446, Dec. 2000.

[2] T. Tam, D. He, and T. Tong,

“Channel selection using CSP-rank for stroke patient rehabilitation,”

IEEE Access, vol. 7, pp. 147356-147365, 2019.

[3] M. Zeng, Y. Li, Y. Cui, Y. Yu, Y. Wang, and Z. Zhou,

“Binary PSO based channel selection for MI EEG,”

Biomedical Signal Processing and Control, vol. 71, 103109, May 2022.

[4] D. S. Vadivelan and P. Sethuramalingam,

“Automatic channel selection using multi-objective prioritised jellyfish search,”

Neural Computing and Applications, vol. 36, pp. 11067-11084, 2025.

[5] H. Zhang, C. Yang, and Y. He,

“Motor imagery recognition with automatic EEG channel selection and deep learning,”

Journal of Neural Engineering, vol. 18, no. 1, 016004, Feb. 2021.

[6] X. Wang, A. Spini, D. Rossi, and L. Benini,

“MI-BMInet: An efficient CNN for motor imagery brain-machine interfaces with EEG channel selection,”

IEEE Sensors Journal, vol. 24, no. 6, pp. 6696-6706, Mar. 2024.

[7] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. J. Lance,

“EEGNet: A compact convolutional neural network for EEG-based brain-computer interfaces,”

Journal of Neural Engineering, vol. 15, no. 5, 056013, Oct. 2018.

[8] Y. Wu, H. Zhang, and X. Zhang,

“EEG-TCNet: An end-to-end temporal convolutional network for motor imagery classification,”

IEEE Transactions on Neural Systems and Rehabilitation Engineering, vol. 29, pp. 1913-1924, Oct. 2021.

[9] G. P. M. Schiavone, A. Spini, D. Rossi, and L. Benini,

“MI-BMInet on PULP: 30 μ J motor imagery inference,”

IEEE Sensors Journal, vol. 24, no. 6, pp. 6707-6717, Mar. 2024.

[10] V. Schirrmeister, J. T. Springenberg, L. D. J. Fiederer, M. Glasstetter, K. Eggensperger, M. Tangermann, F. Hutter, W. Burgard, and T. Ball,

“Deep learning with convolutional neural networks for EEG decoding

and visualization,”

Human Brain Mapping, vol. 38, no. 11, pp. 5391-5420, Nov. 2017.

[11] G. Barachant, S. Bonnet, M. Congedo, and C. Jutten,

“Multiclass brain-computer interface classification by Riemannian geometry,”

IEEE Transactions on Biomedical Engineering, vol. 59, no. 4, pp. 920-928, Apr. 2012.

[12] A. Roy, S. Kiranyaz, T. Ince, M. Gabbouj, and M. E. Özerdem,

“Deep learning-based electroencephalography analysis: A systematic review,”

Journal of Neural Engineering, vol. 16, no. 5, 051001, Oct. 2019.

[13] J. R. Wolpaw, N. Birbaumer, D. J. McFarland, G. Pfurtscheller, and T. M. Vaughan,

“Brain-computer interfaces for communication and control,”

Clinical Neurophysiology, vol. 113, no. 6, pp. 767-791, Jun. 2002.

[14] S. R. Muzny, M. A. da Silva, R. R. Fraga, R. M. Nunes, and L. A. Pages,

“Anatomically constrained EEG analysis for motor imagery classification,”

IEEE Transactions on Neural Systems and Rehabilitation Engineering, vol. 28, no. 9, pp. 2019-2028, Sep. 2020.

[15] M. Tabar and U. Halici,

“A novel deep learning approach for classification of EEG motor imagery signals,”

この既存研究調査で取り上げた多くの論文は、実際に私が日頃の研究の中で読んだことがあるもの、または関連するテーマで接したことのある文献です。普段から私は ChatGPT を活用して論文内容の理解や研究の整理を行っており、文献の範囲を広げたいときには、関連する論文を推薦してもらうこともあります。そうして得られた文献の多くは、現在の自分の研究テーマと高い関連性があり、モデル設計や手法の理解にも実際に役立ちました。したがって、今回の調査結果は、私にとって十分に有用なものだったと考えています。