

心電図を合成する拡散モデルへの XAI の適用に関する研究

A Study on the Application of XAI to Diffusion Models for Synthesizing Electrocardiograms

指導教員 細野裕行 教授, 関弘翔 助教

1106 松本峻佑

1. まえがき

1990～2001 年ごろ, 薬剤性致死的不整脈である Torsade de Points(TdP)によって, 薬剤の開発中止が相次いだ. TdP を誘発する薬剤のほとんどは, 心電図の QT 間隔 (図 1) を延長させると報告されている¹⁾. そのため, 現在製薬の臨床開発では早期に心電図を用いて臨床評価を受けることが必要となった. しかし, 臨床評価では心電図の測定を複数回, 複数人に行う必要があり, 1 回の心電図測定には約 50 ドルかかるため, 莫大なコストがかかる²⁾. さらに, データを取得する際には欠損が発生することもあり, 取り直しを行うとさらにコストがかかる. この問題に対し, 近年の AI 技術を応用した心電図の合成や予測が有効との報告がある³⁾.

先行研究³⁾では拡散モデルを応用した欠損補完用の生成モデルである SSSD^{S4}⁴⁾を用いた心電図の合成を検討した. その結果, 時系列データの長期依存性を捉えるために設計された S4 層を含む拡散モデルが心電図の合成に適していることが示された. しかし, AI 技術を用いた生成モデルの生成プロセスはブラックボックス化しており, 予測値を決定するプロセスが不透明である. そのため, 生成モデルが出力した心電図波形がどのような理由で生成されたのか分からず, 偶然正しい波形が出力された可能性も否定できないため, 結果に対して信頼ができない問題がある.

そこで, AI の予測を説明する技術である Explainable AI (XAI)を用いてモデルの解釈を行うことで結果に対する信頼の向上が見込めると考えた. 本研究では, 心電図を合成する生成モデルの解釈性向上を目的に, 生成モデルの SSSD^{S4}に XAI を適用する方法を提案し, 心電図合成の際に重視される時系列データの可視化に取り組んだ.

2. 生成モデルと XAI

2.1 SSSD^{S4}

SSSD^{S4}は拡散モデルである DiffWave に基づき, 拡散埋め込み後の残留ブロック内の拡散層を構造化状態空間シーケンスモデル⁵⁾の層(S4 層)に置き換えるなどの変更を行うことで効率的に時系列における長期依存性を捉えることを可能にしたモデルである.

構造化状態空間シーケンスモデルは時系列における長期依存性を効率的にとらえるための手法で, 状態空間モデルに基づき, 設計されたものである. 式(1)に状態空間モデルの式を示す⁶⁾. この式は, 1 次元の入力である $u(t)$ を潜在空間 $x(t)$ にマッピングし, $y(t)$ という出力信号に反映している. A , B , C , D はそれぞれ勾配降下法で学習されるパラメータである.




図 1 典型的な心電図波形の例

$$x(t) = Ax(t) + Bu(t) \quad \text{and} \quad y(t) = Cx(t) + Du(t) \quad (1)$$

2.2 XAI

本研究では XAI 手法として, モデルに依存することなく適用できる LIME⁶⁾と, LIME に SHAP⁷⁾の理論を応用した KernelSHAP⁸⁾, およびその効率化を図った FastSHAP⁹⁾の計 3 種類を使用した. SHAP とは, 協力ゲーム理論のシャープレイ値に基づいて, 各入力特徴量がモデルの出力にどのように貢献したのかを SHAP 値を用いて表す手法である. LIME とは, 特定のデータポイントの周辺のデータを生成し, そのデータに対するモデル予測結果から, 各入力特徴量の重要度を推定する手法である.

3. データセット及び提案手法

3.1 データセット

本研究は自治医科大学附属さいたま医療センター臨床研究に関する倫理委員会の承認 (臨 S23-071)を受けて実施した.

学習および検証用のデータは, 自治医科大学附属病院さいたま医療センター新生児集中治療室においてサンプリング周波数 1000Hz で取得したものをを使用した. データセットにする際に 6 人分の新生児モニター心電図の電圧データを後 100Hz にダウンサンプリングし, 標準化した後データサイズが 200 ポイントになるように区切ることで 2 秒間ごとのデータにした.

3.2 提案手法

約 2 心拍から 1 心拍を予測することができれば, 臨床評価において測定回数を削減することに十分に貢献できると考えた. そのため, データの約 1 心拍分である後尾 60 ポイントを欠損させ, 欠損させた部分を生成するように学習させたモデルに対して XAI を使用することを提案する.

入力の各特徴量が出力に与える影響を算出する XAI 手法を, モデルの出力が数値ではなく波形である SSSD^{S4}に対してそのまま適用することは難しい. そのため SSSD^{S4}の出力を数値とする回帰モデル, またはクラスにする分類モデルへの拡張を行った. 具体的には, SSSD^{S4}を用いて生成した波形に対して Christov アルゴリズム¹⁰⁾を用いて R 波を検出し, 検出された R 波の位置をポイントで出力する回帰モデルとした. 図 1 に示す R の部分が R 波である. その後, 生成された波形のそれぞれのポイントをクラスとし, 図 2 のように回帰モデルで出力されたポイントを平均とし, 試験的に標準偏差を 3 に設定した正規分布を各クラスの疑似的な確率として出力する分類モデルとした.

また, 拡張したモデルをそれぞれの XAI に適用した形で使用するため, 回帰モデルへと拡張したモデルに対して KernelSHAP と FastSHAP を, 分類モデルへと拡張したモデルに対して LIME を使用した.




図 2 各クラスの確率の例

4. SSSD^{S4}に対する XAI の適用

4.1 SSSD^{S4}に対する SHAP の適用

SHAP はモデルの出力に対して入力された特徴量がどの程度貢献したのかを SHAP 値で表す。つまり、SHAP 値が大きい特徴量ほど出力に大きく影響しているため、モデルが重要視している点だといえる。

図 3, 4 に、SSSD^{S4}に対して KernelSHAP と FastSHAP を使用した結果を示す。どちらの SHAP も実行時間が同程度(約 1.5 日)になるようにパラメータを設定して実行した。赤が入力、緑が出力の合成心電図波形である。また、青の棒グラフがそれぞれのポイントでの SHAP 値の絶対値をとった値である。二つの結果を比較すると、KernelSHAP は SHAP 値が出力されていない点が多くあり(図 3)、FastSHAP は、KernelSHAP と比較して多くの点で SHAP 値が計算できている(図 4)。そのため、同程度の実行時間では FastSHAP に比べて KernelSHAP は十分に SHAP 値を算出できず、FastSHAP の方が SSSD^{S4}の解釈を行ううえで有効であると考えた。そのため、モデルの解釈については FastSHAP を用いて行った。

モデルの解釈を行うため FastSHAP を用いていくつかのデータに対して SHAP 値を算出した。図 5 に算出した際の例を示す。算出した結果より、生成部位に近い後半の点や、R 波や T 波の頂点で SHAP 値が大きくなる傾向のあるデータが多いことが確認できた。また、生成部位から離れた 0 ポイントあたりの点でも SHAP 値が与えられていることが確認できた。これらの結果より SSSD^{S4}は生成部位に近い特徴量、R 波や T 波を重要視しつつも、過去のデータの長期依存性も捉えていると考えられる。




図 3 KernelSHAP を用いた際の SHAP 値




図 4 FastSHAP を用いた際の SHAP 値




図 5 FastSHAP を用いた際の SHAP 値の例

4.2 SSSD^{S4}に対する LIME の適用

時系列データに対して LIME を使用するためにデータを 70 個に分割し、それぞれに摂動を加える形で LIME を使用した。図 6 に LIME 使用し、影響度の高かった 5 つのセグメントを黄色く示した結果を示す。図は R 波や T 波の頂点が黄色くなっており、このことから T 波や S 波の頂点の影響度が高くなっていることがわかる。SHAP を適応した際にも同様の結果がいくつか確認できており、SSSD^{S4}が R 波や T 波の周期性を重要視していると考えられる。

5. むすび

本研究では心電図を生成する拡散モデルである SSSD^{S4}の解釈を行うことを目的に、SSSD^{S4}に XAI を適応する方法を提案し、モデルが重要視している点の可視化を通したモデルの解釈を行った。XAI を用いた結果、SSSD^{S4}は生成部位に近い点を重要視しつつも、遠い過去の情報も捉えることができていることと、データによっては周期性を重要視し、生成を行っていることが示唆された。

今後は、さらに多くのデータに対して重要度を算出し、モデルの解釈を進めていくことや、医学、薬学的知見に基づき、得られた結果が信頼できるものであるかどうかを考察していく必要がある。




図 6 LIME を適応した結果

参考文献

- 1) 厚生労働省, 薬食審査発 1023 第 1 号(2009,10,23)
- 2) Benoit Tyl, et al, Journal of Clinical Pharmacology(2009)
- 3) 森田直人,他,日本臨床薬理学会学術総会, 2-C-P-14 (2023)
- 4) Juan Miguel Lopez Alcaraz, et al,TMLR2022(2023)
- 5) Albert Gu,et al, ICLR2022
- 6) Marco Tulio Ribeiro,et al, KDD 2016(2016)
- 7) Scott Lundberg,et al,NIPS2017(2017)
- 8) Ian Covert, et al, AISTATS 2021 (2021)
- 9) Neil Jethani, et al, ICLR 2022 (2022)
- 10) Lvylo I Christov, BioMedical Engineering OnLine(2004)