

Diffusion Models を用いた術前乳癌患者の腹臥位乳房 MRI の変換に関する研究

A Study on the Transformation of Supine Breast MRI in Preoperative Breast Cancer Patients Using Diffusion Models

指導教員 教授 細野裕行, 助教 関弘翔

3809 本郷羽琉

1. まえがき

乳癌は日本人女性の罹患する癌の第1位であり年間9万人以上の人が発症している。乳癌の手術では多数の患者に乳房温存術と呼ばれる癌とその周囲の組織のみを切除する、部分切除術が施行される。乳房温存術にはトレードオフがあり、断端陽性（抽出標本の断端に癌が見られること）の可能性を考慮すると多く切除した方が再発防止の観点では安心だが、乳房の形を保つためには少なく切除した方が形の温存に適している。乳房温存術の過不足ない切除のために、術前の MRI 検査による画像診断が重要になってくる^[1]。

従来の乳房温存術のための MRI 検査は、腹臥位（うつ伏せ）で撮影されるが、手術は背臥位（仰向け）で行われる。そのため、手術を行う際は腹臥位と背臥位での癌細胞のずれを想定しながらの切除が必要となり、医師の経験と勘が重要視される。

この問題に対し、天野らが持つ癌の位置を正確にプロジェクションマッピングする技術^[2]を用いることで、過不足ない切除手術の可能性を高めることができる。この技術を適用するためには、腹臥位造影 MRI（造影剤を使用するうつ伏せ状態での MRI）と背臥位造影 MRI（造影剤を使用する仰向け状態での MRI）が必要となる。しかし、その2回の MRI 検査を行うために造影剤を2回投与することによる、経済的負担やアレルギーのリスクが高まる身体的負担から、選択する患者が少ない状況である。

先行研究^{[3][4]}では、造影剤一回の投与での MRI 検査を可能にするために、Generative Adversarial Networks (GAN) の一種である CycleGAN による造影・非造影 MRI の相互変換を行った。結果として、腹臥位造影 MRI と腹臥位非造影 MRI の変換を行うことができたが、背臥位非造影 MRI と背臥位造影 MRI の変換はできていなかった。また、GAN は学習が不安定であると報告されており、より安定した最新の生成モデルへの期待がある。

そこで本研究では、安定した造影・非造影 MRI の変換のために、GAN ではなく学習に安定性がある Diffusion Models^[5]を用いた腹臥位の造影・非造影の変換を行い、変換画像の品質について評価する。

2. 方法

2.1 腹臥位乳房 MRI の変換に用いたモデル

Diffusion Models は、拡散過程と逆拡散過程という2つの過程から構成される。拡散過程は、式 (1) で表される。 β_t は $[0,1]$ のノイズスケジューリングパラメータであり、 T に向かって線形で大きくなるように設定する。入力データ $\mathbf{x}_0$ に β_t の強度でランダムなノイズを加える操作を T 回繰り返し、最終的に完全なノイズ画像 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ へ変化させる。それぞれのタイムステップ t で得られる画像を $\mathbf{x}_t$ とし、その確率分布を $q(\mathbf{x}_t | \mathbf{x}_{t-1})$ と表す。逆拡散過程は、式 (2) で表される。完全なノイズ $p(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ を始点とするマルコフ連鎖によってデータ $\mathbf{x}_0$ を生成する。ノイズ入力 $\mathbf{x}_t$ に対して、ノイズを除去したデータである $\mathbf{x}_{t-1}$ は、確率分布 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$ に従って生成させる。ここで、 $\mu_\theta(\mathbf{x}_t, t)$ はパラメータ θ を持つニューラルネットワークが出力する確率分布の平均であり、 $\Sigma_\theta(\mathbf{x}_t, t)$ は共分散行列を

表す。Diffusion Models は、パラメータ θ を更新しながらタイムステップごとに学習を行う。

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = p_N(\mathbf{x}_t | \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}) \quad (1)$$

$$\begin{cases} p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) \\ p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = p_N(\mathbf{x}_{t-1} | \mu_\theta(\mathbf{x}_t, t), \Sigma_\theta(\mathbf{x}_t, t)) \end{cases} \quad (2)$$

Conditional Diffusion Models は、逆拡散過程において特定の条件を与えることで、任意のデータの生成や変換を可能にする技術である。これを医療画像生成に応用した Med-DDPM^[6]が提案されている。

Med-DDPM は、脳 MRI データセットにおいて、条件として脳の領域や腫瘍領域を表すマスク画像を与えることで任意の MRI を生成する Conditional Diffusion Models である。Med-DDPM では、ノイズに対して、条件であるマスク画像をチャネル方向に結合することで条件付けを可能にしている。

本研究では、Med-DDPM を乳房 MRI データセットに適用させる。最終的な目的は、背臥位非造影 MRI から背臥位造影 MRI への変換であり、その前段階として、腹臥位非造影 MRI から腹臥位造影 MRI への変換を目指す。このため、マスク画像の代わりに腹臥位造影 MRI を入力データとして与える。

2.2 データセット

本研究では、日本大学病院の天野助教から提供された、造影腹臥位と非造影腹臥位の MRI データを用いる。表1に作成したデータセットを示す。

前処理としてデータを $[-1, 1]$ で正規化した。正規化を行わない場合、生成データに強いノイズが生じたためである。

2.3 評価方法

本研究では、腹臥位造影 MRI とモデルが生成した腹臥位造影 MRI を視覚的に比較することによる、定性評価を行う。

3. 結果

3.1 Med-DDPM の学習条件

表1に示したデータセットを用いて、Med-DDPM の学習と推論を行った。表2に Med-DDPM の学習条件を示す。

設定値1から設定値2への変更理由は、ノイズ低減である。正規化後の生成データに関して、ノイズは低減したものの完全には消えない問題があった。学習損失グラフを確認したところ、最終タイムステップまで振れ幅が大きく、損失が高いデータに影響を受けてノイズが残存していることが考えられた。そこで、損失関数を L1 から Log-Cosh に変更した。また、学習率 0.00001 では 5000 エポック内で最適に収束できていないと考え、学習率を 0.0001 に増加させた。さらに、ノイズの低減につながると考え、バッチサイズを 1 から 2 に増加させることも検討した。

ここで、Log-Cosh とは、L1 損失と L2 損失両方の特性を持ち合わせた損失関数である。L1 のみでは対応しきれない、0 付近の小さな誤差にも対応できる。下記に Log-Cosh の式を示す。式中の $\mathbf{y}_i$ は予測値、 t_i は目標値である。

$$\text{LogCosh} = \sum_{i=1}^N \log(\cosh(y_i - t_i)) \quad (3)$$

また、更なるノイズの低減と画質向上のために、設定値3に示すように、エポック数を 5000 から 10000 に変更した。

3.2 推論結果

推論結果との比較のために、図 1 に造影前のテストデータを示し、図 2 に造影後のテストデータをそれぞれ示す。図 3 に設定値 1 で学習したモデルによるテストデータに対する推論結果を、図 4 に設定値 2 で学習したモデルによるテストデータに対する推論結果を、図 5 に設定値 3 で学習したモデルによるテストデータに対する推論結果をそれぞれ示す。

まず図 2, 3 を比較すると、乳房から胴体にかけての輪郭や、癌細胞や臓器、血管の集合の白さのおおよそは表現できているが、画像全体のノイズが目立っているため、造影 MRI の品質が十分に確保できていない。この原因として、L1 損失の特性による再現性が考えられる。L1 損失では、各ピクセル誤差の絶対値の和を求めるので、大きな誤差も小さな誤差も同様に扱われる。そのため、細部の変化がうまく再現できず、結果として推論結果のノイズにつながったと考えられる。

次に図 2, 4 を比較すると、設定値 1 と同様、乳房から胴体にかけての輪郭や、癌細胞や臓器、血管の集合の白さのおおよそは表現できている。また、設定値 1 と比べると、ノイズが減少していることや、左乳房の癌細胞が強調されていることが見て取れるため、設定値を変更したことにより、細部の変化の再現性に寄与し、造影 MRI としての品質向上につながったと考えられる。しかし、図 2 は、白と黒のコントラストが明確であるのに対し、図 4 は白と黒のコントラストが曖昧になっており、画像全体のノイズが目立っている。また、左乳房の癌細胞の白さが弱いことも確認できる。

最後に、図 2 と図 5 を比較すると設定値変更前と後と同様、乳房から胴体にかけての輪郭や、癌細胞や臓器、血管の集合の白さのおおよそは表現できている。また、設定値 2 と比べて、左乳房の癌細胞の輪郭が明確に表現できており、図 2 の特徴をより確保していることが読み取れる。また、図 4 と比べてノイズが低減しており、エポック数の増加に効果があったと考えられる。しかし、左乳房の癌細胞の白さが図 2 ほど強く表現できてはいないため、改善が必要である。

図 2 と比較した際の、図 3, 4, 5 の画質の粗さの原因として、ハイパーパラメータの調整が不足していることが考えられる。

4. むすび

本研究では、腹臥位非造影 MRI から腹臥位造影 MRI に変換するモデルの画質向上を目的として、条件として腹臥位非造影 MRI を与えた Conditional Diffusion Models による腹臥位造影 MRI の生成を行った。Med-DDPM を応用したモデルを構築し、バッチサイズ、エポック数、学習率、損失関数の変更を行うことでノイズ低減と品質向上を図った。結果として、損失関数を L1 から Log-Cosh に変更することで、造影後のテストデータの特徴をより確保した画像の生成が可能となった。さらにエポック数を増加することで、癌細胞の輪郭の再現性が向上し、結果として画質向上に寄与することができた。しかし、実際の腹臥位造影 MRI と比べると、生成した腹臥位造影 MRI は乳癌細胞の白さが弱いため、改善が必要である。

本研究では、ハイパーパラメータを試験的に設定したため、今後は、適切なハイパーパラメータの調整や、条件として与えるデータの追加を検討することで、Med-DDPM による生成画像の画質向上を目指す。また、RMSE や SIMM などの定量的表手法も検討する。

表 1 学習に用いたデータセット

	非造影腹臥位	造影腹臥位
Train	340	340
Test	10	10

表 2 学習条件

	設定値 1 (変更前)	設定値 2 (変更後)	設定値 3 (変更後)
Input Shape(D, H, W)	(64, 128, 128)		
Output Shape(D, H, W)	(64, 128, 128)		
Batch Size	1	2	2
Epoch	5000	5000	10000
Learning Rate	0.00001	0.0001	0.0001
Optimizer	Adam	Adam	Adam
Loss Function	L1	Log-Cosh	Log-Cosh
Time Steps	250	250	250




図 1 造影前テストデータ




図 2 造影後テストデータ




図 3 設定値 1 推論結果




図 4 設定値 2 推論結果




図 5 設定値 3 推論結果

参考文献

- [1] 白岩美咲, 医用画像情報学会雑誌(2012), 29 巻, 4 号, pp.78-81, 2012.
- [2] M. Amano, et al., BioMed, vol. 2020, p.1-9, 2022.
- [3] 吉田雪子, 日本大学理工学部応用情報工学科令和 4 年度卒業論文, 2023.
- [4] 鳥巢美優, 日本大学理工学部応用情報工学科令和 5 年度卒業論文, 2024.
- [5] J. Ho, et al. 2020, 33: 6840-6851.pp 6840-6851,2024.
- [6] F. Khader, et al, arXiv preprint arXiv:2211.03364, pp.1-20, 2022