

インサイドセールス音声の特徴づける音響特徴の研究

A study of acoustic features in inside sales speech

浅井 拓也 *1*2

Takuya Asai

凌 佩珊 *1

Peishan Ling

菊池 英明 *1

Hideaki Kikuchi

神長 伸幸 *2

Nobuyuki Jincho

*1 早稲田大学 人間科学部

Graduate School of Human Sciences, Waseda University, Japan

*2 ミイダス株式会社 HR サイエンス研究所

HR Science Institute, MIIDAS co., ltd. Japan

In this study, simulated business meeting speech with controlled linguistic context was acquired and the distribution of acoustic features was examined. A total of 88 acoustic features were exhaustively calculated. Next, the t-SNE method was used for dimensionality reduction and to identify acoustic features that reveal speaker differences. The results showed that the mean value of delta F0, the variance of delta power, and the mean value of vocal fold vibration intensity characterized inside-sales speech.

1. 背景・目的

我々はインサイドセールスの音声における音響特徴を研究し、その知見を営業成績の推定や商談会話のための発話訓練に活用することを目指している。

商談会話を対象とした研究では発話の言語的特徴が興味を中心であり、音声の音響的特徴に関する議論は限定的である。Stoltzman は、説得を意図した 5 分未満のプレゼンテーション音声を解析し、Vocal Activity (発話量や話速など) が高く、Vocal Emphasis (音圧や音高など) が低い音声は説得力があると知覚されやすいことを報告している [Stoltzman 06]。また、同研究において、アポイントメント獲得を意図したカスタマーサービス音声を解析し、Vocal Activity が低く、Vocal Emphasis が高い発話者が、アポイントメント獲得に成功しやすいことを報告している [Stoltzman 06]。

この研究は商談会話の成否が、言語的な内容のみならず、音声の音響的印象に影響されることを示す重要な研究であるものの、利用されている音響特徴が限定的であり、また、実験で用いられる音声の言語情報も統制されていない。そのため、本研究では、言語情報の統制した模擬商談音声を収集し、音響特徴量を網羅的に調査することにより、商談音声において発話者の声の特徴づける音響的特徴の選出を目的とした。

2. 方法

言語情報の統制のため、インサイドセールスのうちアポイントメント獲得場面を想定した模擬商談音声を収録した。セールス役として実務経験ある発話者 172 名、顧客側として、大学生 2 名が収録に参加した。実際のセールス場面を想定し、Amazon Connect を介したオンライン環境にて音声収録を行った。

収録は大きく、台本部と、自由発話部に分けられる。台本部では、まず、セールス側は名乗りをあげ、次いで、採用の状況確認を行った。それに対し顧客側は自身が採用担当であり、採用を行っていることをセールス側に告げた。最後にセールス側が次回商談のために顧客の予定を尋ねた。

ただし、発話の自然性を考慮し、それぞれの参加者には、細かい言葉遣いはあまり気にせず、流れの参考にするように教示がなされた。続く、自由発話部では、募集職種や採用人数、採用スケジュール等、通常の業務に合わせた形式で自由に対話を行っ

た。本研究では台本部、最終発話を対象に解析を行った。なお、最終発話内容は以下の通りである。

そうしましたら、お電話越しにはなりますが、今までにない採用手段としてミイダスの画面をご覧くださいながらご提案できればと思うのですが、近日でお仕事のおじゃまになりにくいタイミングはございますか？

収録された音声は、聴取にて、セールスの発話箇所が特定された。この際に、発話内容が台本から大きく離れ、発話箇所の特定が困難なものや、背景雑音が大きいデータは除外され、合計 100 個の音声を選択された (女性 7 名、男性 93 名)。



抽出された音声は OpenSMILE [Eyben 10] を用いて音響特徴量に変換された。ここで音響特徴量セットには、eGMAPS [Eyben 15] を利用した。このセットは F_0 や Jitter など周波数特性に関わる特徴量や、Formant をはじめとするスペクトル特性に関わる特徴量、Loudness をはじめとするパワー特性に関わる特徴量、計 26 種類が基本になる。この基本特徴量から平均や標準偏差、レンジ、四分位などの要約統計量を算出し、88 次元の特徴量が抽出された。

算出された音響特徴量を要約し、特徴量の効果を分析するために、t-SNE 法による次元圧縮 [Maaten 08] を試みる。t-SNE 法では、高次元のデータ集合を 2, 3 次元に配置する際に高い確率で類似した集合が近傍に、異なる集合が遠方になるように対応づける。上述の音響解析によって得られた 88 次元の特徴量に対して、t-SNE 法を適用することで、特徴量間の距離に基づいて音声の集合が形成され、類似したまとまりや、音声間の距離が可視化される。この空間においてそれぞれの特徴量の大きさを濃淡で表示することにより、音声を分離するのに有効な特徴量を探索した。

3. 結果

t-SNE 法による圧縮結果を、それぞれの音声の F_0 。平均毎に色分けした結果を図 1 に標準偏差毎に色分けした結果を図 2 に示す。図 1 を観察すると、右上に値の高い群が存在する。これらの群の音声を聴取すると、この群には女性話者が集まっていた。一方で、図 2 を観察すると、男女ともに、値の高い群と低い群が存在することがわかった。この結果から、 F_0 。に関しては平均値よりも標準偏差の方が発話者の声の特徴づけやすいことが示唆された。

連絡先: 浅井拓也, 早稲田大学, qh73xe@ruri.waseda.jp

図 1: t-SNE による次元圧縮結果 (F_0 平均)図 2: t-SNE による次元圧縮結果 (F_0 標準偏差)

同様に音圧平均毎に色分けした結果を図 3 に、標準偏差毎に色分けした結果を図 4 に示す。図 3 を観察すると、一様に高い値を示した。一方で、図 4 を観察すると、男女ともに、右下に特に値の高い群が集中した。この結果から、音圧に関しては平均値よりも標準偏差の方が発話者の声の特徴づけやすいことが示唆された。

Alpha Ratio は 50 ～ 1000 Hz 帯域と 1 ～ 5 kHz 帯域の合計エネルギー比である。Hammarberg Index は 0 ～ 2 kHz 帯域と 2 ～ 5 kHz 帯域の最大エネルギー比である。t-SNE 法による圧縮結果を、Alpha Ratio の平均値毎に色分けした結果を図 5 に、Hammarberg Index の平均値毎に色分けした結果を図 6 に示す。図 5, 6 共に男女共に上下に高い値を示す群と、低い値を示す群に分割された。Alpha Ratio, Hammarberg Index は声帯振動を前提とする低周波数帯域と、高周波数帯域のエネルギー比であることから、声帯振動の強さが発話者の声の特徴づけやすいことが示唆された。

最後に声質に関わる特徴量として知られる 500 Hz と 1500 Hz 帯域のスペクトル傾斜及び Jitter 平均毎に色分けした結果を、図 7, 図 8 に示す。図 7 を観察すると、男女共に中央下に比較的高い群が観察された。図 8 を観察すると、特に中央付近に比較的高い値の群が観察された。500 Hz と 1500 Hz 帯域のスペクトル傾斜は声帯振動の息もれ性を、Jitter は声帯振動の周期性を表す音響特徴量であることから、特に女性においては息もれ性に、男性においては声帯振動の周期性に、発話者の声の特徴が表出されることが示唆された。

4. まとめと考察

言語的な内容を統制した模擬商談音声を取得し、音響特徴の分布を調べた。音響特徴として Eyben らが提案した 88 次元の特徴を網羅的に算出した。解析の結果、 F_0 やインテンシティの平均値のような静的な特徴量は男女差や、その人の個人の特徴を示すことは確認されたものの、話し方のような特性を表現することは困難であった。一方で変化量や加速度においては、インサイドセールスが能動的に行っている表現を抽出しやすいことが示唆された。

上記結果を踏まえ、 F_0 の平均値及び、標準偏差、Loudness 平均値及び標準偏差、Alpha Ratio の平均値及び標準偏差、Hammarberg Index の平均値及び標準偏差、スペクトル傾斜の平均

値及び標準偏差、Jitter の平均値及び標準偏差の 12 次元に限定をし、t-SNE 法による次元圧縮を行った。

圧縮された空間において、近い距離の音声はどのような印象を持つかを考察するために、音声同士の印象を聴取にて確認した。圧縮された空間を K 平均法を用いて教師なしクラスタ解析を行い、それぞれのクラスタに属す音声を聴取した。聴取の結果、特に早口で話す印象の音声や、丁寧な印象を与える音声、抑揚豊かな印象の音声や、起伏の少ない印象の音声などに分離された。

これらの結果により、特にインサイドセールス音声を音響特徴で分類する場合には、静的な特徴よりも動的な特徴が効果的である可能性が示唆された。

参考文献

- [Eyben 10] Eyben, F., Wöllmer, M., and Schuller, B.: Opensmile: the munich versatile and fast open-source audio feature extractor, in *Proceedings of the 18th ACM international conference on Multimedia*, pp. 1459–1462 (2010)
- [Eyben 15] Eyben, F., Scherer, K. R., Schuller, B. W., Sundberg, J., André, E., Busso, C., Devillers, L. Y., Epps, J., Laukka, P., Narayanan, S. S., et al.: The Geneva minimalist acoustic parameter set (GeMAPS) for voice research and affective computing, *IEEE transactions on affective computing*, Vol. 7, No. 2, pp. 190–202 (2015)
- [Maaten 08] Maaten, Van der L. and Hinton, G.: Visualizing data using t-SNE., *Journal of machine learning research*, Vol. 9, No. 11 (2008)
- [Stoltzman 06] Stoltzman, W. T.: *Toward a social signaling framework: Activity and emphasis in speech*, PhD thesis, Massachusetts Institute of Technology (2006)




図 3: t-SNE による次元圧縮結果 (Loudness 平均)




図 4: t-SNE による次元圧縮結果 (Loudness 標準偏差)




図 5: t-SNE による次元圧縮結果 (Alpha Ratio 平均)




図 6: t-SNE による次元圧縮結果 (Hammarberg Index 平均) ,




図 7: t-SNE による次元圧縮結果 (スペクトル傾斜 平均)




図 8: t-SNE による次元圧縮結果 (Jitter 平均)