

列車運行実績データに基づいた機械学習による駅出発遅延時間推定手法の検討

正員 福田 卓海^{a)} 学生員 佐藤 駿一*
正員 高橋 聖* 正員 中村 英夫*

Takumi Fukuda^{a)}, Member, Sato Shuniti*, Student Member, Sei Takahashi*, Member, Hideo Nakamura*, Member

In the urban railways of the metropolitan area, train delays during morning rush hours have become a significant issue. This problem isn't merely caused by large, sudden delays, but also by an accumulation of minor delays, which can escalate into substantial setbacks. This presents a disadvantage not only for the operators managing the train services but also for the users. Recent years have seen active reporting of studies predicting delay times. However, these studies do not take into account the accumulative nature of delays because the data input to the learning machine is only for stations behind the target station. Therefore, this paper aims to predict the delay time that occurs when each train departs from a station. To do so, we constructed a network that takes into account the propagation of delays by using data from stations in front of the target station as input. We will provide an overview of the network we constructed and report on its predictive accuracy.

キーワード：電気鉄道, 機械学習, 遅延予測, スケジューリング, シミュレータ

Keywords: Electric railroad, machine learning, delay prediction, scheduling, simulator

1. はじめに

首都圏における都市鉄道が抱える問題として朝の通勤時間帯の遅延がある。朝 6 時頃から 8 時頃までは 1 日のうちで最も利用者が多い時間帯であるため、各事業者は輸送力増強を目的とし、様々な対策を講じている。中でも列車運転間隔の短縮は輸送力に直結するため非常に重要な対策であり、利用者の利便性にも大きな影響を与える。しかし、列車運転間隔の短縮は輸送力を向上させる一方で遅延の影響を大きくする要因になる。現状では一度発生した遅延を解消するには時間がかかるため、間引き運転や列車の運転間隔調整などを行い列車間の間隔を整えている。その結果、事業者が設定した輸送力は維持されず、また利用者は旅行時間が延長するため満足度が低下する。以上のことから輸送力を保持したまま遅延の少ない運行を実現することが望まれている。

一方で、遅延への対策を講じる際には事前にシミュレータ等を用いて影響度を確認する。既存の列車運行シミュレータで列車運行をシミュレーションする際には、路線データや車両データ等の基本的なデータに加え駅での停車時間を

入力しシミュレーションする。この時入力する駅での停車時間は、実際に列車が運行した際のデータ（以下、列車運行実績データ）を用いることが一般的である。したがって、遅延対策のために講じる路線形状の変化やダイヤの変更に伴う駅での変化した停車時間を入力することは不可能である。

そこで筆者らは、機械学習を用いた列車運行実績データに基づく駅出発遅延時間予測が可能となれば、路線形状変更や駅取り扱いの変更に伴う運転時間の変化をもとに駅出発遅延時間を決めることができるため、列車運行シミュレータにおいて遅延対策前後の効果を検証できると考えた。本稿では、列車運行シミュレータに組み込むことを前提とした列車の駅出発遅延時間予測手法について説明し、提案する手法を用いた駅出発遅延時間の予測精度で評価した。

2. 研究背景と目的

〈2・1〉 研究背景 在来線の多くは、一意に決められた距離で列車の速度を制限し安全を確保する固定閉そくというシステム上で運行している⁽¹⁾⁽²⁾。後方の列車が先行の列車に接近し列車間隔が短くなると、後方の列車の走行速度を制限し安全を確保する仕組みである。このような仕組みのため、輸送力の向上を目的に列車運行間隔を短縮していると、例えば前方列車が駅出発時に遅延をした場合に、後方列車への影響は運転間隔が広い場合に比べ大きくなる。朝の混雑時間帯以外の時間帯では、列車運転間隔が十分に取られているため、駅で発生する小さな遅延で大きくダイ

a) Correspondence to: fukuda.takumi@nihon-u.ac.jp

* 日本大学理工学部

〒 274-8501 千葉県船橋市習志野台 7-24-1

College of Science and Technology, NIHON UNIVERSITY,
7-24-1, narashinodai, funabashi-shi, Chiba, 274-8501 Japan

ヤを乱すことはないが、混雑時間帯は列車間隔が短いため、小さな遅延であっても後続へ影響を与えその遅延が解消することなく次々と伝搬していく。伝搬した遅延は拡大し続け、ラッシュ時間帯を過ぎても解消しないため問題となっている。こうした遅延に対する遅延対策を行う際には、事前にシミュレータを用いてその効果を検証する。現状では遅延対策により変更された路線データは入力することができるが、駅で発生しうる遅延時間は予想できないため既存の列車運行実績データを入力することで影響度を評価している。しかし、路線形状や駅構内距離等を変更した際には前方列車が後方列車へ与える影響が変化するため、駅出発時の遅延時間も既存のデータと同じにはならない。したがって、事前に遅延対策の定量的な評価を既存の列車運行実績データで行うことは難しいため、走行データから駅で発生する遅延時間を推定することが必要である。

〈2・2〉 関連研究 近年国内において列車の遅延予測に関する研究が活発になりつつある。しかしその多くは運行管理業務支援が目的であり、慢性的な遅延伝搬を特徴として捉えられているものは少ない。

列車運行予測の基礎的な研究としては、國松らによる列車運行・旅客行動シミュレータによる利用者数の推定及び遅延予測手法が提案されている。しかしこれらは、既知のデータの統計から導出された回帰式を用いて推定をしており、日ごとに違う遅延のデータを反映しておらず遅延伝搬の特徴を捉えた推定をしていない⁽³⁾。機械学習を用いた列車遅延予測の研究としては、辰井らにより時系列データの予測が得意とされている Long Short Term Memory（以下、LSTM）を用いて列車遅延時間を予測する手法について提案され誤差 5 秒以内の精度が 38.9 %としている⁽⁴⁾⁽⁸⁾。また、岩本らは、短時間先の遅延を予測しダイヤ図を描画する予測ダイヤ機能を開発し、一部路線の運行管理システムで実用化している。しかし、ユーザが駅、列車種別、時間帯等に応じてパラメータを多数設定する必要があり、列車の走行のみから遅延時間を予測推定することができない⁽⁵⁾。また、これらの研究では予測器に入力するデータを予測対象駅の後方のみとしているため、伝搬する遅延の特徴を捉えられていない。

一方で、海外においても遅延予測の研究は行われている。Zhou らの研究では弱学習機を複数用いて学習させるスタッキングと呼ばれる手法を用い、中国東北部の鉄道における列車遅延時間の予測を行っている。この予測では 30 秒以内の予測精度が 90 %とされているが、対象路線が高速路線であるため列車の運転間隔が広く、日本の首都圏における複雑な遅延状況とは大きく異なる⁽⁶⁾。

〈2・3〉 研究の位置付け 本研究の目的は列車運行シミュレータによる遅延対策の効果検証及び評価をより正確に行うことである。そのためには、列車運行実績データに含まれる列車走行と駅遅延の複雑な関係を機械学習により学習し遅延時間を予測し対策前後で変化するであろう駅発生遅延を比較する必要がある。先行研究において予測対象




Fig. 1. Delay trends.

駅より後方のデータを学習器の入力データとし遅延時間の予測を行っていた。しかし、慢性的な遅延は列車前方方向から伝搬してくるため、遅延の特徴を学習していない。そこで本稿では、入力データに予測対象列車が予測対象の駅へ到着した時点で分かる先行列車の予測対象駅より前の走行データを含めることで、遅延伝搬の特徴を学習できるような Convolutional Neural Network（以下、CNN）⁽⁷⁾ モデルを構築した。

3. 列車運行実績データの分析

〈3・1〉 列車運行実績データの概要 列車運行実績データとは、列車運行日の全ての列車走行を記録したものであり、「列車名、列車種別、各駅の到着時間、各駅の出発時間、到着番線」が記録されている。到着時間及び出発時間は秒単位で記録されているため時間分解能が高いデータとなっている。本稿では、これらのデータと列車運行ダイヤを比較することで各駅の到着遅延時間や出発遅延時間、駅間走行時間などを算出し学習データとした。算出したデータを下記に示す。なお、全て秒単位のデータとなっている。

- (1) 出発遅延時間=実績出発時刻-予定出発時刻
- (2) 到着遅延時間=実績到着時刻-予定到着時刻
- (3) 駅間走行時間=駅到着時刻-後方駅出発時刻
- (4) 駅間発生遅延=到着遅延時間-後方駅出発遅延時間
- (5) 駅発生遅延=出発遅延時間-到着遅延時間
- (6) 停車時間=実績出発時刻-実績到着時刻
- (7) 到着間隔=実績到着時刻-先行列車出発時刻

〈3・2〉 遅延の特徴 遅延には時間帯によって 3 種類の状態に分けることができる。Fig.1 に示す図は、一年間のある駅での遅延の増加傾向を確認するために、縦軸に出発遅延時間、横軸に時刻としたものである。Fig.1 より遅延の推移には

- (1) 初期遅延が発生し遅延が増加して行く時間帯。
- (2) 遅延が増加しきり停滞する時間帯。
- (3) 増加していた遅延が減少していく時間帯。




Fig. 2. Accumulation of small delays.

の3種類の時間帯があることが分かる。

(1)の時間帯以前では多様な遅延が発生しているが遅延が拡大する傾向にはない。しかし、(1)の時間帯に入ると遅延が拡大する傾向が確認できる。この時間帯は、利用者数が増加するため列車の運転間隔が狭くなる時間帯であり、駅での乗降時間が増加しやすくなることで停車時間が規定を超過し遅延が拡大しやすいため(1)のような傾向となる。(2)の時間帯では、増加した遅延が増えることなく一定で推移している。この時間帯は、増えていく遅延に対して運転間隔調整等の運転整理を行うことで遅延の拡大を抑えている時間帯である。(3)の時間帯では、一定で推移していた遅延時間が減少していく傾向が確認できる。この時間帯は、利用者数が減少するため列車の運行間隔が広くなる時間帯である。この時間帯では、遅延を抑える運転整理策と列車の運行間隔の広さから増加した遅延を急速に収束させることができている。

(1)の時間帯において発生している遅延を確認できるダイヤ図を Fig.2 に示す。青線が規定されているダイヤで走行した場合の軌跡であり、赤線が実際に列車が走行したダイヤである。したがって、青線と赤線のずれが遅延時間となる。Fig.2 よりある列車に遅延が発生しその次の列車の走行速度が遅くなることで、遅延が伝搬していくことが確認できる。

本稿において対象とする遅延は(1)の時間帯において発生している Fig.2 に示す伝搬していく遅延である。

〈3・3〉 駅発生遅延の駅間関係性 ある駅で発生する遅延時間に対して他駅の遅延時間に相関があれば、機械学習を用いずとも駅で発生しうる遅延時間を推定することが可能である。そこで、各駅の駅出発遅延時間を相関分析し相関関係があるか確認した。遅延の影響範囲をヒートマップを用いて可視化した図を Fig.3 に示す。相関係数は一般的に0から0.2間で「ほぼ相関なし」、0.2から0.4間で「やや相関あり」、0.4から0.7間で「かなり相関あり」、0.7から1.0間で「強い相関あり」とされる。




Fig.3. Heatmap visualization of correlation coefficients.

Fig.3の横軸は列車、縦軸は駅を取り、縦横軸0のデータが比較の基準となる列車と駅であり、基準となる列車と駅を比較してそれぞれのデータの相関の強さを、赤から青の範囲で示している。例えば、縦横軸1のデータは、縦横軸0の列車の一本後ろの列車かつ一つ後ろの駅を意味し、縦横軸0のデータとの相関を示している。列車はAからGへ向かって走行している。ここで、縦横軸0のデータは自身を比較しているため最も強い相関1.0となる。Fig.3中の各象限におけるデータの意味は

第一象限 予測対象駅に対して後方の未来のデータ

第二象限 予測対象駅に対して後方の過去のデータ

第三象限 予測対象駅に対して前方の過去のデータ

第四象限 予測対象駅に対して前方の未来のデータ

である。

Fig.3より、駅で発生する遅延に対して相関を示すデータの範囲には特徴があることが確認できる。象限ごとにある駅に対する遅延の影響を分析する。第一象限は、ある駅で発生した遅延が後続の列車の後方の駅へ伝搬していることを裏付けるデータであり、象限内の広範囲が「かなり相関あり」のデータであることが分かる。第二象限は、先行研究において予測のための入力データとされるデータであるが、象限内で「かなり相関あり」のデータが少ないことが確認できる。特に対象列車に対して前方3列車目を確認すると、予測対象駅の後方1駅目の相関は「やや相関あり」であり、発生する遅延に対する関連性が低いと言える。一方で第三象限では、予測対象列車に対して前方3列車目を確認すると、予測対象駅の前方1駅目の相関が「かなり相関あり」となっている。また、先行1列車目および2列車目においても同様であるため、ある駅で発生する遅延に対して先行列車の前方駅からの影響があると言える。第四象限には大きな相関が確認できない。これは〈3・1〉で示した遅延伝搬の特性から妥当な結果と言える。遅延はある列車に発生した遅延が後続列車の走行に影響を及ぼすことで伝搬




Fig.4. CNN model.

していくため、第四象限で示される後続列車の前方駅との関連性は低くなる。以上より、ある駅で発生する遅延時間を予測するには、第二象限のデータだけではなく第三象限のデータを含めることが有効である可能性が示唆された。

4. 機械学習ネットワークでの遅延予測

〈4・1〉 ネットワークの構成と入力データ 本稿で使用したネットワークは畳み込みニューラルネットワーク（以下、CNN）である。列車遅延の予測問題ではLSTMを使用する研究が多いが、遅延の伝搬は各列車単位で起きているわけではなく、〈3・3〉で示したように前方の列車の影響を受けているため、取り扱うデータを離散的データであると仮定し個々のデータ空間上の関係性を学習することができるCNNを採用した。遅延伝搬の特徴を学習するためには、列車が走ってきた区間のデータではなくこれから走る区間を走った先行列車のデータが重要である。現実では、予測対象の列車が駅に到着した時点で先行列車が前方の駅に到着していない区間も存在するが、本研究ではシミュレータ上での遅延対策を評価することを目的としているため、先行列車のデータが全て分かるものとして入力データを作成した。

本稿で使用したネットワークを Fig.4 に示す。予測対象

Table 1. validation model.

名称	モデル 1	モデル 2	モデル 3	モデル 4
モデル構造	CNN	LSTM	CNN	CNN
対象列車	列車本数：6 後方駅：3 前方駅：0	列車本数：6 後方駅：3 前方駅：3	列車本数：6 後方駅：3 前方駅：3 (Opadding 有)	列車本数：6 後方駅：3 前方駅：3 (Opadding 無)
入力データ	到着遅延 出発遅延 駅発生遅延 駅停車時間 駅間走行時間 駅間発生遅延			

Table 2. Data not considered as noise range.

feature	max[s]	min[s]
Arrival delay	400	-100
Departure delay	400	0
Station travel time	250	0
Station travel delay	100	-100
Station occurrence delays	100	-100
Stop time	200	0
Intrval time	500	0

駅に対して後方駅のためのデータを入力とし、3次元の畳み込み層3層と全結合層4層で構成されたCNNモデルを基準のネットワーク（以下、モデル1）とする。モデル1に対し、予測対象駅に対して後方駅と前方駅のデータを入力とするネットワークを3つ構築し精度を比較した。作成したモデルと入力データの違いを Table1 に示す。モデル2から4の説明変数には予測対象駅より前方のデータを入力している。モデル2のみLSTMで構築している。モデル3とモデル4は共にCNNで構築しているが、説明変数へ入力する前方駅のデータを、予測対象列車が駅へ到着した段階で分からない部分を0で埋めているモデルがモデル3であり、先行列車の情報は全て分かったと仮定して入力としているモデルがモデル4である。なお、全てのモデルにおいて損失関数はmaeを使用し、最適化アルゴリズムはadamを使用した。

〈4・2〉 使用データ 本研究で対象としている遅延は徐々に増加していく遅延である。したがって、突発的に発生する大きな遅延時間を対象としない。そのような遅延時間は学習ノイズとなるため Table2 で示すデータの範囲内に収まるデータのみ使用した。

使用したデータは2019年度の平日朝7時から9時までに走行する列車のうち、ノイズとなるデータを除いた全1600データである。このうち、80%を学習データ20%をテストデータとし予測精度を比較した。テストデータは連続したデータではなくランダムに選ばれるものとする。

Table 3. Accuracy by model.

Station	Model1[%]	Model2[%]	Model3[%]	Model4[%]
A	58.3	36.4	57.6	57.9
B	43.9	36.8	47.5	47.3
C	43.9	30.3	48.5	47.8
D	43.9	36.5	50.2	51.1
E	58.5	36.7	54.3	57.1
F	69.5	39.1	65.2	67.8
G	62.4	52.5	60.6	65.0

〈4・3〉 各入力による精度 大都市圏を通る路線から6駅用意し、それぞれの駅について予測した精度を比較する。対象路線の各検証駅では快速等の追い越しや待ち合わせは無く、走行する全ての列車が停止する駅である。また、対象とする時間帯は朝の混雑時間帯であり、列車の走行間隔が一日のうちで最も短くなる時間帯の列車とした。

予測精度を評価するために、実績値と予測値の絶対値5秒以内の精度を比較した。各モデルにおける精度をTable3に示す。基準としたモデル1とLSTMを使用したモデル2の予測精度を比較すると、CNNを使用したモデル1の精度は7駅中5駅が10ポイント以上モデル2より精度が高いことが確認できた。また、残りの2駅においても7ポイント程度良い精度である。他モデルと比較してもモデル2の精度が低いことから、遅延の伝搬は各列車単位で起こっていることではなく、前後の列車の影響を受けていることを示す結果であると言える。

CNNモデルを用いることで列車間の遅延の関係を学習することができていることが確認できたため、入力する説明変数の違いについて考察する。まず、モデル1とモデル3を比較すると、7駅中3駅で精度の向上が見られ最大で6ポイント程度改善していることが分かる。しかし、その他の駅では精度が悪化しており、特にE駅以降では4ポイント悪化している駅も存在する。精度が向上したB、C、D駅と精度が悪化したE、F、G駅の違いは、他線の接続の有無である可能性がある。本モデルの説明変数には混雑率を入力していないため、接続のタイミングによる乗客の増減を考慮していない。したがって、遅延原因の比重が先行列車よりも混雑である可能性のある駅は、説明変数に前方駅の情報を入力しても、ノイズとなっていると考えられる。また、モデル3は駅到着時点で分からない先行列車の情報は0で保管している。そのため、ノイズの影響が強く出た可

能性がある。モデル3と先行列車の情報が全てわかっていると仮定したモデル4を比較すると、モデル3に対して予測精度が悪化する駅は1駅でありその他の駅は同等か改善が確認できる。しかも、予測精度が改善した駅は、E、F、G駅であり、G駅においてはモデル1と比較しても改善がみられることから、到着時点で分からない前方駅の情報が重要であった可能性が高いと言える。

モデル2から4を比較すると、先行列車の情報が全てわかっているモデル4の精度が最も高いことが確認できた。しかし、モデル1と比較すると精度が改善されない駅がある。そこで、モデル1とモデル4で許容する実績値と予測値の差の絶対値を3秒、5秒、10秒と変更したときの予測精度を比較した。結果をTable4に示す。Table4より、B、C、D駅において許容値を変更した場合でも予測精度の優位性が変化しないことが確認できる。したがって、前方駅の情報予測精度に寄与していると言える。一方で、モデル1に対してモデル4の精度が悪化していたE、F駅においては、許容する絶対値によって予測精度が改善していることから、ネットワークの構成やハイパーパラメータの調整が十分でない可能性が考えられ、これらの駅では精度が向上する可能性があると言える。しかし、F駅においては全ての許容値でモデル1に対して予測精度が悪化していることから、前方駅の情報ノイズとなっていると言える。

以上のことから、CNNは伝搬する遅延の特徴を捉えることが出来、列車の遅延予測において有効である可能性を示した。また、予測対象列車の予測対象駅より前方のデータは遅延予測に対して有効な説明変数であることを明らかにした。

〈4・4〉 モデル4の予測精度 モデル4を使用して、ある日のG駅における朝ラッシュ時間帯における駅発生遅延を予測し、駅出発遅延時間を算出した結果をFig.5に示す。Fig.5は、縦軸に駅出発遅延時間、横軸に列車を取り、青線がある日の実績遅延時間、橙線が予測値である。

全体として遅延の増加から減少までを予測できていることが分かる。特にラッシュ時間帯における遅延が増加する現象を正確に予測できていることが確認できた。一方で遅延が停滞し、減少していく部分において予測精度が悪い。これは学習データに増加する時間帯以外のデータを含めていないためである。したがって、学習データにより広い時間帯を含めることで遅延が増加する時間帯に限らず正確に予

Table 4. Accuracy by error tolerance.

absolute value	3s		5s		10s	
name	Model1[%]	Model4[%]	Model1[%]	Model4[%]	Model1[%]	Model4[%]
A	38.8	38.6	58.3	57.9	84.0	84.1
B	27.9	30.0	43.9	47.3	72.5	74.2
C	28.4	31.2	43.9	47.8	72.4	75.4
D	32.6	35.3	43.9	51.1	77.8	80.9
E	38.5	41.0	58.5	57.1	86.2	87.1
F	47.0	46.3	69.5	67.8	93.8	91.9
G	42.4	45.0	62.4	65.0	89.8	89.6




Fig. 5. Prediction Accuracy of Model 4.

測できる可能性がある。

5. まとめ

本稿では、実施前の遅延対策を定量的に評価するための列車運行シミュレータの開発を目的として、列車の駅発生遅延を予測する機械学習モデルと入力データ構造を提案し、朝のラッシュ時間帯に発生する小規模な積み重なる遅延を対象に、遅延予測の精度を比較した。その結果、CNNは許容する実績値と予測値の差の絶対値を5秒許容した場合において、平均して50%程度の予測精度であったことから、LSTMよりCNNはより遅延伝搬の特徴を捉えることができることを証明した。また、予測対象駅より前方の駅を説明変数として加えることで予測精度が最大で10ポイント程度向上したことから、提案手法である遅延伝搬の特徴に基づいた説明変数の構築は遅延予測に対して有効であることを確認した。

本稿のネットワークは列車運行実績データから得られる時間のみのデータを用いて、予測できる精度を評価した。しかし、提案手法を用いても予測精度が向上しない駅が存在したことから、混雑率などより遅延寄与する情報を入力する必要があることが分かった。今後は、混雑率と遅延の関係を明確にし、混雑率を考慮した遅延予測手法を構築する必要がある。

文 献

- (1) 秋田雄志 他：鉄道信号，一般社団法人 日本鉄道電気技術協会 (2015)
- (2) 中村英夫：鉄道解体新書，オーム社 (2021)
- (3) 國松武俊，平井力，富井規雄：マイクロシミュレーションを用いた利用者の視点による列車ダイヤ評価手法，電気学会論文誌D（産業応用部門），Vol.130，No.4，pp.459-467，2010
- (4) 辰井大祐，中挾晃介，國松武俊，坂口隆，田中俊一：深層学習を用いた列車遅延予測，鉄道総研報告書，Vol.35，No.3，pp.23-28 (2021)
- (5) 岩本章寛，佐藤剛士，弓田康弘，溝口和人，安河内崇，福井清純：予測ダイヤからの運転整理入力機能の開発，鉄道サイバネ・シンポジウム論文集，51，p.5，2014
- (6) P.Zhou, L.Chen, X.Dai, B.Li, and T.Chai: Intelligent prediction of train delay changes and propagation using RVFLNs with improved transfer learn-

ing and ensemble learning, IEEE Transactions on Intelligent Transportation Systems, vol.22, no.12, pp.7432-7444(2021)

- (7) Y.LeCun, L.Bottou, Y.Bengio, and P.Haffner : Gradient based learning applied to document recognition, Proceedings of the IEEE, vol.86., no.11, pp.2278-2324 (1998)
- (8) A.Graves, S.Fernández, and J.Schmidhuber: Bidirectional LSTM Networks for Improved Phoneme Classification and Recognition, ICANN 2005, pp.799-804 (2005)