

- 1.自前で日本語文を最小化+更に GPT4o で最小化
- 2.gpt4 と google AI studio で英訳
- 3.双方に出力された文章を提示して英語論文として適切な方を聞く
- 4.表現が適切な方をまとめて一つの文章にまとめてから、google AI studio で整える
→仕上げでは google AI studio の方が自然さと明確さを両立できていたため

基本この繰り返しで各セクションを英訳

自前の論文なので伝えたいニュアンスのズレを確認しやすいと思ったため選定

【原文】

2022 年度より,高等学校では情報科目が必修となった.さらに,2025 年からは大学入試共通テスト

トへの情報科目の設置が広く知られている.これは,昨今の情報教育の重要性がより一層高まっ

てきたことを意味している.

日本では,これから目指すべき未来社会の姿として Society5.0 というものを掲げている.内閣府によると Society5.0 では,「サイバー空間とフィジカル空間を高度に融合させたシステムにより,経済発展と社会的課題の解決を両立する,人間中心の社会」のことを指すとしている.そこで求められる人材像の一つに,「様々な分野において AI やデータの力を最大限活用し展開できる人材」というものが含まれており,そのような人材を育む教育が求められており,平成 30 年告示の学習指導要領においても,情報技術を用いて問題を主体的に解決できる人材の育成を目的としている.その中でも,AI を用いた組み込みシステムは情報技術の中核に位置する AI を体験的に学習することができる.

機械学習は,内容としては曖昧になる部分が多くその結果として最適な手法選択,活用が難しい

い.そこで AI を用いた組み込みシステムを教材として用いることで機械学習の学習過程や,実環

境との差異,仮想空間を用いるメリット等を学ぶことができる.よって本研究では,組み込みデ

バイスを用いた機械学習教材の開発を目的とする.

【最小化】

2022 年度より,高等学校では情報科目が必修となった.さらに,2025 年からは大学入試共通テスト

トへの情報科目が設置された.これは,昨今の情報教育の重要性が一層高まったことを意味している.

日本では,これから目指すべき未来社会の姿として Society5.0 を掲げている.内閣府によると Society5.0 は,「サイバー空間とフィジカル空間を高度に融合させたシステムにより,経済発展と社会的課題の解決を両立する,人間中心の社会」のことを指す.そこで求められる人材像の一つに,「様々な分野において AI やデータの力を最大限活用し展開できる人材」が含まれており,そのような人材を育む教育が求められている.平成 30 年告示の学習指導要領においても,情報技術を用いて問題を主体的に解決できる人材の育成を目的としている.その中でも,AI を用いた組み込みシステムは情報技術の中核に位置する AI を体験的に学習することができる.

機械学習は,曖昧な部分が多くその結果として最適な活用が難しい.そこで AI を用いた組み込みシステムを教材として用いることで機械学習の学習過程や,実環境との差異,仮想空間を用いるメリットを学ぶことができる.本研究では,組み込みデバイスを用いた機械学習教材の開発を目的とする.

- ・～設置された.:自分で最小化
- ・そのような人材～:gpt が最小化

【原文】

1. まえがき

2022 年度より，高等学校では情報科目が必修となった．さらに，2025 年からは大学入試共通テストへの情報科目の設置が広く知られている．これは，昨今の情報教育の重要性がより一層高まってきたことを意味している．日本では，これから目指すべき未来社会の姿として Society5.0 というものを掲げている．内閣府によると Society5.0 では，「サイバー空間とフィジカル空間を高度に融合させたシステムにより，経済発展と社会的課題の解決を両立する，人間中心の社会」のことを指すとしている．そこで求められる人材像の一つに，「様々な分野において AI やデータの力を最大限活用し展開できる人材」というものが含まれおり，そのような人材を育む教育が求められており，平成 30 年告示の学習指導要領 1) においても，情報技術を用いて問題を主体的に解決できる人材の育成を目的としている．その中でも，AI を用いた組み込みシステムは情報技術の中核に位置する AI を体験的に学習することができる．そこで本研究では，今現在求められている新たな教材の有用性の評価を目標として，既存の教材と提案する教材の比較検討を行う前段階であるシミュレータと組み込みデバイスを用いた機械学習教材，3 軸姿勢制御モジュール SHISEIGYO-3cube(以下，SHISEIGYO-3)の開発を行った．

2. 本論

2.1 既存の教材

既存の機械学習教材として，レゴエデュケーション SPIKE プライム(以下，SPIKE プライム)が広く用いられている．SPIKE プライムは，株式会社アフレルが販売している情報学習用教材であり，ライントレース走行を行うモジュールを扱うものである．この学習キットは複数の種類が存在し，目的別に様々な学びを得ることができる．その一つとして AI 入門者に向けたプログラミング言語 Python と機械学習フレームワーク TensorFlow を組み合わせた自動走行がある．SPIKE プライムでは，画像データの収集を行い教師データとして加工し，教師データを用いた学習済みモデルの推論による自動走行を実現する過程で，画像処理による制御から教師あり学習や畳み込みニューラルネットワークの仕組みまでを学ぶことができる．また，シミュレータを用いた強化学習を行い自動走行を実現するプロセスも選択できる．一方この教材には，走行制御等の工学的学びがない点と二つの機械学習の長所および短所や問題に適した手法の選択への理解が深まらないという欠点が挙げられる．

2.2 提案する教材

開発する教材 SHISEIGYO-3 は、実機モジュールとシミュレータの二つから構成されている。辺倒立を行うための制御信号をシミュレータを用いて学習し、学習済みモデルを用いて実機上で姿勢制御を行う。本教材では、強化学習についての学びを想定し、シミュレータ上で学習モデルのトレーニングを行い学習済みモデルを実機上で動作させる過程で、機械学習だけでなく PWM 制御といった工学的要素についても学ぶことができる。

2.3 SHISEIGYO-3

SHISEIGYO-3 は、図 1 に示すようなフライホイール付きのリアクションホイールをマイコン ESP32 評価ボードの制御することで辺倒立を行う姿勢制御モジュールである。この辺倒立姿勢制御ロボットは、6 軸慣性センサ MPU6050 から取得した値をカルマンフィルタに通し、モジュールの角度、加速度、角速度の算出を行い、制御に用いる。倒立は作用反作用の法則に基づき実現し、倒れる方向にリアクションホイールを回転させ、反作用によって起き上がる。これを傾きセンシングとモータ制御を高速に繰り返すことによって辺倒立状態を維持する。図 2 に基本的な処理プロセスを示す。

2.4 強化学習

実機に搭載する学習済みモデルとして、エージェントの角度、加速度、角速度を入力値としてホイール制御を行う強化学習モデルの構築を行った。

2.4.1 Unity

本研究では、シミュレーションエンジンとして Unity を用いる。Unity は誰でも無料で利用できるリアルタイム 3D エンジンであり、ゲーム開発やシミュレーション、アプリケーション開発など幅広い用途で用いられている。実機モジュールのモータの回転速度を Unity 上のエージェントやホイールに直接代入すると、値が非常に大きいため正常な処理を行えないことがある。そこで、10 分の 1 程度にダウンスケーリングしてシミュレーションを行った。

2.4.2 ML-Agent

Unity Machine Learning Agents(以下、ML-Agent) は、Unity で作られたシミュレーション環境において機械学習を活用するためのパッケージである。図 3 に ML-Agent の基本構造を示す。ML-Agent は Python 側と通信を行い、Tensorflow または PyTorch を用いて学習を行う。扱える学習アルゴリズムは、ppo, sac の二つとなる。ML-Agent を利用することでエージェントが自己学習によってタスクを習得する強化学習を実現することができる。ML-Agent は、基本的に機械学習の中でも強化学習を扱うことに特化しているツールキットである。サポートする機械学習手法は、強化学習、模倣学習の二つであるが、転用可能な API を用いカスタム学習アルゴリズムを実装することで幅広い手法に対応できる。

2.4.3 学習対象

強化学習は周囲の環境状態に応じた逐次意思決定に適している。SHISEIGYO-3 では、逐次処理を行っている部分はホイールの回転速度制御であり、PWM を用いて制御を行う。MPU6050 からカルマンフィルタを経由し取得できるエージェントの角度、加速度、角速度を入力として、辺倒立を実現できるホイールの回転制御部に対し強化学習を行った。ステップ数は一律 50 万ステップで学習を終了させ、モデルを出力させた。

2.4.4 学習パラメータ

初めは学習アルゴリズムとして ppo を使用したが、辺倒立を実現することができなかった。文献 3) によると、実機ロボットのシミュレーションなどの報酬を獲得することが難しいシミュレータでは、sac を用いることが望ましい旨が示されていた。これは、ppo が現在の状態を用いて学習を行うのに対し、sac は過去の状態を参照し学習を行うためである。ハイパーパラメータとして、学習率を $3.0e-4$ 、バッチサイズを 64、レイヤー数を 2 層とし、学習を行った。学習の様子を図 4、図 5、図 6 に示す。なお、グラフの 3 つの線は特徴的な報酬または Loss 波形を見せた学習をピックアップして載せている。累積報酬は、X 軸がエピソード数、Y 軸が報酬の累積値である。理想的な学習では、学習の進行に応じて増加していくことが望ましい。損失関数は、X 軸がエピソード数、Y 軸が各種 Loss の値である。いずれのグラフも損失が 0 付近に収束することが望ましい。

2.4.5 報酬設計

X 軸角度が 5 度以下 85 度以上の値を取った際に転倒判定として報酬を与えず処理しエピソードを終了させる。報酬の形式として、転倒せずに姿勢を維持した時間毎秒ごとに +0.01 の報酬を加算する。加えて一定時間以上の姿勢を維持した場合にボーナスで報酬を +1.0 与えてそのエピソードを終了させる。最後に 1 フレーム前より目標角度(辺倒立の目標角度は 45 度とする)に対する誤差が小さい場合に +0.001 の報酬を与えた。この報酬設計で学習を進めた際に、初動から 35 万ステップあたりまで順調に学習が進む。しかし、マイナスの報酬を設定していないためある程度の時間を稼ぎ報酬を取得、転倒を繰り返す挙動や、あえて不安定な挙動を取り、その後に目標角度に徐々に近づけることで報酬を大きくする挙動を見せた。そこで、転倒に対し僅かながら負の報酬を与え、直前の目標誤差と現在の目標誤差の差異から報酬を加算するのではなく、誤差の平均値が小さくなることで報酬を獲得できる形に設計した。ここまでの学習では、一定時間を超えたタイミングで各エージェントが転倒し、次のエピソードへ進むことで報酬を獲得し直そうとする。そこで、2 段階目の学習としてここから学習済みのモデルに対し、揺れの抑制と辺倒立を長時間実現するための学習を行った。初期モデルから揺れの抑制と辺倒立の長時間維持を実現する報酬設計では、報酬を獲

得できず学習が進行しない．そのため，学習したモデルを更に学習させるファインチューニングを必要とした．

2.4.6 結果

図 6 に示した試行では，赤線のように最終的に Loss が大きくなる場合や青線のように途中で獲得する報酬が低下する場合も確認できるが，複数回実行することで黄色い線に示されるような理想的な学習結果を取得できた．これは，ロボットのシミュレーションという特性上学習が安定しないため，複数回の試行を必要としていることを意味する．複数回試行した中で，最も安定したモデルをファインチューニングし，5 分間安定した姿勢制御を実現することができた．

2.5 実機搭載

強化学習モデルをマイコンボードに乘せるためにはいくつかの手順が必要となる．学習済みモデルは onnx モデルとして出力されるが ESP32 ではリソースが限られているため，大規模で複雑なニューラルネットワークモデルの直接実行は困難である，そのため，まずモデルの量子化やプルーニングを用いて onnx モデルの簡略化を行う．次に，ESP32 では，onnx をサポートしていないためモデルの変換を行う．用いる形式はスマートフォン上などで動作させることができるモデルである TensorFlow Lite(以下，TFLite 形式) を用いる，ESP32 では，TensorFlow Lite for Microcontrollers(以下，TFLM) を利用してモデルの実行が可能である．カルマンフィルタを用いた位置推定を含む入力値をモデルに与え，フィードバック制御を行う．このとき，取得したモジュールの各種データの誤差，伝達遅延を，あらかじめシミュレータ側で疑似的に再現することで対処する．

3. あとがき

本研究では，機械学習教材開発を目的として，シミュレータの構築および学習モデルを搭載した実機の開発を行った．教材としての扱いやすさの観点からシミュレータのエンジンとして Unity を，ツールキットとして ML-Agent を用いた．SHISEIGYO-3 では，強化学習の仕組みの理解に加え姿勢制御という教師あり学習や教師なし学習による実現が難しい問題を扱うことにより，強化学習が適した問題への理解を促すことができる．また，他の既存の教材にない特徴として，過学習の直観的な理解およびその解決方法について学ぶことができる．今後の展望として，情報科の学部生に既存の機械学習の講義で用いられるペーパーテストや，既存の教材を用いた実習，提案する教材を用いた実習を行いアンケート方式を用いてそれぞれ比較検討を行う

【英語論文化】

Information Science became mandatory in high schools in the 2022 academic year and will be included in university entrance exams from 2025, highlighting the increased importance of IT education. Japan envisions its future society as Society 5.0, described by the Cabinet Office as a human-centered society that integrates cyberspace and physical space to balance economic progress with social problem-solving. Achieving this vision requires talent capable of effectively utilizing AI and data across various fields, **a need** emphasized by the 2018 curriculum guidelines which aim to foster such individuals. Therefore, using AI-embedded systems as teaching tools can elucidate ML processes, the differences between real and virtual environments, and the benefits of virtual spaces. This research aims to develop ML teaching materials using embedded devices.

SHISEIGYO-3 is a posture control module that uses a reaction wheel with a flywheel, controlled by an ESP32 evaluation board, to achieve edge-standing. The module calculates its angle, acceleration, and angular velocity by passing values from a 6-axis inertial sensor (MPU6050) through a Kalman filter. It maintains the edge-standing posture by rapidly repeating tilt sensing and motor control, rotating the reaction wheel in the direction of the fall to create a counteracting force that brings it back upright.

For the simulation engine, Unity was used for its ease of use. The Unity Machine Learning Agents (ML-Agent) toolkit was utilized, which is a package for machine learning in simulation environments created with Unity. The ML-Agent communicates with Python and uses TensorFlow or PyTorch for learning. The supported learning algorithms are ppo and sac.

A reinforcement learning model was built to control the wheels, using the agent's angle, acceleration, and angular velocity as inputs. The study initially used the ppo learning algorithm but was unable to achieve edge-standing. Based on a reference, sac was found to be more suitable for simulators where it is difficult to obtain rewards, such as in real-robot simulations, because it references past states for learning while ppo learns from the current state. After multiple trials, an ideal learning result was obtained. The most stable model from these trials was fine-tuned, and stable posture control was achieved for five minutes.

To deploy the reinforcement learning model onto a microcontroller board, the model, which is output as an onnx model, needs to be simplified due to the ESP32's limited resources. This is done through quantization and pruning. The model is then converted to the TensorFlow Lite (TFLite) format, which the ESP32 can execute using TensorFlow Lite for Microcontrollers

(TFLM). The input values, which include position estimates from a Kalman filter, are fed into the model to perform feedback control. To address errors and transmission delays from the sensor data, these factors are simulated in the simulator beforehand.