

英語論文レポート課題

精密機械工学専攻 5013 戴佳俊

本翻訳では、まず原文となる日本語論文を「最小主義」の観点から簡潔かつ明瞭な表現に整えた後、英訳を実施した。翻訳にあたっては、PPT 資料で示された「技術英語翻訳の 5 つの主義」を AI に明示し、それに基づいた出力を得るよう依頼した。

使用した AI は以下の 2 種類である：

- ChatGPT (o4-mini-high, OpenAI)
- Google AI Studio

両者から得られた英文を比較し、前述の主義に照らして最も適切と判断される表現を選定・採用した。

日本語論文：運動想起時脳波の機械学習による手の開閉動作判別に関する一検討

原文

はじめに

腕の皮膚の表面に付けた電極センサで筋電位を検出し、手を握る、開くなどの動作させる人体装着ロボット（筋電義手）の検討が行われている [1]。筋電位は脳からの指令（信号）で発生されるので、その脳波信号を検出・識別できれば、ロボットを制御できることになる。その実現のため、ブレイン・マシン・インターフェース [2]、脳波による人工手の制御 [3]、脳波の機械学習からの左右の手の動作の識別 [4] [5] など多くの研究が行われている。しかし、動作識別に用いる脳波特徴量も明確になっているとは言えない。また、脳波検出において、被験者の頭部に膨大な数の電極を取り付ける必要があり、被験者に大きな負担となる。

これまで、少ない電極数で測定した脳波で義手を制御することを目的に、右手の開閉動作時の脳波を測定し、時間周波数解析を行い、動作に関連する脳波の特徴抽出を検討した [6]。

その結果、動作によって異なる周波数成分に変化（パターン）が見られた。そのパターンを機械学習させることで、開閉動作を判別できる可能性がある。画像認識の分野では、たたみ込みニューラルネットワーク（CNN）がよく用いられており、精度を上げている [7]。

本研究では、義手の制御に用いる脳波信号の抽出を目的とし、手の開閉運

動想起時の脳波（EEG）を 13 ch で測定した。
時間一周波数解析により求めた、 α 波など各周波数帯のパワーの時間変化パターンを CNN に学習させて動作判別を試みた。

最小化

腕の皮膚表面に装着した電極センサで筋電位を検出し、手を握る・開くといった動作を行う人体装着型ロボット（筋電義手）が検討されている [1]。筋電位は脳からの指令（信号）で発生するため、その脳波信号を検出・識別できれば、ロボットを制御できる。この実現に向けて、ブレイン・マシン・インターフェース [2]、脳波による人工手の制御 [3]、脳波の機械学習を用いた左右の手の動作識別 [4] [5] など多くの研究がなされている。しかし、動作識別に用いる脳波特徴量は未だ明確ではない。また、脳波検出では被験者の頭部に多数の電極を取り付ける必要があり、被験者への負担が大きい。我々はこれまで、少ない電極数で測定した脳波による義手制御を目的に、右手の開閉動作時の脳波を測定し、時間一周波数解析によって動作関連脳波特徴の抽出を検討してきた [6]。その結果、動作に応じて周波数成分に異なる変化（パターン）が確認された。これらのパターンを機械学習モデルに学習させることで、開閉動作を判別できる可能性がある。画像認識分野では、畳み込みニューラルネットワーク（CNN）が広く用いられ、精度向上に貢献している [7]。

本研究では、義手制御に用いる脳波信号の抽出を目的とし、13 チャンネルで手の開閉運動想起時の脳波（EEG）を測定した。そして、時間一周波数解析から得られた α 波など各周波数帯のパワーの時間変化パターンを CNN に学習させ、動作判別を試みた。

英 ChatGPT o4mini-high

Introduction

Researchers are investigating myoelectric prosthetic hands—wearable robotic devices that use electrode sensors on the arm’s skin to detect muscle potentials and execute grasp and release movements [1]. Because these potentials originate from brain signals, detecting and identifying electroencephalogram (EEG) signals should enable direct prosthetic control. To this end, studies have explored brain-machine interfaces [2], EEG-based control of artificial hands [3], and machine learning-based classification of left- and right-hand movements from EEG [4][5]. However, the EEG features effective for movement classification remain unclear, and EEG acquisition still

requires attaching numerous electrodes to the scalp, imposing a significant burden on participants.

In our previous work, we recorded EEG during imagined right-hand opening and closing using a reduced number of electrodes to develop prosthetic control methods [6]. Time-frequency analysis revealed distinct frequency patterns for each movement. Machine learning models trained on these patterns may discriminate opening and closing movements. In image recognition, convolutional neural networks (CNNs) have significantly improved classification accuracy [7].

This study aims to extract EEG signals for prosthetic hand control by recording 13-channel EEG during imagined hand opening and closing. We applied time-frequency analysis to extract time-varying power patterns in frequency bands—such as alpha waves—and trained a CNN to classify these movements.

英 Google AI studio

Introduction

Myoelectric prostheses control hand movements, such as grasping and opening, by detecting muscle signals from the arm's surface using electrode sensors [1]. The brain originates the commands for this muscle activity. Therefore, directly detecting and identifying the underlying brain signals—electroencephalography (EEG)—could enable prosthetic control. This potential has driven extensive research into Brain-Machine Interfaces (BMIs) [2], EEG-based prosthetic hand control [3], and machine learning models that use EEG to discriminate between left and right hand movements [4, 5].

However, two challenges persist. First, the specific EEG features that best identify movements remain unclear. Second, conventional EEG recording requires attaching numerous electrodes to the scalp, which places a significant burden on the user.

Our previous research aimed to control a prosthesis using EEG from fewer electrodes [6]. We recorded EEG during right-hand opening and closing movements and used time-frequency analysis to extract movement-related features. The results revealed distinct patterns in frequency components that corresponded to each movement. These

patterns suggest that a machine learning model could learn to discriminate between opening and closing actions. In image recognition, Convolutional Neural Networks (CNNs) are widely used to improve classification accuracy [7].

In this study, we aim to extract effective EEG signals for prosthesis control. We recorded 13-channel EEG as subjects imagined opening and closing their hand. We then extracted the time-varying power patterns from frequency bands, such as the alpha band, and trained a CNN on these patterns to discriminate between the imagined movements.

原文

2. 運動想起時の脳波測定

2. 1 課題 手の開閉動作想起時の脳波を測定するため、次の 4 つの課題 (Task) を被験者に与えた。

- Task I-a: 右手を握りながら、手を握るイメージをする
- Task I-b: 右手を開きながら、手を開くイメージをする
- Task II-a: 右手を握るイメージのみをする
- Task II-b: 右手を開くイメージのみをする

Task I は, CNN の学習に用いるデータ作成用であり, 手の力を抜いたリラックス状態から, 被験者の任意のタイミングで動作とそのイメージ(運動想起)を約 6s 行わせた。Task II はテストデータ作成用であり, リラックス状態で 2s 経過後に, 動作を約 6s 間イメージ(運動想起)させた(手は動かさない)。各 Task の測定時間は約 10 s であり, それぞれ 30~50 回行った。また, リクライニングチェアに座らせ, 測定時は開眼状態とし, 瞬きをしないようにお願いした。被験者は同意書を得た健康な男性 5 人 (21~23 歳) とした。

2. 2 脳波測定方法

Fig. 1 の測定系を用いて, 脳波 (EEG) と筋電図 (EMG) の同時測定を行った。脳波測定の電極配置は国際 10/20 法に従い, Fz, Fp1, Fp2, F3, F4, F7, F8, Cz, C3, C4, T3, T4, Pz の 13 箇所とし, G を接地電極, A1 と A2 を連結し基準電極とした。筋電図測定の電極は浅指屈筋に配置した。各信号を, HUM フィルタと 0.5-300 Hz のバンドパスフィルタを持つ増幅器 (脳波: 80 dB, 筋電位: 66 dB) を通した後, サンプリング周波数 1 kHz, 量子

化ビット数 16 bit でコンピュータに取り込み、記録した。Task(a)と(b)では、筋電位の立ち上がり時刻を動作の開始時刻とした。

最小化

2.1 課題

脳波測定のため、被験者に以下の4課題を実施させた。

- Task I-a : 右手を握りつつ握るイメージ
- Task I-b : 右手を開きつつ開くイメージ
- Task II-a : 握るイメージのみ
- Task II-b : 開くイメージのみ

TaskI はCNN 学習用データ取得を目的とし、リラックス状態から任意のタイミングで約6秒間運動想起を行った。TaskII はテスト用データ取得を目的とし、リラックス後2秒経過してから約6秒間想起を実施した（手は静止）。各課題の持続時間は約10秒、各30～50回繰り返した。被験者は同意を得た健康な男性5名（21～23歳）。測定中はリクライニングチェア着座、開眼および瞬き抑制を指示した。

2.2 測定方法

Fig. 1の装置を用い、EEGとEMGを同時記録した。EEG電極は国際10/20法に従いFz、Fp1、Fp2、F3、F4、F7、F8、Cz、C3、C4、T3、T4、Pzの13点を配置し、Gを接地、A1/A2を基準とした。EMG電極は浅指屈筋に設置した。各信号はHUMフィルタおよび0.5-300 Hzバンドパスフィルタ付き増幅器（EEG: 80 dB、EMG: 66 dB）を通し、1 kHz、16 bitで記録した。運動開始時刻は筋電位の立ち上がりで定義した。

英 ChatGPT o4-mini-high

2.1 Tasks

Subjects performed four tasks for EEG recording:

- Task I-a: imagined hand closing while grasping
- Task I-b: imagined hand opening while extending
- Task II-a: imagined hand closing only

- Task II-b: imagined hand opening only

Task I supplied CNN training data: from a relaxed state, subjects performed 6 s of motor imagery at arbitrary times. Task II supplied test data: after 2 s of relaxation, subjects performed 6 s of imagery (hand stationary). Each trial lasted ~10 s and was repeated 30-50 times. Five healthy male subjects (21-23 years) participated with informed consent. During recording, subjects sat in a reclined chair with eyes open and minimized blinking.

2.2 Recording

Using the setup in Fig. 1, we recorded EEG and EMG simultaneously. EEG electrodes were placed at 13 sites (Fz, Fp1, Fp2, F3, F4, F7, F8, Cz, C3, C4, T3, T4, Pz) per the international 10/20 system, with G as ground and A1/A2 as reference. We placed EMG electrodes on the flexor digitorum superficialis. We filtered signals with a HUM filter and a 0.5-300 Hz bandpass filter (EEG: 80 dB; EMG: 66 dB), sampled them at 1 kHz with 16-bit resolution, and defined motor onset by EMG activation.

英 Google AI studio

2.1 Experimental Tasks

To record electroencephalography (EEG), we instructed subjects to perform the following four tasks:

- Task I-a: Physically clench the right hand while imagining the action.
- Task I-b: Physically open the right hand while imagining the action.
- Task II-a: Only imagine clenching the right hand (motor imagery).
- Task II-b: Only imagine opening the right hand (motor imagery).

We designed Task I to acquire training data for the Convolutional Neural Network (CNN). Starting from a relaxed state, subjects initiated the action and imagery for approximately 6 seconds at their own timing. We designed Task II to acquire testing data. After a 2-

second relaxation period, subjects performed the motor imagery for approximately 6 seconds while keeping their hand still.

Each trial lasted about 10 seconds, and we repeated each task 30 to 50 times per subject. Five healthy male subjects (ages 21-23) participated after providing informed consent. During the recordings, we instructed subjects to sit in a reclining chair, keep their eyes open, and minimize blinking.

2.2 Data Acquisition

We simultaneously recorded EEG and electromyography (EMG) using the equipment shown in Fig. 1.

We placed 13 EEG electrodes on the scalp according to the International 10/20 system at the following locations: Fz, Fp1, Fp2, F3, F4, F7, F8, Cz, C3, C4, T3, T4, and Pz. The ground electrode was placed at G, and the linked earlobes (A1/A2) served as the reference. We placed EMG electrodes over the flexor digitorum superficialis muscle.

We passed both signals through an amplifier equipped with a HUM filter and a 0.5-300 Hz band-pass filter. The amplification gain was 80 dB for EEG and 66 dB for EMG. Finally, we digitized the signals at a sampling rate of 1 kHz with 16-bit resolution. We defined the onset of movement as the point where the EMG signal began to rise.

原文

3. 学習用データの作成

脳波信号に対して、解析フレーム長(ハミング窓)1 s, シフト長 0.1 s, 1024 点 FFT とした時間-周波数解析を行った。Task I では、動作を開始した時刻を、EMG から検出した。脳波情報として、 α 波 (8-13 Hz) , β 波 (13-30 Hz) , θ 波 (4-8 Hz) , δ 波 (0.5-3 Hz) 成分のパワーを求めた。Fig. 2 に Task Ia の結果の例を示す。約 2 s に手を握り始め、その頃から α 波と β 波成分のパワーが大きく変化している。そこで、Fig. 3 に例を示すように、動作開始後からの 3 s 間について、 α 波など各周波数帯のパワーを抽出し、縦軸を電極位置、横軸を時間とするパワーの時間変化パターン(スペクトルパターン)を作成した。動作によって、 α 波と β 波のパワーが大きくなる時刻に違いが見られる。このスペクトルパターンを学習・

判別用のデータとする。

最小化

3. 学習用データ作成

脳波信号に対し、解析フレーム長 1 s (ハミング窓)、シフト長 0.1 s、1024 点 FFT で時間-周波数解析を実施した。Task I では、EMG で検出した動作開始時刻を基準に、 α 波 (8-13 Hz)、 β 波 (13-30 Hz)、 θ 波 (4-8 Hz)、 δ 波 (0.5-3 Hz) のパワーを算出した (Fig. 2)。動作開始約 2 s 後に $\alpha \cdot \beta$ 波パワーが変化するため、動作開始から 3 s 間の各周波数帯パワーを抽出し、縦軸に電極位置、横軸に時間をとったスペクトルパターンを作成した (Fig. 3)。これを学習・判別用データとする。

ChatGPT o4mini-high

3. Training Data Preparation

We applied time-frequency analysis to EEG signals using a 1 s Hamming window, 0.1 s shift, and a 1024-point FFT. In Task I, we detected movement onset via EMG and computed power in the alpha (8-13 Hz), beta (13-30 Hz), theta (4-8 Hz), and delta (0.5-3 Hz) bands (Fig. 2). Because alpha and beta power began to change about 2 s after onset, we extracted each band's power over the 3 s following movement onset and generated spectral patterns with electrode position on the vertical axis and time on the horizontal axis (Fig. 3). We used these patterns as training and classification data.

Google AI studio

3. Preparing the Training Data

We performed a time-frequency analysis on the recorded electroencephalography (EEG) signals. To do this, we applied for a Short-Time Fourier Transform (STFT) with a 1024-point Fast Fourier Transform (FFT), using a 1-second analysis window (Hanning window) that we shifted in 0.1-second increments.

For the Task I data, we first identified the movement onset using the electromyography (EMG) signal. Using this onset as the reference time point, we calculated the power in the alpha (8-13 Hz), beta (13-30 Hz), theta (4-8 Hz), and delta (0.5-3 Hz) frequency bands (Fig. 2).

We observed that the power in the alpha and beta bands changed approximately 2 seconds after the movement began. Based on this, we extracted a 3-second segment of power data for each frequency band, starting from the movement onset. From this segment, we created a spectral pattern image where the vertical axis represents the electrode locations, and the horizontal axis represents time (Fig. 3). We used these images as the final dataset for training and testing our model.

原文

4. CNN を用いた手の開閉動作の判別の試み

4.1 学習・判別方法 運動想起時の脳波から「右手を握る

(Close)」, 「右手を開く (Open)」の動作の判別を試みた。ここでは、2つのたたみ込み層とプーリング層で構成される LeNet [7] を基本構造とする、活性化関数を ReLU とした CNN を用いた。

学習データには、右手の開閉動作時の Task I のスペクトルパターンを用いた。データ数は各動作 30~50 個であり、その内の 10%を検証データとした。テストデータ用には、運動想起のみの Task II のイメージ開始後 3 s 間のパターンを用いた。また、テストデータ数は各 30~50 個である。

4.2 結果と考察 学習 (検証) 結果を Table 1 に示す。A11 は全ての脳波成分をまとめた場合、 α , β などは各成分のパターンのみを学習・判別に用いた結果である。被験者によって判別精度 (正答率) が異なるが、A11 の精度が低く、 α 波, β 波, θ 波成分の場合に比較的良好な結果が得られた。動作判別に有効である可能性が示唆される。未学習の運動想起時のパターンを用いた判別結果を Table 2 に示す。Table 1 と同様な傾向であるが、全体的に精度が低い結果となった。これは、実際に手を動かした場合と動かさない (運動想起のみの) 場合で、脳波の現れ方に違いがあることが考えられる。また、同じ被験者でも、試行によって脳波パターンが異なる場合が見られ、学習させるデータに工夫が必要と考えられる。動作をしていない状態の判別も必要であり、これらの検討は今後の課題である。

最小化

4. CNN を用いた手の開閉動作識別

4.1 学習・判別方法

運動想起時の EEG から「右手を握る (Close)」と「右手を開く (Open)」を識別するため、LeNet 構造 (畳み込み層 2+プーリング層、活性化関数 ReLU) の CNN を用いた。学習には Task I のスペクトルパターンを使用し、各動作 30~50 試行中 10 %を検証用に割り当てた。テストには Task II の想起開始後 3 s 間のスペクトルパターンを用い、各動作 30~50 試行を実施した。

4.2 結果と考察

Table 1 に学習 (検証) 結果を示す。全周波数帯 (All) と、各周波数帯 (α 、 β 、 θ 、 δ) 別の識別精度を比較したところ、被験者間でばらつきはあるが、 $\alpha \cdot \beta \cdot \theta$ 帯が All より高い精度を示し、動作識別に有効である可能性を示唆した。Table 2 は想起のみデータの識別結果を示す。全体的に精度は低下し、実動作と想起の EEG パターン差、被験者内・試行ごとの変動が原因と考えられる。今後は想起と実動作時の EEG 差や被験者内変動を考慮したデータ設計および、非動作状態の識別方法を検討する必要がある。

ChatGPT o4mini-high

4. CNN-Based Classification of Hand Opening and Closing Movements

4.1 Training and Classification

We used a CNN based on the LeNet architecture (two convolutional layers, pooling layers, ReLU activation) to classify “Close” versus “Open” from EEG during motor imagery. We trained the network on spectral patterns from Task I, allocating 10 % of 30-50 trials per class for validation. We tested the model on spectral patterns from the first 3 s after imagery onset in Task II, using 30-50 trials per class.

4.2 Results and Discussion

Table 1 shows validation accuracies for all frequency bands (“All”) and for individual bands (alpha, beta, theta, delta). Although accuracy varied across subjects, the alpha, beta, and theta bands outperformed “All,” suggesting their suitability for movement classification. Table 2 presents classification results using imagery-only data; overall accuracy declined, likely due to

differences between actual and imagined EEG patterns and intra-subject variability. Future work will address EEG differences between imagery and execution, intra-subject variability, and discrimination of non-movement states.

Google AI studio

4. Discriminating Hand Movements Using a CNN

4.1 Training and Evaluation Method

We used a Convolutional Neural Network (CNN) to discriminate between imagined right-hand "Close" and "Open" movements from the EEG data. The network used a LeNet-based architecture, which includes two convolutional-pooling layers and the ReLU activation function.

To train the model, we used the spectral pattern images generated from Task I. From the 30-50 trials available for each movement, we set aside 10% for validation. To test the model, we used the spectral pattern images generated from the first 3 seconds of motor imagery in Task II, evaluating it on all 30-50 trials for each movement.

4.2 Results and Discussion

Table 1 presents the training and validation results. We compared the classification accuracy using data from all frequency bands combined ("All") against using data from the alpha, beta, theta, and delta bands individually. Although performance varied across subjects, the models trained on the alpha, beta, and theta bands each achieved higher accuracy than the "All" bands model. This result suggests these specific bands are highly informative for movement classification.

Table 2 shows the classification results on the motor-imagery-only data (Task II). The overall accuracy was lower on this dataset. We attribute this performance decline to two factors: the difference in EEG patterns between executed and imagined movements, and the high variability within each subject and across trials.

Future work must address these issues. We need to design experiments that account for the discrepancies between imagined and executed movements and also develop methods to reliably classify the non-

movement (idle) state.

原文

5 . おわりに

右手の開閉動作時の脳波を CNN で学習させることにより、運動想起時の脳波で動作を判別できる可能性が得られた。今後、被験者を増やし、精度の向上、およびより少ない電極数による脳波で判別する方法を検討する予定である。最後に、実験に協力頂いた被験者に感謝する。

最小化

5. おわりに

本研究では、CNN を用いて右手開閉動作時の EEG を学習させ、運動想起中の動作識別の可能性を示した。今後は被験者数を増やし、精度向上と少電極での識別方法を検討する。実験協力者に感謝する。

ChatGPT o4mini-high

5. Conclusion

This study demonstrated that a convolutional neural network trained on EEG recorded during right-hand motor imagery can classify opening versus closing movements. Future work will expand the subject pool, improve classification accuracy, and investigate methods for EEG-based discrimination using fewer electrodes. We thank the participants for their cooperation.

Google AI studio

5. Conclusion

In this study, we trained a Convolutional Neural Network (CNN) on electroencephalography (EEG) data recorded during executed hand movements. We demonstrated that this model can then discriminate between imagined opening and closing movements, confirming the potential of this approach.

In future work, we will recruit more subjects to improve

classification accuracy and develop methods that achieve reliable discrimination using fewer electrodes.

Acknowledgements

We thank the participants for their cooperation.

第一段落

ChatGPT と Google AI Studio の出力を比較し、それぞれの特徴を以下の観点で分析した：

1. 最小主義の観点では、ChatGPT は冗長な言い回しを避け、短く簡潔な構文を用いる傾向がある（例：Researchers are investigating myoelectric prosthetic hands—wearable robotic devices that use electrode sensors on the arm’s skin to detect muscle potentials and execute grasp and release movements）。
2. 一方、動詞主義・能動態主義においては、Google は明確な主語と動作の流れを意識した表現が多く見られた（例：The brain originates the commands for this muscle activity. Therefore, directly detecting and identifying the underlying brain signals—electroencephalography (EEG)—could enable prosthetic control. This potential has driven extensive research into Brain-Machine Interfaces (BMIs) [2], EEG-based prosthetic hand control [3], and machine learning models that use EEG to discriminate between left and right hand movements [4, 5].）。
3. 具体化主義の面では、Google 版は「課題を2つに分けて提示する」など、構造面でも明確さがあり、より論理的な記述となっている（However, two challenges persist. First, the specific EEG features that best identify movements remain unclear. Second, conventional EEG recording requires attaching numerous electrodes to the scalp, which places a significant burden on the user.）。

以上より、技術英語としての論理性と動詞中心性を優先し、Google 版の表現を選定した。

第二段落

ChatGPT と Google AI Studio の出力を比較し、それぞれの特徴を以下の観点で分析した：

まず、動詞主義および能動態主義の観点では、Google 版は明確な主語と動作（例：We instructed、We designed、We recorded）を使用しており、手順や目的が明快であった。これは読者に対する説明責任が求められる学術文書として重要な特性である。

次に、語順主義においても、Google 版は目的→方法→結果の流れに沿った構文が多く、文の理解がスムーズであった。

また、具体化主義の点でも、Google 版は抽象的な行動を避け、例えば「Physically clench the right hand」「keep their hand still」など具体的な表現を用いており、再現性の高い記述となっている。

以上より、Google 版の表現を選定した。

第三段落

ChatGPT と Google の両バージョンを比較した結果、以下の点が明らかとなった：

- ChatGPT は最小主義を強く反映し、1 文あたりの情報量が多く簡潔で読みやすい（例：We applied time-frequency analysis to EEG signals using a 1 s Hamming window, 0.1 s shift, and a 1024-point FFT. We applied time-frequency analysis to EEG signals using a 1 s Hamming window, 0.1 s shift, and a 1024-point FFT.）。
- Google は「STFT」や「reference time point」などの用語を明示することで具体化主義に優れており、論文としての専門性を高めている（例：We performed a time-frequency analysis on the recorded electroencephalography (EEG) signals. To do this, we applied for a Short-Time Fourier Transform (STFT) with a 1024-point Fast Fourier Transform (FFT), using a 1-second analysis window (Hanning window) that we shifted in 0.1-second increments. We performed a time-frequency analysis on the recorded electroencephalography (EEG) signals. To do this, we applied a Short-Time Fourier Transform (STFT) with a 1024-point Fast Fourier Transform (FFT), using a 1-second analysis window (Hanning window) that we shifted in 0.1-second increments.）。

- 動詞主義・能動態主義の観点では、Google の “We observed...” や “we created...” といった動作を明確に述べる表現が際立っていた。

以上より、Google AI Studio の翻訳を選定した。

第四段落

ChatGPT と Google の出力を比較した結果、以下の通り特徴が見られた：

- 最小主義の観点からは ChatGPT が簡潔に構造をまとめ、短い文で情報を伝達している（例：4.1 の手法説明）。
- 具体化主義と語順主義の観点では、Google の表現が情報の流れや因果関係、数値や理由の明示が優れており、結果の考察部分（4.2）において特に学術的な明瞭さを感じた。
- 能動態主義・動詞主義 の点でも Google は “We attribute...” “We need to design...” など主語と動作を明示する表現が多く、読者に対する行動的提案が伝わりやすい。

以上の理由により、第4段については Google AI Studio の翻訳を選定した。

比較の結果、Google AI Studio は 動詞中心 ・ 能動態 ・ 具体化 に優れており、学術論文にふさわしい論理的な表現が多く見られました。特に “We trained...” や “This suggests...” など、主語と動作が明確で、学術的な文章構成に適していました。一方で、ChatGPT は 簡潔さ に優れた出力が多く、必要に応じて簡明な表現として取り入れました。

段落ごとの選定方針は以下の通りです：

- 第1段では Google の具体性と動詞主義を重視
- 第2・3段では Google の構文的明快さを活かしつつ、ChatGPT の簡潔な語句も一部採用
- 第4段では モデル訓練と結果解釈の説明が丁寧な Google 出力を採用
- 第5段では Google の形式的な構成をベースに、学術論文らしいまとめと謝辞を反映

以上より、本翻訳は 技術的正確性と英語としての自然さを両立 させることを目指し、AI 出力の長所を活かしつつ、五つの主義に即した適切な表現選択

を行いました。

以上の5つの段落における比較検討の結果、Google AI Studio の翻訳を中心に採用することとした。理由として、Google の出力は全体的に動詞主義・能動態主義・具体化主義の観点からより明確かつ論理的な記述が多く、学術文書としての表現に優れていたためである。一方で、ChatGPT の出力には最小主義や自然な語順が活かされた部分もあり、簡潔性において参考となる表現も見られた。