

ブラウン橋拡散モデルを用いた造影背臥位乳房 MRI の生成に関する研究

A Study on The Generation of Contrast-Enhanced MRI in Supine Position Using Brownian Bridge Diffusion Models

指導教員 細野裕行 教授, 関弘翔 助教

1047 佐々木颯

1. まえがき

造影腹臥位MRIは腫瘍を捉えるのに適したモダリティであり、乳房温存手術の術前診断として使用される。しかし、手術時は背臥位であり、乳房の形状変化に伴い腫瘍の位置も変化してしまう。このため、造影腹臥位 MRI の情報を手術に直接利用できず、医師は経験的に切除範囲を決定する必要がある。この問題に対し、造影腹臥位・背臥位 MRI を用いて、腫瘍の位置を皮膚にプロジェクションマッピングする技術¹⁾がある。これによって、造影 MRI の情報の直接利用が可能となるが、身体的・経済的なコストから造影背臥位 MRI は撮影されにくい。よって、造影背臥位 MRI に近いデータを獲得する別の手法が求められている。このことから本研究では Image-to-Image(I2I)モデルを用いて、非造影・造影腹臥位 MRI と非造影背臥位 MRI から造影背臥位 MRI を得る手法を検討している。データ数が豊富な腹臥位 MRI における非造影像から合成造影像へ変換するモデルを構築し、背臥位 MRI 用にモデルを転移することで実現を図る。

先行研究^{2,3)}では、CycleGAN⁴⁾を用いて腹臥位 MRI における非造影像と造影像の相互変換を実現したが、信号強度が大きく異なる、腫瘍が白く染まらないといった問題点があった。

本研究では、CycleGAN より学習が安定しており、生成品質で優れているとされる拡散モデル⁵⁾ベースの Brownian Bridge Diffusion Models(BBDM)⁶⁾を腹臥位における非造影像から合成造影像の変換に応用することで上記問題の改善について取り組んだ。

2. 方法と使用する I2I モデル

2.1 データセットと前処理

モデルの学習、推論には日本大学医学部から提供されている腹臥位 MRI を使用した。ただし、データによって値域が大きく異なっており、外れ値が存在しているため、Min-Max 法を用いて[0, 1]に正規化を行った。また、データは(92, 212, 212)の形状にトリミングした。表 1 に Train, Test データの例数を示す。

2.2 定量評価手法

変換したデータに対する定量評価手法として、Root Mean Squared Error(RMSE), Peak Signal-to-Noise Ratio(PSNR), Structural Similarity Index(SSIM)⁷⁾を使用した。式(1), (2), (3)~(6)にそれぞれ、RMSE, PSNR, SSIM を示す。ただし、 $\mathbf{x}$ は元データ、 $\hat{\mathbf{x}}$ は変換データ、 μ は平均、 σ は分散、 cov は共分散、 N はボクセル数とする。

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (1)$$

$$PSNR = 10 \log_{10} \frac{MAX(=1)^2}{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (2)$$

$$SSIM = [l(\mathbf{x}, \hat{\mathbf{x}})] \cdot [c(\mathbf{x}, \hat{\mathbf{x}})] \cdot [s(\mathbf{x}, \hat{\mathbf{x}})] \quad (3)$$

$$l(\mathbf{x}, \hat{\mathbf{x}}) = \frac{2\mu_{\mathbf{x}}\mu_{\hat{\mathbf{x}}} + \text{const}}{\mu_{\mathbf{x}}^2 + \mu_{\hat{\mathbf{x}}}^2 + \text{const}} \quad (4)$$

$$c(\mathbf{x}, \hat{\mathbf{x}}) = \frac{2\sigma_{\mathbf{x}}\sigma_{\hat{\mathbf{x}}} + \text{const}}{\sigma_{\mathbf{x}}^2 + \sigma_{\hat{\mathbf{x}}}^2 + \text{const}} \quad (5)$$

$$s(\mathbf{x}, \hat{\mathbf{x}}) = \frac{2cov_{\mathbf{x}\hat{\mathbf{x}}} + \text{const}}{\sigma_{\mathbf{x}}\sigma_{\hat{\mathbf{x}}} + \text{const}} \quad (6)$$

2.3 3D-BBDM (提案 I2I モデル)

3D-BBDM は BBDM を 3 次元データ(MRI)に対応できるように拡張したものであり、ドメイン A から B への変換を目的とした学習を行う。また、Forward Process, Reverse Process を Vector Quantized Generative Adversarial Networks(VQGAN)⁸⁾の Latent Space で行っている。

2.4 3D-cBBDM (提案 I2I モデル)

3D-cBBDM は、3D-BBDM に条件付けの機構を追加したものである。U-Net⁹⁾へデータを入力する際に、条件データを加えることで条件付けを実現した。条件付けの機構を追加した理由は、非造影像から合成造影像へ変換する際に腫瘍の位置を明確に再現するためである。

条件として加えるデータは、造影像に対して一定の閾値以上のボクセルだけを取り出し、VQGAN よって埋め込み表現にしたものである。これによって、造影剤によって白くなった(腫瘍の位置が白くなった)部分だけを取り出すことが可能となる。

2.5 VQGAN

VQGAN は次元圧縮に用いられる。Encoder を用いて入力 $\mathbf{x}$ を潜在変数 $\mathbf{z}$ に変換し、式(7)で各ボクセルと $\mathbf{z}_k$ (Codebook)の差が最小となるような $\mathbf{z}_q$ に量子化を行う。

$$\mathbf{z}_q = q(\mathbf{z}) := \operatorname{argmin}_{\mathbf{z}_k} \|\mathbf{z}_{ij} - \mathbf{z}_k\| \quad (7)$$

この量子化された $\mathbf{z}_q$ を Decoder に通すことで再構築データ $\hat{\mathbf{x}}$ を得る。

2.6 CycleGAN

CycleGAN は I2I モデルであり、データ $\mathbf{x}$ をデータ $\hat{\mathbf{y}}$ に変換する Generator $\mathbf{G}$ とデータ $\mathbf{y}$ をデータ $\hat{\mathbf{x}}$ に変換する Generator $\mathbf{F}$ 、変換結果を識別する Discriminator $\mathbf{D}_X, \mathbf{D}_Y$ で構成される。

3. I2I モデルの学習と推論

3.1 腹臥位用 VQGAN の学習

構築する VQGAN は、非造影像用と造影像用の 2 種類であり、表 1 に示した Train データを用いて学習を行った。表 2 に非造影像用 VQGAN と造影像用 VQGAN の学習条件について示す。

表 1 腹臥位 MRI データセット

	非造影像(例)	造影像(例)
Train	330	330
Test	10	10

表 2 VQGAN の学習条件

	非造影像用	造影像用
Input/Output Shape	(1,92,212,212)	(1,92,212,212)
Epoch	500	500
Batch Size	2	2
Downsample Factor	[4, 4, 4]	[4, 4, 4]
Learning Rate	0.0003	0.0003
Embedding_dim	8	8
Optimizer	Adam	Adam
学習時間	2.7 日	2.9 日
Loss 関数	L1 Loss	L1 Loss

3.2 腹臥位用 VQGAN の再構築結果

表 1 の Test データを 3.1 節で学習した非造影像用、造影像用 VQGAN に入力し、再構築データを得た。図 1 に非造影像と造影像の再構築結果、表 3 に各定量評価手法の結果を示す。図 1 の結果より、腫瘍の位置が明確に再構築されていることが確認できる。これは、3D-BBDM および 3D-cBBDM の Latent Space への圧縮に適切なモデルが構築できたと考えられる。

3.3 3D-BBDM および 3D-cBBDM, CycleGAN の学習

3.4 表 1 に示した非造影像、造影像の Train データを非造影像用 VQGAN、造影像用 VQGAN で埋め込み表現にしたものを 3D-BBDM、3D-cBBDM の学習に使用した。ただし、CycleGAN は埋め込み表現に変換せずに使用する。表 4 に 3D-BBDM および 3D-cBBDM, CycleGAN の学習条件を示す。

3.5 3D-BBDM および 3D-cBBDM, CycleGAN の変換結果

3.6

表 4 の条件で学習した 3D-BBDM および 3D-cBBDM, CycleGAN に表 1 の非造影像の Test データを入力として、合成造影像への変換を行った。図 2 に変換結果、表 5 に各定量評価手法の結果を示す。ただし、変換結果は Min-Max 法で $[0, 1]$ に正規化を行っている。図 2 より、CycleGAN と比較し、3D-BBDM および 3D-cBBDM は腫瘍が鮮明でないことが確認できる。しかし、3D-cBBDM の方はわずかなではあるが腫瘍が確認でき、条件付けの効果が見られる。また、表 5 より定量的にも CycleGAN に劣っているが、同程度の評価を得ている。そして、3D-BBDM および 3D-cBBDM の学習時間は CycleGAN より短く、高速で安定した学習ができたといえる。

腫瘍が鮮明でなかった原因としては、BBDM の L1 Loss に問題があると考えられる。造影剤によって白く染まる部分は基本的に内臓と腫瘍であることから、非造影像から合成造影像に変換した際に損失として表れやすいのは内臓と腫瘍である。加えて、内臓は腫瘍と比較し、MRI 全体に対して占める領域が広いことから、内臓の次に腫瘍が損失として表れる。このため、BBDM の L1 Loss では内臓を重視し、腫瘍を重視しない傾向にあった可能性が挙げられる。




図 1 VQGAN の再構築結果

表 3 各定量評価手法の結果

RMSE ↓	PSNR ↑	SSIM ↑
--------	--------	--------

非造影像用	0.0559	25.186	0.7547
造影像用	0.0533	25.461	0.5713

表 4 各モデルの学習条件

	3D-BBDM	3D-cBBDM	CycleGAN
Input	(8,23,53,53)	(16,23,53,53)	(1,92,212,212)
Output	(8,23,53,53)	(8,23,53,53)	(1,92,212,212)
Optimizer	Adam	Adam	Adam
Learning Rate	0.0001	0.0001	0.0001
Epoch	1500	1500	400
Batch Size	2	2	1
Timestep	1000	1000	-
学習時間	2.3 日	5.3 日	10 日
Loss 関数	L1 Loss	L1 Loss	敵対的損失 一貫性損失




図 2 腹臥位における非造影像から合成造影像への変換結果

表 5 各定量評価手法の結果

	RMSE ↓	PSNR ↑	SSIM ↑
3D-BBDM	0.0582	24.755	0.7594
3D-cBBDM	0.0587	24.673	0.7554
CycleGAN	0.0575	24.819	0.7809

4. むすび

本研究では、腹臥位における非造影像から合成造影像へ変換するモデルの品質向上を目的に、VQGAN の構築、3D-BBDM および 3D-cBBDM モデルの提案を行った。VQGAN では腫瘍が鮮明に再構築されており、適切なモデルが構築できたといえる。また、提案モデルにより、従来の CycleGAN よりも高速で安定した学習ができた一方で、提案モデルでは腫瘍が白く染まらず、品質は劣る結果となった。原因としては、腫瘍が重視されない損失関数を定義していたことが考えられる。

今後は、腫瘍が重視されやすい損失関数の設定、条件データ・条件付けの機構の改善によって、腫瘍が白く染まらない問題を解決する必要がある。

参考文献

- 1) M. Amano, et al., BioMed, vol. 2020, p.1-9, 2022.
- 2) 吉田雪子, 日本大学理工学部応用情報工学科令和 4 年度卒業論文, 2023.
- 3) 鳥巢美優, 日本大学理工学部応用情報工学科令和 5 年度卒業論文, 2024.
- 4) JY. Zhu, et al., ICCV, pp.2223-2232, 2017.
- 5) J. Ho, et al., NeurIPS, pp.6840-6851, 2020.
- 6) B. Li, et al., CVPR, pp.1952-1961, 2023.

- 7) Z. Wang, et al., IEEE TIP, pp.600-612, 2004.
- 8) P. Esser, et al., CVPR, pp.12873-12883, 2021.
- 9) O. Ronneberger, et al., MICCAI, Vol.9351, pp.234-241, 2015.

上の文章は原文

日本語添削後の文章を下に示す.

添削のルール

- ・最小主義に基づいたリファイン
- ・曖昧な表現の具体化
- ・空っぽ表現の削除（「～ということが重要です」, 「～することが期待される」など）
- ・「～を行う」, 「～である」の動詞化
- ・可能な限り簡潔な文章にし, 文章が長くないようにした.
- ・「このため」, 「よって」などの接続詞の削除

5. まえがき

造影腹臥位MRIは腫瘍を捉えるのに適したモダリティである。乳房温存手術の術前診断として使用される。手術時は背臥位であり、乳房の形状変化に伴い腫瘍の位置も変化する。造影腹臥位MRIを手術に直接利用できず、医師は経験的に切除範囲を決定する。この問題に対し、造影腹臥位・背臥位MRIで、腫瘍を皮膚にプロジェクションマッピングする技術¹⁾がある。造影MRIの直接利用が可能となるが、身体的・経済的なコストから造影背臥位MRIは撮影されにくい。造影背臥位MRIに近いデータを獲得する手法が求められている。本研究ではImage-to-Image(I2I)モデルで、非造影・造影腹臥位MRIと非造影背臥位MRIから造影背臥位MRIを得る。データ数が豊富な腹臥位MRIにおける非造影像から合成造影像へ変換するモデルを構築し、背臥位MRI用にモデルを転移する。

先行研究²⁾³⁾では、CycleGAN⁴⁾で腹臥位MRIにおける非造影像と造影像の相互変換したが、信号強度が大きく異なる、腫瘍が白く染まらない問題点があった。

本研究では、CycleGANより学習が安定しており、生成品質で優れている拡散モデル⁵⁾ベースのBrownian Bridge Diffusion Models(BBDM)⁶⁾を腹臥位における非造影像から合成造影像の変換に応用することで上記問題の改善をした。

6. 方法とI2Iモデル

6.1 データセットと前処理

モデルの学習、推論には腹臥位MRIデータを使用した。データによって値域が異なっており、外れ値がある。Min-Max法を用いて[0, 1]に正規化。また、データは(92, 212, 212)の形状にトリミング。表1にTrain, Testデータの例数を示す。

6.1 定量評価指標

変換データに対する定量評価として、Root Mean Squared Error(RMSE), Peak Signal-to-Noise Ratio(PSNR), Structural Similarity Index(SSIM)⁷⁾を使用した。式(1), (2), (3)~(6)にそれぞれ、RMSE, PSNR, SSIMを示す。ただし、 x は元データ、 $\hat{x}$ は変換データ、 μ は平均、 σ は分散、 cov は共分散、 N はボクセル数とする。

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (1)$$

$$PSNR = 10 \log_{10} \frac{MAX(=1)^2}{1/N \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (2)$$

$$SSIM = [l(x, \hat{x})] \cdot [c(x, \hat{x})] \cdot [s(x, \hat{x})] \quad (3)$$

$$l(x, \hat{x}) = \frac{2\mu_x\mu_{\hat{x}} + \text{const}}{\mu_x^2 + \mu_{\hat{x}}^2 + \text{const}} \quad (4)$$

$$c(x, \hat{x}) = \frac{2\sigma_x\sigma_{\hat{x}} + \text{const}}{\sigma_x^2 + \sigma_{\hat{x}}^2 + \text{const}} \quad (5)$$

$$s(x, \hat{x}) = \frac{2cov_{x\hat{x}} + \text{const}}{\sigma_x\sigma_{\hat{x}} + \text{const}} \quad (6)$$

6.1 3D-BBDM (提案I2Iモデル)

3D-BBDMはBBDMをMRIに対応できるように拡張したものであり、ドメインAからBへの変換を目的とした学習をする。Forward Process, Reverse ProcessをVector Quantized Generative Adversarial Networks(VQGAN)⁸⁾のLatent Spaceで行っている。

6.2 3D-cBBDM (提案I2Iモデル)

3D-cBBDMは、3D-BBDMに条件付けの機構を追加したものである。U-Net⁹⁾へデータを入力する際に、条件データを加

えることで条件付けした。条件付けの機構を追加した理由は、非造影像から合成造影像へ変換する際に腫瘍の位置を明確に再現するためである。

条件として加えるデータは、造影像に対して一定の閾値以上のボクセルだけを取り出し、VQGANによって埋め込み表現にしたものである。造影剤によって白くなった(腫瘍の位置が白くなった)部分だけを取り出せる

6.3 VQGAN

VQGANは次元圧縮に使う。Encoderで入力 x を潜在変数 $\hat{z}$ に変換し、式(7)で各ボクセルと z_k (Codebook)の差が最小となるような z_q に量子化を行う。

$$z_q = q(\hat{z}) := \operatorname{argmin}_{z_k} \|\hat{z}_{ij} - z_k\| \quad (7)$$

量子化された z_q をDecoderに通し、再構築データ $\hat{x}$ を得る。

6.4 CycleGAN

CycleGANはI2Iモデルである。データ x をデータ y に変換するGenerator G とデータ y をデータ x に変換するGenerator F , 変換結果を識別するDiscriminator D_x, D_y で構成される。

7. I2Iモデルの学習と推論

7.1 腹臥位用VQGANの学習

構築するVQGANは、非造影像用と造影像用の2種類である。表1に示したTrainデータを用いて学習した。表2に非造影像用VQGANと造影像用VQGANの学習条件を示す。

表6 腹臥位MRIデータセット

	非造影像(例)	造影像(例)
Train	330	330
Test	10	10

表7 VQGANの学習条件

	非造影像用	造影像用
Input/Output Shape	(1,92,212,212)	(1,92,212,212)
Epoch	500	500
Batch Size	2	2
Downsample Factor	[4, 4, 4]	[4, 4, 4]
Learning Rate	0.0003	0.0003
Embedding_dim	8	8
Optimizer	Adam	Adam
学習時間	2.7日	2.9日
Loss 関数	L1 Loss	L1 Loss

7.1 腹臥位用VQGANの再構築結果

表1のTestデータを3.1節で学習した非造影像用、造影像用VQGANに入力し、再構築データを得た。図1に非造影像と造影像の再構築結果、表3に各定量評価手法の結果を示す。図1より、腫瘍の位置が明確な再構築が確認できる。3D-BBDM, 3D-cBBDMのLatent Spaceへの圧縮に適切なモデルが構築できた。

7.2 3D-BBDMおよび3D-cBBDM, CycleGANの学習

表1に示した非造影像、造影像のTrainデータを非造影像用VQGAN, 造影像用VQGANで埋め込み表現にしたものを3D-BBDM, 3D-cBBDMの学習に使用した。

CycleGANは埋め込み表現に変換せずに使用する。

表4に3D-BBDMおよび3D-cBBDM, CycleGANの学習条件を示す。

7.4 3D-BBDMおよび3D-cBBDM, CycleGANの変換結果

7.5

表4の条件で学習した3D-BBDM, 3D-cBBDMおよびCycleGANに表1の非造影像のTestデータを入力して、合成造影像への変換した。図2に変換結果、表5に各定量評価手

法の結果を示す。変換結果は Min-Max 法で[0, 1]に正規化した。図 2 より, CycleGAN と比較し, 3D-BBDM, 3D-cBBDM は腫瘍が鮮明でない。3D-cBBDM の方はわずかではあるが腫瘍が確認でき, 条件付けの効果が見られる。また, 表 5 より定量的にも CycleGAN に劣っているが, 同程度の評価を得ている。3D-BBDM, 3D-cBBDM の学習時間は CycleGAN より短く, 高速で安定した学習ができた。

腫瘍が鮮明でなかった原因は, BBDM の L1 Loss に問題がある。造影剤によって白く染まる部分は基本的に内臓と腫瘍であることから, 非造影像から合成造影像に変換した際に損失として表れやすいのは内臓と腫瘍である。内臓は腫瘍と比較し, MRI 全体に対して占める領域が広く, 内臓の次に腫瘍が損失として表れる。このため, BBDM の L1 Loss では内臓を重視し, 腫瘍を重視しない傾向にあった。




図 3 VQGAN の再構築結果

表 8 各定量評価手法の結果

	RMSE ↓	PSNR ↑	SSIM ↑
非造影像用	0.0559	25.186	0.7547
造影像用	0.0533	25.461	0.5713

表 9 各モデルの学習条件

	3D-BBDM	3D-cBBDM	CycleGAN
Input	(8,23,53,53)	(16,23,53,53)	(1,92,212,212)
Output	(8,23,53,53)	(8,23,53,53)	(1,92,212,212)
Optimizer	Adam	Adam	Adam
Learning Rate	0.0001	0.0001	0.0001
Epoch	1500	1500	400
Batch Size	2	2	1
Timestep	1000	1000	-
学習時間	2.3 日	5.3 日	10 日
Loss 関数	L1 Loss	L1 Loss	敵対的損失 一貫性損失




図 4 腹臥位における非造影像から合成造影像への変換結果

表 10 各定量評価手法の結果

	RMSE ↓	PSNR ↑	SSIM ↑
3D-BBDM	0.0582	24.755	0.7594
3D-cBBDM	0.0587	24.673	0.7554
CycleGAN	0.0575	24.819	0.7809

8. むすび

本研究では, 腹臥位における非造影像から合成造影像へ変換するモデルの品質向上を目的に, VQGAN の構築, 3D-BBDM, 3D-cBBDM を提案した。VQGAN では腫瘍が鮮明に再構築されており, 適切なモデルが構築できた。従来の CycleGAN よりも高速で安定した学習ができた一方で, 提案モデルでは腫瘍が白く染まらず, 品質は劣る結果となった。原因は, 腫瘍が重視されない損失関数を定義が考えられる。

今後は, 腫瘍が重視されやすい損失関数の設定, 条件データ・条件付けの機構の改善によって, 腫瘍が白く染まらない問題を解決する。

参考文献

10) M. Amano, et al., BioMed, vol. 2020, p.1-9, 2022.
11) 吉田雪子, 日本大学理工学部応用情報工学科令和 4 年度卒業論文, 2023.
12) 鳥巢美優, 日本大学理工学部応用情報工学科令和 5 年度卒業論文, 2024.
13) JY. Zhu, et al., ICCV, pp.2223-2232, 2017.
14) J. Ho, et al., NeurIPS, pp.6840-6851, 2020.
15) B. Li, et al., CVPR, pp.1952-1961, 2023.
16) Z. Wang, et al., IEEE TIP, pp.600-612, 2004.
17) P. Esser, et al., CVPR, pp.12873-12883, 2021.
18) O. Ronneberger, et al., MICCAI, Vol.9351, pp.234-241, 2015.

日本語→英文に使用するモデルは ChatGPT-o4 である。
選択理由に関しては、別の添付 PDF に示した通りである。

授業で学んだ内容のもと、以下のようなプロンプトを作成した。

「あなたは、日本語の学術文書を英語に翻訳する専門アシスタントです。以下の原文を、次のガイドラインに従って、英語の学術論文として通用するレベルで翻訳してください。

✍ 翻訳方針：

- 正確性と自然さ：文法的に正しく、学術的に自然な英語表現にしてください。
- 専門性の維持：専門用語は正確に英訳し、可能であれば学術分野（例：生物学、物理学、心理学など）に応じた用語を使用してください。
- セクション構造の保持：Abstract, Introduction, Method, Results, Discussion などの構成は維持し、必要に応じて英語圏のスタイルに調整してください。
- 最小主義に基づくリファイン：
 - 冗長な表現は徹底的に削除
 - 曖昧な語句（例：「できるだけ頻繁に」→「once a day 以上」など）の具体化
 - 空っぽ表現（例：「～ということが重要です」「～することが期待される」など）の削除
 - 「～である」「～を行う」などの抽象動詞の明確な動詞化
 - 「このため」「よって」などの接続詞を可能な限り削除し、論理的に接続された自然な英文に
- 文法・表現への配慮：
 - 冠詞（the, a, an）の適切な使用
 - 可算・不可算名詞の使い分け
 - 動詞の自動詞・他動詞の使い分け
 - 時制の一貫性
- 可読性：
 - 長い日本語の文は必要に応じて英語で分割し、明晰で読みやすくしてください。
- 原文の意味内容は厳密に保持してください。ただし、誤字脱字や不自然な表現がある場合は、自然な意味を推測して英訳してください。
- 翻訳対象は論文に限らず、学会発表スライド、ポスター原稿、レジュメ、要旨なども含まれます。

文章作成の方針

• 翻訳方針に沿っていない内容を挙げて、ChatGPT-o4 に入力し、再構築した。

例（Abstract）

- 2 行目最後：surgery is performed in the supine position
なぜ the がついている？→ 手術は supine position に限定されるから？

prone position との対比だから？

- 6 行目：Projection mapping (PM) techniques have been developed to

project tumor positions from both prone and supine MRIs onto the skin.

ちょっと長いかな？

- 8 行目：subjective estimation. 前には empirical judgement とある

- 9 行目：limiting the clinical application of PM

原文は、造影背臥位 MRI は撮影されにくく、PM 法は使われない。まあいいか？・・・

the が使われているのは PM 法という特定のケースであるから。

- 10 行目：To make PM-guided surgery feasible, we aim to generate supine contrast-enhanced MRI.

なんかめんどくさい。もっと端的にしよう あと contrast-enhanced prone mriの方が自然か？

- 12 行目：to convert non-contrast prone MRIs into contrast-enhanced ones,

ones 使わないでもっとわかりやすく書けないかな
そのあとの using a large dataset もいいけど

うーん？

- 最終行：non-contrast prone MRIs into contrast-enhanced versions

なんで versions 使った？？？

9. Introduction

Contrast-enhanced prone MRI is effective for visualizing breast tumors. It is widely used for preoperative assessment in breast-conserving surgery. surgery is performed in the supine position. This causes tumor displacement, making prone MRI unsuitable for intraoperative use. Surgeons must rely on empirical judgment to determine the resection area.

Projection mapping (PM) techniques have been developed to project tumor positions from both prone and supine MRIs onto the skin. PM allows more accurate resection planning without subjective estimation. However, contrast-enhanced supine MRI is difficult to obtain, which limits the clinical application of PM.

To solve this problem, We proposed a method to generate contrast-enhanced supine MRI using deep generative models. First, we train a model with a large prone MRI dataset to convert non-contrast into contrast-enhanced. Second, we fine-tune the model with a small supine MRI dataset to generate synthetic contrast-enhanced supine MRI.

Previous studies enabled image translation between non-contrast and contrast-enhanced prone MRI. However, they failed to highlight tumors clearly. To overcome this, we adopt a diffusion model known for high-quality image generation. This model improves tumor visibility in the translation from non-contrast to contrast-enhanced prone MRI

10. Method and I2I Models

10.1 Dataset and Preprocessing

Prone MRI were used for model training and inference. Due to variation in intensity ranges and the presence of outliers, voxel values were normalized to the range [0, 1] using Min-Max normalization. All volumes were resized to a shape of (92, 212, 212) for processing. The number of training and test samples is summarized in Table 1.

10.2 Quantitative Evaluation Metrics

We used Root Mean Squared Error(RMSE), Peak Signal-to-Noise Ratio(PSNR), and Structural Similarity Index(SSIM) to evaluate the inferred data. Equations (1), (2), and (3)~(6) define RMSE, PSNR, and SSIM, respectively.

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (1)$$

$$PSNR = 10 \log_{10} \frac{MAX(=1)^2}{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (2)$$

$$SSIM = [l(x, \hat{x})] \cdot [c(x, \hat{x})] \cdot [s(x, \hat{x})] \quad (3)$$

$$l(x, \hat{x}) = \frac{2\mu_x \mu_{\hat{x}} + \text{const}}{\mu_x^2 + \mu_{\hat{x}}^2 + \text{const}} \quad (4)$$

$$c(x, \hat{x}) = \frac{2\sigma_x \sigma_{\hat{x}} + \text{const}}{\sigma_x^2 + \sigma_{\hat{x}}^2 + \text{const}} \quad (5)$$

$$s(x, \hat{x}) = \frac{2cov_{x\hat{x}} + \text{const}}{\sigma_x \sigma_{\hat{x}} + \text{const}} \quad (6)$$

10.3 3D-BBDM(Proposed I2I Model)

3D-BBDM is an extension of BBDM adapted for 3D volume data. The model is trained to translate images from domain A to domain B. Forward and reverse diffusion processes are executed in the latent space of a Vector Quantized Generative Adversarial Network (VQGAN).

10.4 3D-cBBDM(Proposed I2I Method)

3D-cBBDM is an extension of 3D-BBDM with a conditional mechanism. Conditioning is implemented by feeding both the input and the condition data into the U-Net[9]. This mechanism is introduced to better preserve tumor localization when translating

non-contrast images into contrast-enhanced ones.

The condition data are derived by extracting voxels from the contrast-enhanced images that exceed a predefined intensity threshold. These regions, corresponding to areas highlighted by the contrast agent (i.e., tumor regions), are encoded into latent representations using VQGAN.

10.5 VQGAN

VQGAN is used for dimensionality reduction. The encoder maps the input x to a latent representation z_{hat} . Quantization is then applied to obtain z_k , which minimizes the distance to the nearest codebook vector z_q , as defined in Equation (7):

$$z_q = q(\hat{z}) := \underset{z_k}{\operatorname{argmin}} \|\hat{z}_{ij} - z_k\| \quad (7)$$

10.6 CycleGAN

CycleGAN is an image-to-image (I2I) translation model. It consists of two generators, G and F , and two discriminators, D_X and D_Y . Generator G translates data x to y_{hat} , while generator F maps y to x_{hat} . The discriminators evaluate the realism of the translated outputs in domains X and Y , respectively.

11. Training and Inference of I2I Models

11.1 Training of VQGAN for Prone MRI

Two VQGANs were constructed for non-contrast and contrast-enhanced MRI. Both were trained using the training data shown in Table 1. Table 2 presents the training settings for each model.

Table 11 Prone MRI Dataset

	Non-Contrast	Contrast Enhanced
Train	330	330
Test	10	10

表 12 VQGAN Training Settings

	Non-Contrast	Contrast Enhanced
Input/Output Shape	(1,92,212,212)	(1,92,212,212)
Epoch	500	500
Batch Size	2	2
Downsample Factor	[4, 4, 4]	[4, 4, 4]
Learning Rate	0.0003	0.0003
Embedding_dim	8	8
Optimizer	Adam	Adam
Learning Time	2.7 day	2.9 day
Loss Function	L1 Loss	L1 Loss

11.2 Reconstruction Results of VQGANs for Prone MRI

The VQGANs for non-contrast and contrast-enhanced MRI, trained as described in Section 3.1, were applied to the test dataset listed in Table 1 to obtain reconstructed images. Figure 1 shows the reconstruction results for both modalities, and Table 3 reports the corresponding quantitative evaluation metrics.

The results in Figure 1 confirm that tumor locations were clearly preserved in the reconstructions. These results indicate that the VQGANs are suitable for latent space compression in both 3D-BBDM and 3D-cBBDM.

11.3 Training of 3D-BBDM, 3D-cBBDM, and CycleGAN

The non-contrast and contrast-enhanced training data shown in Table 1 were encoded into latent representations using the corresponding VQGANs. These embeddings were used to train 3D-BBDM and 3D-cBBDM. CycleGAN, by contrast, was trained directly on the image data without latent encoding. Table 4 summarizes the training settings for all models.

11.4 Translation Results of 3D-BBDM, 3D-cBBDM, and CycleGAN

The trained models—3D-BBDM, 3D-cBBDM, and CycleGAN—were used to translate the non-contrast test data from Table 1 into synthetic contrast-enhanced images under the training conditions listed in Table 4. The translated outputs were normalized to the range [0, 1] using Min-Max normalization. Figure 2 shows the visual

results, and Table 5 reports the quantitative evaluation metrics.

Compared to CycleGAN, both 3D-BBDM and 3D-cBBDM produced less distinct tumor regions. However, 3D-cBBDM retained faint tumor features, suggesting a slight benefit from conditioning. Although the scores in Table 5 indicate that both BBDM-based models performed slightly worse than CycleGAN, their evaluation values remained comparable. Furthermore, the training time for 3D-BBDM and 3D-cBBDM was shorter than that of CycleGAN, enabling faster and more stable training.

The reduced clarity of tumor regions in the BBDM-based outputs appears to stem from limitations in the L1 loss. Since contrast agents primarily highlight internal organs and tumors, these regions contribute most significantly to the reconstruction loss. Organs occupy a larger volume in MRI scans than tumors, causing the L1 loss to prioritize organ reconstruction over tumor detail. As a result, the model tended to underemphasize tumors during training.




Figure 5 VQGAN Reconstruction Results

Table 13 Quantitative Evaluation Results

	RMSE ↓	PSNR ↑	SSIM ↑
Non-Contrast	0.0559	25.186	0.7547
Contrast-Enhanced	0.0533	25.461	0.5713

Table 14 I2I Models Training Settings

	3D-BBDM	3D-cBBDM	CycleGAN
Input	(8,23,53,53)	(16,23,53,53)	(1,92,212,212)
Output	(8,23,53,53)	(8,23,53,53)	(1,92,212,212)
Optimizer	Adam	Adam	Adam
Learning Rate	0.0001	0.0001	0.0001
Epoch	1500	1500	400
Batch Size	2	2	1
Timestep	1000	1000	-
Learning Time	2.3 days	5.3 days	10 days
Loss Function	L1 Loss	L1 Loss	Adversarial Loss Consistency Loss




Figure 6 Translation Results

Table 15 Quantitative Evaluation Results

	RMSE ↓	PSNR ↑	SSIM ↑
3D-BBDM	0.0582	24.755	0.7594
3D-cBBDM	0.0587	24.673	0.7554
CycleGAN	0.0575	24.819	0.7809

12. Conclusion

This study proposed 3D-BBDM and 3D-cBBDM to improve the quality of translating prone non-contrast MRI into synthetic contrast-enhanced images, along with the construction of VQGANs for latent compression. The VQGANs achieved clear reconstruction of tumor regions, indicating that appropriate latent models were successfully built. Compared to the conventional CycleGAN, the proposed models enabled faster and more stable training. However, tumor regions were not well enhanced, resulting in lower image quality. This limitation is likely due to a loss function that fails to sufficiently prioritize tumor regions.

Future work will focus on designing loss functions that emphasize tumor structures and improving the conditioning mechanism and input data to address the lack of tumor enhancement.

References

- 19) M. Amano, et al., BioMed, vol. 2020, p.1-9, 2022.
- 20) 吉田雪子, 日本大学理工学部応用情報工学科令和4年度卒業論文, 2023.
- 21) 鳥巢美優, 日本大学理工学部応用情報工学科令和5年度卒業論文, 2024.
- 22) JY. Zhu, et al., ICCV, pp.2223-2232, 2017.
- 23) J. Ho, et al., NeurIPS, pp.6840-6851, 2020.
- 24) B. Li, et al., CVPR, pp.1952-1961, 2023.
- 25) Z. Wang, et al., IEEE TIP, pp.600-612, 2004.
- 26) P. Esser, et al., CVPR, pp.12873-12883, 2021.
- 27) O. Ronneberger, et al., MICCAI, Vol.9351, pp.234-241, 2015.

各章の評価

Introduction

- ある患者の「prone」の説明の後に「the supine position」とあり、腹臥位 MRI を撮影した患者の背臥位 MRI という流れになっており、「the」の使い方が適切
- その後の「the resection area」も、前文で示された「患者の切除範囲の決定」という前文の患者に着目した「the」であり適切.
- 具体的な方法が示されている（曖昧でない）

Method and I2I Models

- 曖昧な表現がない
- 用語の使われ方が正しい
- 深層学習分野での画像変換は Image Translation と呼ばれる. この変換で Translate が使用されており、適切.
- 正式名称（略称）の形になっている
- 動詞の主語が明確
- このため、することが期待されるといった冗長さが無い

Dataset and Preprocessing

- 入力サイズ、正規化方法（Min-Max）、クロッピング形状 (92,212,212) が明示されており、簡潔かつ十分。

Results

- 腫瘍の不明瞭さについて、背景知識に基づいた論理的な説明がされている。

Conclusion

- the lack of tumor enhancement や loss function that fails to sufficiently prioritize tumor regions など、原因と課題が明示されている。

総合評価

翻訳は全体的に文法的に正確で、英語として自然な表現になっており、冠詞や時制の使い方もだいたい適切だった。専門用語の使い方も正しく、VQGAN や拡散モデル、CycleGAN など、深層学習分野で使われる技術が正確に訳されている点が評価できる。表現は全体的に簡潔で、「～することが重要である」や「あいまいな言い回し」といった空虚な表現もなく、最小主義の観点からも整理されていると感じた。また、文が長くなりすぎないように適切に区切られており、読みやすさも保たれていた。原文の意味も反映されていて、内容を正しく伝えられていた。

したがってこの文章を選択した。