

インサイドセールス音声の特徴づける音響特徴の研究

A study of acoustic features in inside sales speech

浅井拓也 凌佩珊 菊池英明 神長伸幸

早稲田大学 人間科学部

ミイダス株式会社 HR サイエンス研究所

Abstract

原文

In this study, simulated business meeting speech with controlled linguistic context was acquired and the distribution of acoustic features was examined. A total of 88 acoustic features were exhaustively calculated. Next, the t-SNE method was used for dimensionality reduction and to identify acoustic features that reveal speaker differences. The results showed that the mean value of delta F0, the variance of delta power, and the mean value of vocal fold vibration intensity characterized inside-sales speech.

ChatGPT o3 で簡略化

We recorded simulated business-meeting speech under controlled conditions and extracted 88 acoustic features. Using t-SNE for dimensionality reduction, we found that three features—the average change in F0, the variability of power change, and the average vocal-fold vibration intensity—clearly distinguished inside-sales speech.

google 翻訳で日本語訳→簡略化→google 翻訳で英訳

日本語訳

本研究では、言語文脈が制御された模擬ビジネスミーティング音声を収録し、音響特徴量の分布を調べた。合計 88 個の音響特徴量を網羅的に算出した。次に、t-SNE 法を用いて次元削減を行い、話者間の違いを明らかにする音響特徴量を抽出した。その結果、デルタ F0 の平均値、デルタパワーの分散、および声帯振動強度の平均値に、社内営業音声の特徴が表れていることが示された。

簡略化

本研究では、文脈が制御された模擬音声を収録した。音響特徴量の分布を調べたところ、合計 88 個の音響特徴量を算出し、それらを t-SNE 法を用いて次元削減を行い、話者間の違いを明ら

かにした。その結果、デルタ F0 の平均値、デルタパワーの分散、および声帯振動強度の平均値に、社内営業音声の特徴がみられた。

英訳

In this study, we recorded simulated speech with controlled context. We investigated the distribution of acoustic features, calculated a total of 88 acoustic features, and performed dimensionality reduction using the t-SNE method to clarify the differences between speakers. As a result, the characteristics of in-house sales speech were found in the average delta F0, the variance of delta power, and the average vocal fold vibration strength.

以下、AI という表記はすべて ChatGPT o3 で行ったものである。

1. 背景・目的

原文

①我々はインサイドセールスの音声における音響特徴を研究し、その知見を営業成績の推定や商談会話のための発話訓練に活用することを目指している。②商談会話を対象とした研究では発話の言語的特徴が興味を中心であり、音声の音響的特徴に関する議論は限定的である。Stoltzman は、説得を意図した 5 分未満のプレゼンテーション音声を解析し、Vocal Activity (発話量や話速など) が高く、Vocal Emphasis (音圧や音高など) が低い音声は説得力があると知覚されやすいことを報告している [Stoltzman 06]。また、同研究において、アポイントメント獲得を意図したカスタマーサービス音声を解析し、Vocal Activity が低く、Vocal Emphasis が高い発話者が、アポイントメント獲得に成功しやすいことを報告している。③この研究は商談会話の成否が、言語的な内容のみならず、音声の音響的印象に影響されることを示す重要な研究であるものの、利用されている音響特徴が限定的であり、また、実験で用いられる音声の言語情報も統制されていない。そのため、④本研究では、言語情報の統制した模擬商談音声を収集し、音響特徴量を網羅的に調査することにより、商談音声において発話者の声を特徴づける音響的特徴の選出を目的とした。

英訳する際に特に気を付けたポイントと AI の活用方法

①は「目指している」を進行形にせず現在形にするよう注意した (We study ~)。

②は google 翻訳だと In research on business conversations, the focus has been on the linguistic features of speech, and discussion of the acoustic features of speech has been limited になるが、Research on business conversations ~にして副詞を抜いて簡略化した。

また、この文を AI に簡略化させると Previous research has mostly examined what people say, not how they sound. とさらに短くなっていた。what と how の対比構造にすることで speech の繰り返しを避け、「言語的特徴」や「音響的特徴」の言い換えもしっくり来たので、後半部分はこれを採用した。最終的な英訳は Research on business conversations has mostly examined what people say, not how they sound.

③は「～。そのため～」ではなく Because ～にし最初から「～のため、～だ」という形にした。④では「また本研究では」ではなく、we recorded ～にした。最終的な英訳は Because Stoltzman used only a few acoustic measures and did not control the spoken content, we recorded linguistically controlled mock sales conversations, extracted many acoustic features, and identified those that best distinguish speakers in negotiation settings.

英訳

①We study the acoustic characteristics of speech in inside sales, aiming to use the findings to estimate sales performance and to train speech for business negotiations. The recording involved 172 speakers with work experience acting as salespeople, and two university students acting as customers. ②Research on business conversations has mostly examined what people say, not how they sound. Stoltzman analyzed speech from a less than 5-minute presentation intended to persuade, and reported that speech with high vocal activity (volume of speech, speech rate, etc.) and low vocal emphasis (sound pressure, pitch, etc.) is more likely to be perceived as persuasive [Stoltzman 06]. In the same study, he also analyzed customer service speech intended to secure appointments, and reported that speakers with low vocal activity and high vocal emphasis were more likely to succeed in securing appointments. ③Because Stoltzman used only a few acoustic measures and did not control the spoken content, ④we recorded linguistically controlled mock sales conversations, extracted many acoustic features, and identified those that best distinguish speakers in negotiation settings

2. 方法

原文

①言語情報の統制のため、インサイドセールスのうちアポイントメント獲得場面を想定した模擬商談音声を取録した。セールス役として実務経験ある発話者 172 名、顧客側として、大学生 2 名が取録に参加した。実際のセールス場面を想定し、Amazon Connect を介したオンライン環境にて音声取録を行った。②取録は大きく、台本部と、自由発話部に分けら

れる。台本部では、まず、セールス側は名乗りをあげ、次いで、採用の状況確認を行った。それに対し顧客側は自身が採用担当であり、採用を行っていることをセールス側に告げた。最後にセールス側が次回商談ために顧客の予定を尋ねた。ただし、発話の自然性を考慮し、それぞれの参加者には、細かい言葉遣いはあまり気にせず、流れの参考にするように教示がなされた。続く自由発話部では、募集職種や採用人数、採用スケジュール等、通常の業務に合わせた形式で自由に対話を行った。本研究では台本部、最終発話を対象に解析を行った。なお、最終発話内容は以下の通りである。

③「そうしましたら、お電話越しにはなりますが、今までにない 採用手段としてミイダスの画面をご覧くださいながらご提案できればと思うのですが、近日でお仕事のおじゃまになりにくいタイミングはございますか？」

収録された音声は、聴取にて、セールスの発話箇所が特定された。この際に、発話内容が台本から大きく離れ、発話箇所の特定が困難なものや、背景雑音が大きいデータは除外され、合計 100 個の音声を選択された (女性 7 名、男性 93 名)。抽出された音声は OpenSMILE [Eyben 10] を用いて音響特徴量に変換された。ここで音響特徴量セットには、eGMAPS [Eyben 15] を利用した。このセットは Fo や Jitter など周波数特性に関わる特徴量や、Formant をはじめとするスペクトル特性に関わる特徴量、Loudness をはじめとするパワー特性に関わる特徴量、計 26 種類が基本になる。この基本特徴量から平均や標準偏差、レンジ、四分位などの要約統計量を算出し、88 次元の特徴量が抽出された。

算出された音響特徴量を要約し、特徴量の効果を分析するために、t-SNE 法による次元圧縮 [Maaten 08] を試みる。t-SNE 法では、高次元のデータ集合を 2, 3 次元に配置する際に高い確率で類似した集合が近傍に、異なる集合が遠方になるように 対応づける。上述の音響解析によって得られた 88 次元の特徴量 に対して、t-SNE 法を適用することで、特徴量間の距離に基づいて音声の集合が形成され、類似したまとまりや、音声間の距離が可視化される。この空間においてそれぞれの特徴量の大きさを濃淡で表示することにより、音声を分離するのに有効な特徴量を探索した。

英訳する際に特に気を付けたポイントと AI の活用方法

①に「言語情報の統制のため」とあるが、ここでは control for を使わず、To eliminate confounding linguistic variation,とすることで統制の意味を明らかにした。

②では(i) (ii)と番号を振ることで、分かりやすくまとめた。(i) a scripted section~
(ii) a free-conversation section~

③は AI を用いて、論文中の会話の英訳の仕方を参考にした。

④で解析目的（要約＋識別力評価）を能動態で提示して、次に続く手法（t-SNE）へ自然につなげた。（AI 参考）

英訳

①To eliminate confounding linguistic variation, we constructed a linguistically controlled corpus of mock inside-sales calls that mirror an appointment-winning scenario. The recording involved 172 speakers with work experience playing the role of salesperson, and two university students playing the role of customers. The audio was recorded in an online environment via Amazon Connect, simulating a real sales situation. ②Each call contained (i) a scripted section—self-introduction, confirmation of the customer’s recruitment status, and a request for a subsequent meeting—and (ii) a free-conversation section in which the parties discussed job category, head-count, and hiring schedule. Participants were instructed to follow the script’s logical flow while maintaining natural prosody and wording. The present study analyzes the scripted portion and the salesperson’s closing statement.

③(e.g. “While viewing the Mydas screen, may I outline this new recruitment method? Could we schedule a convenient follow-up call?”). All recordings were manually reviewed; utterances that diverged markedly from the script or contained excessive background noise were discarded. The final dataset comprises 100 high-quality speech samples (7 female, 93 male). Acoustic features were extracted from the speech samples with **openSMILE** (Eyben et al., 2010). The **extended Geneva Minimalistic Acoustic Parameter Set (eGeMAPS)** was adopted (Eyben et al., 2015). eGeMAPS provides 26 low-level descriptors (LLDs) encompassing frequency-related measures (e.g., F0, jitter), spectral measures (e.g., formant frequencies), and energy-related measures (e.g., loudness). For each LLD we calculated functionals—mean, standard deviation, range, and quartiles—resulting in 88-dimensional feature vectors per utterance.

④To summarise this feature space and investigate the discriminative utility of individual parameters, we applied **t-distributed Stochastic Neighbour Embedding (t-SNE)** (van der Maaten 2008). t-SNE projects high-dimensional data into two or three dimensions such that acoustically similar observations are placed close together, whereas dissimilar observations are mapped further apart. When the 88-D vectors were projected, clusters of acoustically similar utterances and inter-speaker distances became visually apparent.

Overlaying the magnitude of each feature on this map with a grey-scale heat enabled us to isolate the acoustic attributes that most effectively distinguish speakers.

3. 結果

原文

t-SEN 法による圧縮結果を、それぞれの音声の Fo 平均毎に色分けした結果を図 1 に標準偏差毎に色分けした結果を図 2 に示す。①図 1 を観察すると、右上に値の高い群が存在する。これらの群の音声を聴取すると、この群には女性話者が集まっていた。一方で、図 2 を観察すると、男女ともに、値の高い群と低い群が存在することがわかった。この結果から、Fo に関しては平均値よりも標準偏差の方が発話者の声を特徴づけやすいことが示唆された。

同様に音圧平均毎に色分けした結果を図 3 に、標準偏差毎に色分けした結果を図 4 に示す。図 3 を観察すると、一様に高い値を示した。一方で、①図 4 を観察すると、男女ともに、右下に特に値の高い群が集中した。この結果から、音圧に関しては平均値よりも標準偏差の方が発話者の声を特徴づけやすいことが示唆された。Alpha Ratio は 50 ~ 1000 Hz 帯域と 1 ~ 5 kHz 帯域の合計エネルギー比である。Hammarberg Index は 0 ~ 2 kHz 帯域と 2 ~ 5 kHz 帯域の最大エネルギー比である。t-SEN 法による圧縮結果を、Alpha Ratio の平均値毎に色分けした結果を図 5 に、Hammarberg Index の平均値毎に色分けした結果を図 6 に示す。図 5, 6 共に男女共に上下に高い値を示す群と、低い値を示す群に分割された。Alpha Ratio, Hammarberg Index は声帯振動を前提とする低周波数帯域と、高周波数帯域のエネルギー比であることから、声帯振動の強さが発話者の声を特徴づけやすいことが示唆された。②最後に声質に関わる特徴量として知られる 500 Hz と 1500 Hz 帯域のスペクトル傾斜及び Jitter 平均毎に色分けした結果を、図 7, 図 3 に示す。図 7 を観察すると、男女共に中央下に比較的值の高い群が観察された。図 3 を観察すると、特に中央付近に比較的高い値の群が観察された。500 Hz と 1500 Hz 帯域のスペクトル傾斜は声帯振動の息もれ性を、Jitter は声帯振動の周期性を表す音響特徴量であることから、特に女性においては、息もれ性に、男性においては声帯振動の周期性に、発話者の声を特徴が表出されることが示唆された。

英訳する際に特に気を付けたポイントと AI の活用方法

①「図 1 を観察すると」や「図 4 を観察すると」のような言い方の英訳は避け、**Figure 1 presents** のように、太字にして **present** を使うことで簡略化した。

②の「最後に声質に関わる特徴量として知られる」を「声質の特徴量である」に言い換えた。

英訳

①**Figure 1** presents the t-SNE projection color-coded by mean F0. A distinct high-F0 cluster emerges in the upper-right quadrant and is dominated by female speakers.

Figure 2, color-coded by the standard deviation of F0, shows both male and female utterances partitioned into high- and low-variability clusters. These patterns indicate that F0 variability (SD) provides a more discriminative cue for speaker characterization than the mean F0 value.

Figure 3 illustrates the t-SNE map color-coded by mean sound-pressure level (SPL); values are uniformly high, yielding minimal speaker separation.

Figure 4, color-coded by the standard deviation of SPL, reveals a distinct high-variability cluster in the lower-right quadrant that includes both male and female speakers. These findings indicate that SPL variability (SD) is more informative for distinguishing speakers than the mean SPL.

Figure 5 illustrates the t-SNE map color-coded by the mean Alpha Ratio; points split into vertically separated high- and low-ratio bands for both male and female speakers.

Figure 6, color-coded by the mean Hammarberg Index, shows a comparable bifurcation, confirming that the energy balance between low- and high-frequency bands varies markedly across speakers. ⑦These patterns imply that the distribution of low- versus high-frequency energy—a correlate of vocal-fold excitation strength—is a salient cue for speaker differentiation.

Figure 7 depicts the map color-coded by spectral tilt at 500 Hz and 1500 Hz; a high-tilt cluster emerges in the lower-central region across sexes, suggesting that breathiness distinguishes a subset of speakers, particularly females.

Figure 8, color-coded by the mean jitter, highlights a high-jitter cluster near the origin that is dominated by male speakers. Taken together, these results indicate that breathiness cues separate female voices, whereas cycle-to-cycle irregularity (jitter) is more informative for distinguishing male voices.

4. まとめと考察（同じ分なので省略）

言語的な内容を統制した模擬商談音声を取得し、音響的特徴の分布を調べた。音響特徴として Eyben らが提案した 88 次元の特徴を網羅的に算出した。解析の結果、F0 やインテ

ンシティの平均値のような静的な特徴量は男女差や、その人の個人の特徴を示すことは確認されたものの、話し方のような特性を表現することは困難であった。一方で変化量や加速度においては、インサイドセールスが能動的に行っている表現を抽出しやすいことが示唆された。

上記結果を踏まえ、Fo の平均値及び、標準偏差、Loudness 平均値及び標準偏差、Alpha Ratio の平均値及び標準偏差、Hammarberg Index の平均値及び標準偏差、スペクトル傾斜の平均値及び標準偏差、Jitter の平均値及び標準偏差の 12 次元に限定をし、t-SNE 法による次元圧縮を行った。圧縮された空間において、近い距離の音声がどのような印象を持つかを考察するために、音声同士の印象を聴取にて確認した。圧縮された空間を、K 平均法を用いて教師なしクラスタ解析を行い、それぞれのクラスタに属す音声を聴取した。聴取の結果、特に早口で話す印象の音声や、丁寧な印象を与える音声、抑揚豊かな印象の音声や、起伏の少ない印象の音声などに分離された。

これらの結果により、特にインサイドセールス音声を音響特徴で分類する場合には、静的な特徴よりも動的な特徴が効果的である可能性が示唆された。

参考文献 [Eyben 10] Eyben, F., Wöllmer, M., and Schuller, B.: Opensmile: the munich versatile and fast open-source audio feature extractor, in Proceedings of the 18th ACM international conference on Multimedia, pp. 1459–1462 (2010) [Eyben 15] Eyben, F., Scherer, K. R., Schuller, B. W., Sundberg, J., Andr e, E., Busso, C., Devillers, L. Y., Epps, J., Laukka, P., Narayanan, S. S., et al.: The Geneva minimalistic acoustic parameter set (GeMAPS) for voice research and affective computing, IEEE transactions on affective computing, Vol. 7, No. 2, pp. 190–202 (2015) [Maaten 08] Maaten, Van der L. and Hinton, G.: Visualizing data using t-SNE., Journal of machine learning research, Vol. 9, No. 11 (2008) [Stoltzman 06] Stoltzman, W. T.: Toward a social signaling framework: Activity and emphasis in speech, PhD thesis, Massachusetts Institute of Technology (2006)